信任需要基础设施：如何让AI可靠的取数

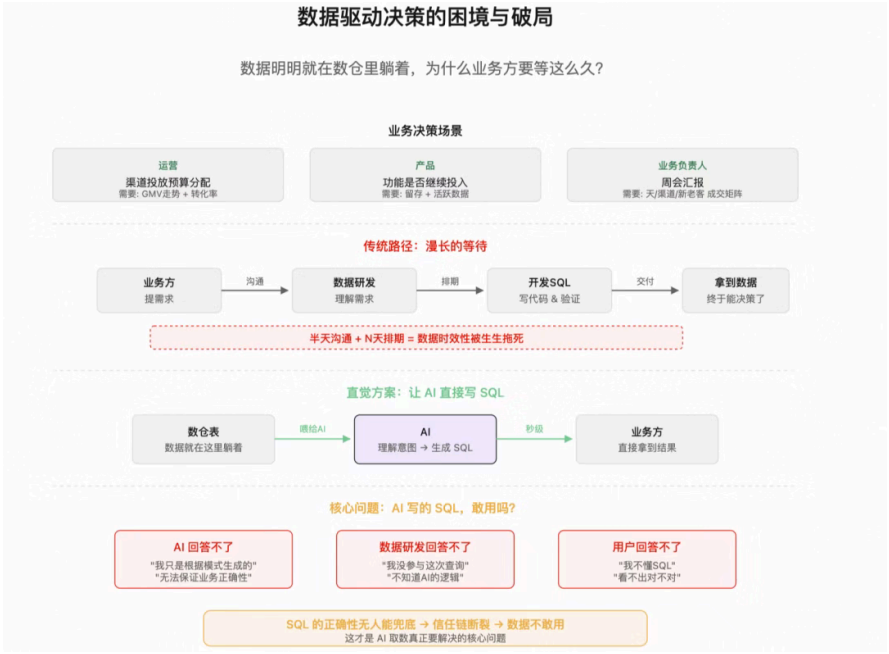
原创 直播技术团队 大淘宝技术 2026年8月27日 19:19 浙江 6人

本文针对AI在复杂数仓环境中取数易产生幻觉、缺乏信任的问题，提出了一套“AI思考能力+工程确定性”的解决方案。通过构建标准化的“代号层”统一业务语义以消除歧义，利用确定性的SQL引擎将用户需求转化为精准SQL并处理权限隔离，同时借助Skill机制限制AI的自由发挥空间并增加可审计性，从而构建起值得信赖的AI取数基础设施；这不仅实现了从模糊需求到准确数据的高效获取，更推动了数据开发角色向高价值语义资产建设的转型及组织协作模式的变革。

01 取个数而已，为什么这么难？

从数据的角度，去看这个世界，获取到自己想要的信息

业务每天都会产生大量的用户行为数据，这些数据都经由数据工程师的加工处理放在数据仓库中，有了这些数据可以让我们的业务决策变得更加合理，科学。但是这些数据已经在数仓了，但是业务一般情况下还是要等较长的时间才能看到想看的数据，为啥取个数这么难呢?



02 为什么不能完全信任AI：数仓复杂性导致模型幻觉不断变大

取数到底是在干什么

- 代号：物理事实的抽象代表

在语言学上，我们为了交流的方便，都会为一些复杂的东西，起一些代号，这些代号是物理事实的抽象代表，代号在我们的生活中处处可见，比如各种名称：人名、地名、物名等等。

在本文中取数语境中的核心代号都代表什么的含义。先看下两个核心抽象的代号：**指标是什么：业务主体行为的度量；维度是什么：业务主体行为发生的环境**。指标名、维度名是具体的代号。比如"用户在直播平台成交了多少钱"这个业务度量的代号是"成交金额","用户从哪种方式进入直播的这个行为环境"是"渠道名称"这个代号，这些代号就代表的是具体业务，都是具体的、真实的事件行为。很多约定俗称的代号，不用沟通解释大家都能对齐，但是一些专业的代号，或者一些事件行为，没有一些标准的代号名称，我们如果用这些各自理解的代号去沟通，去交流，那我们很难去沟通交流

- 真实场景

1）比如现在用户需要一个成交金额，数仓中刚好只有一个成交金额，我们就默认这个就是用户想要的那个成交金额，直接找到成交金额的这张表，基于这个表来组装出来SQL然后去执行，SQL执行返回结果

2）现在问题复杂了，用户说我要gmv，但是数仓中只有成交金额，我们就要去问，我们只有成交金额，你要的是不是成交金额，我们来说明下成交金额描述的事实行为，用户说下他想要的事实行为，达成一致，找到成交金额的这张表，基于这个表来组装出来SQL然后去执行，SQL执行返回结果

3）接着，用户说我要gmv，但是数仓中有两个成交金额的指标，但是计算方式不一样（一个限制了 字段A= 'Y',一个没限制），又要去问，你想要的成交金额是怎么计算的，这两个指标的代表的事实行为是啥（数据口径是啥），是不是你想要的计算方式，好的，用户明确了我要限制字段A='Y'的，好的找到字段A = 'Y' 的那个指标口径，写出一段SQL，SQL执行返回结果

- 流程抽象

其中的核心流程是：用户说他要什么（一个代号），这个代号代表一个业务行为的度量方式。数仓有什么（一堆代号），这些代号都分别代表的业务行为的度量方式，其中还有很多不同的度量方式，用着同一个代号。**有时候用户说的代号和数仓中的代号是对齐的，但绝大多数是对不齐的，代号对齐了，还要明确代号所代表的具体的事实行为是不是对齐了**。这部分对齐是取数的第一步，明确清楚业务想要的是哪个具体代号。第二步，写一个SQL，将这个代号的数据取出来

取数流程中有一个最核心的矛盾点：同一个东西的代号没有标准、没有达成共识

AI独立来完成取数

现在是要AI来完成这一流程：用户说出他想要的代号，AI进行语义理解，理解了用户想要什么。AI理解数仓，数仓中都有什么代号，并且理解清楚每个代号的具体含义。理解清楚之后将用户需求的代号和数仓中的一个代号匹配起来了，然后写一条SQL 返回给用户。在小批量表并且取数需求相对简单的场景下，AI的发散空间相对较小，单独使用AI完成这一流程，可信度还是比较高。但是在复杂的场景下，AI在完成这一流程的过程中就会遇到很多问题，首先AI理解用户语义，这个是AI理解自然语言的能力，模型本身的能力，这个强弱我们无法控制。但是接下来AI要理解数仓中的事实行为代号，理解完要写SQL，就会出现较大的问题

- 理解数仓很难避免幻觉

数仓是业务的数据抽象，业务的不断发展变化，业务的看数视角是不断变化的，决定了数仓是不断变化的，这些变化体现在数仓中就是：数据的事实行为描述越来越多、数仓不断的冗余、数仓表的不断膨胀，复杂性极大，具体到业务需求不知道应该用哪一种计算方式，只能不断的去确认沟通，这样的数仓复杂性，多义性让AI理解的话，幻觉极大，很难正确理解数仓中事实行为代号（数据口径）的现状

- 写出SQL更难避免幻觉

基于第一层理解数仓数据口径的基础上，叠加真实的取数需求，进入第二个问题：AI怎么写SQL。数仓是冗余的，同一个指标代号的计算方式是多样的，决定了取数SQL会涉及到很多的选择决策，比如指标计算口径确定、表选择，维度计算口径、表选择、数据筛选等等。这一步需要在第一步的基础上，再理解需求，进行很多的SQL决策，才能写出来一个语法正确、语义正确的SQL

AI 可以生成语法完美但语义错误的 SQL ，通过各种手段可以在很大的程度上做到70%，80%，甚至90%的正确率。这些正确率，听起来是好的，在评测的领域中就很好的成绩，但是在生产环境中呢，也就是意味着永远有错的可能，而用户是不知道这一次是对的，还是错的

此外，取数系统能发挥出最大的价值的点在于：这套系统的用户不是数据开发，而是运营、产品、分析师，甚至是 AI Agent 本身，他们无法判断一段 SQL 是否完全语义正确。如果系统的可靠性依赖于"有人会审 SQL"这个前提，用户并没有被解放，SQL必须无须确定，用户只确认，语义自己是不是想要的，只确认业务方面的知识，不需要关心这个数怎么取

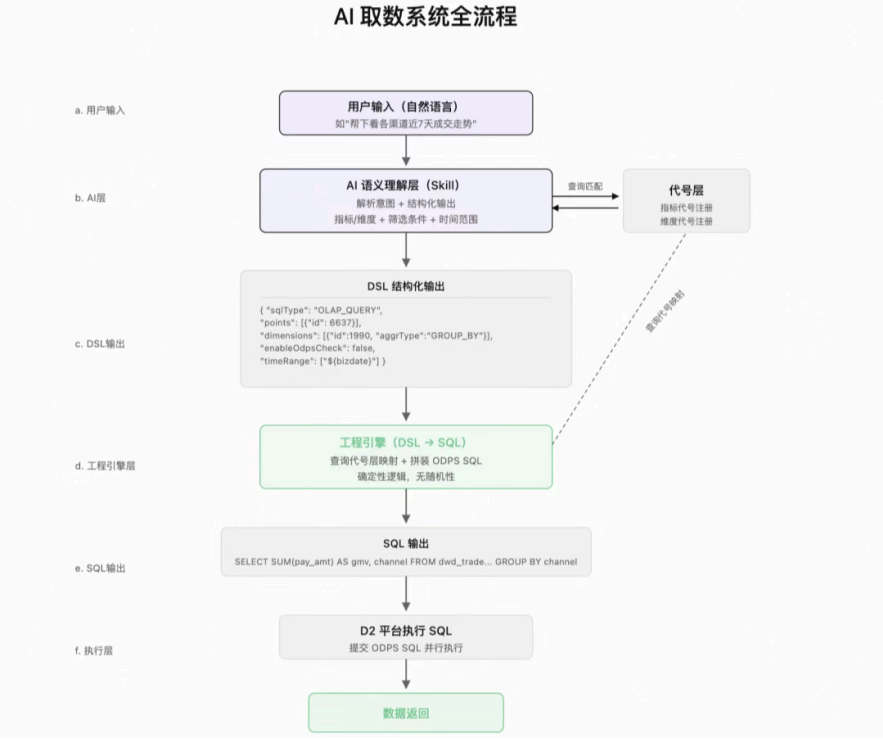
03 各取所长：AI的思考能力+工程的确定性

AI不擅长的事情：精准的完全确定的输出；工程擅长的事情：确定性的输入产生确定性的输出，用工程的强确定性来弥补AI的不确定性

针对AI怎么理解数仓中的事实行为代号？我们对数仓进行抽象规整，建设代号层，让AI有一个清晰、易用、便于理解的数据

针对AI怎么写SQL？我们将写SQL的复杂性屏蔽掉，只让AI输出用户的需求，构造一个查询请求（轻量级的JSON），工程将查询请求翻译为确定性SQL

整体流程图



为什么值得信任

每一环都有明确的角色来确认，保证整体流程可靠、值得信任



- 各环节的判断力

在代号对齐环节，用户需要判断这个代号是不是自己想要的

在代号数仓映射环节，数仓同学需要判断这个代号在数仓中的口径是什么

在SQL引擎生成环节，SQL引擎需要判断SQL的组织是不是语法语义正确的

- 对用户的要求有所变高

在现在的全链路协作的过程中，用户可以提一个相对模糊的取数需求，或者说截一个图，或者说可以给某某去确认，研发的主观能动性，会去通过各种方式，和用户沟通收集信息把这个需求澄清完毕。但是现在AI取数系统的流程中需要用户自己根据AI理解代号层的结果，然后和用户对齐代号，用户需要对AI对齐的代号有判断力，要和AI对齐自己的真实意图。这其中也变相对我们的代号层的质量有很高的要求，不能有二义性，要具有含义代表唯一性

通过AI Agent平台直接使用

Skill作为现在Agent主流的扩展能力，在任何的平台都可以集成使用，同样的我们的取数技能在Claude Code、Qoder等Agent平台上都可安装使用

04

代号层 — 让同一个东西的代号有标准、达成共识

业务行为的标准、唯一的数据代号化表达。比如"在直播间成交的金额" 这个业务行为的代号就是"成交金额"，只有这样的一个名称

代号集，定义的就是这样一个映射关系，本质也是一个字典。通过这个直播数据大字典，我们可以对很多直播下事实达成共识，用一种代号来表达。我们基于阿里巴巴这个词沟通就不会有歧义，因为大家都知道阿里巴巴代表的是什么物理世界的东西。战争时代通过无线电进行发报，也要按照统一的密码来进行沟通，沟通双方也要定义好双方共同认可的密码本

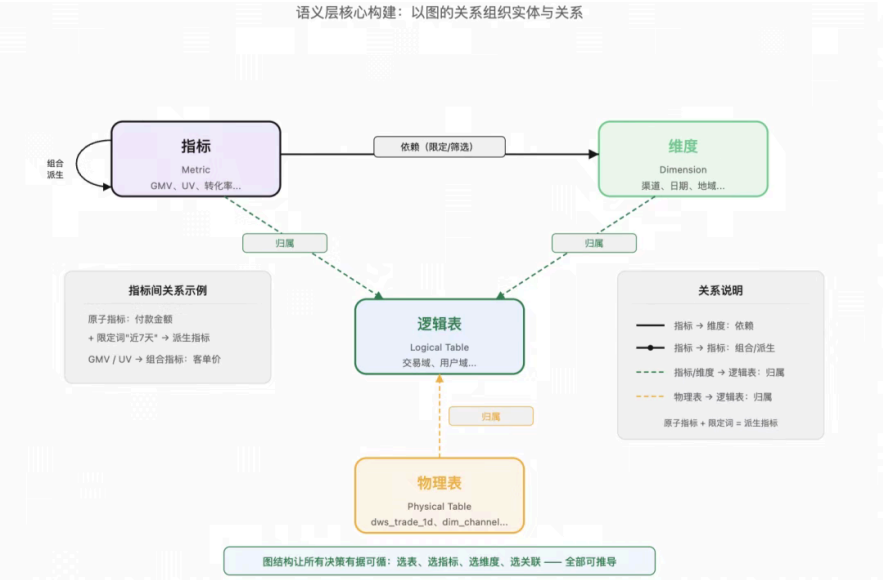
在系统中的定位

对于系统中的AI来说，代号层就是一个沟通的共识层，"统一了直播数据事实的文字"，让AI和用户可以用同样的一种语言和用户沟通，解决取数中代号对齐问题

对于系统中的SQL引擎来说，代号层就是一个数仓映射层，让代号回归到数仓，让代号具体落实到数字物理世界，解决取数中SQL书写问题

代号层的结构如何

我们以逻辑表为核心来构建我们的代号层。逻辑表就是整个代号层的骨架，从整个数仓的角度来说，本质是对业务过程的又一次抽象



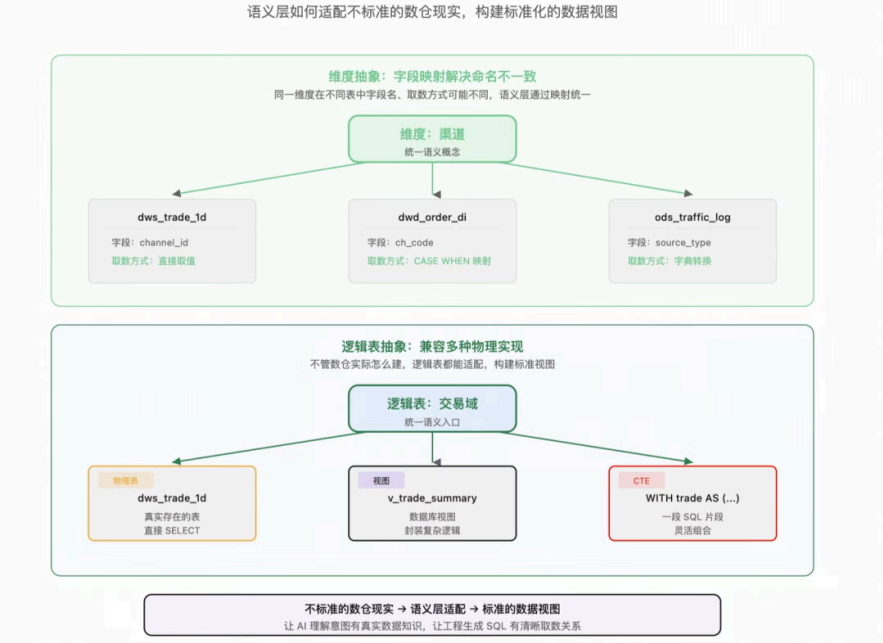
真实的数仓怎样挂载到代号层

对于同一个代号，数仓中都是有好几份的，是冗余存储的，冗余存储是数仓的一个核心特性

从大的逻辑上来说，核心分为事实表和维表。其中事实表是按照业务过程的来组织的表，业务过程就是业务时间行为的抽象集合。比如成交的业务过程，有明细表、各粒度的dws汇总表；同样的观看业务过程，有明细表、各粒度的dws汇总表。维度表核心有：各个实体的维表。比如主播维表、用户维表、商品维表等等。这个就是数仓的骨架部分，是这个数仓的核心

表所承载的都是维度和指标。这些维度和指标都是上文中代号的具体的数仓实现。比如成交金额这个代号，就在成交业务过程的明细表中的一个字段、在dws汇总表中的一个字段。这些具体的表字段，成交金额这个代号在数仓中的事实体现。也就是说，用户需要成交金额这个代号的时候，我可以给用户其中的任意一个都是对的，都是同一个事实的表达。所以数仓中的这些字段都会绑定在成交金额的这个代号上。同样的维度也是，同一个维度代号也是在数仓中的很多地方都是有的，很多数仓事实字段都可以表达出来这个代号

我们的代号是按照业务过程的标准组织的，如果真实的数仓也按照这个组织的标准去建设的话，那很完美的就可以进行对接。但是如果不标准，其实也没问题，只要能从标准中的数仓中抽象出来这些代号的具体实现就行。我们的代号层也设计了字段映射，自定义CTE等功能，来从逻辑上讲不标准的数仓，挂载到标准的代号层



05 SQL引擎 — 如何去写出来取数的SQL

在真实的数仓中，写SQL，也是一件看似简单，其实有超级多的细节选择的问题，并且都是确定性的规则，工程是最佳的，最值得信任的保障

用户通过和AI的交互，已经从标准的统一的代号库里面，取到了他想要的那一个代号，这个代号已经唯一确定了，接下来的核心动作就是拿到这个唯一的代号，从已经挂载到这个代号层的物理数仓，拿到这个统一的代号集，然后根据具体的实现方式，构建出来一条SQL

代号在数仓中具体化、唯一化

整体的选择的目标就是：在能正确满足需求的情况下，找到一种最快的计算方式，也就是找到一种参与计算数据量最小的一种方式。选择整体分为两步：

1. 收集本次需求的具体数仓要求
2. 在满足要去的表中，选择一张最优的

SQL组织

上面通过收集要求、按照数仓加工规则选择出来每个代号的具体表达，接下来就是按照标准SQL语法，将这些进行SQL组织。其中也有很多的细节，比如筛选提前做。如果有关联需要关联维表，还要确定关联方式。派生指标要先加工原子指标，先加工限定词，然后再后面的一层加工。如果有limit 还有需要在结尾添加limit语法

监控分析

有了这一套SQL引擎工程体系，我们将用户的查询记录下来。我们可以中心化将这些请求的日志，忠实的记录下来，然后做一些常用DSL的分析，工程稳定性的监控，为后续的数仓迭代，DSL能力覆盖范围迭代、评测系统构建等场景提供数据源支持

06 Skill：将AI拴在流程的笼子里

AI很强，但是很容易乱干，自以为是的去干，要设计一套让AI沿着工作的流程

门禁机制

有了上面的确定性的基础，我们怎么让AI确定的生成我们要的JSON结构呢？在这一步的核心风险点是，AI自己去查资产层会出现二义性或者多义性的情况。

在出现高歧义的情况下，必须要停下来去向用户确认，必须要遵循这个前提，不允许自己做决定。在生成SQL的过程中，AI只需要拿到工程生成的SQL，不允许修改任何SQL，一边需要用户确认，另一边生成的SQL不允许修改，最大限度的缩小AI发挥的空间

可审计回溯

我们在很多的关键流程节点都增加了过程留痕，比如查询到实体需要留痕、生成的JSON要保存下来、生成的SQL要保存下来，让每一步都可以追溯，AI也可以自己检查

钩子机制

在现在的Agent平台上，不管是Claude Code、Qoder、Codex都会有工程钩子的设计，这些让Agent在执行到某些动作的时候直接强制执行某段逻辑，让AI的可靠性持续增强

07 回到信任

信任不是给予的，是构建的

设计让AI值得信任的系统：我们的这套系统正式构建了一个值得信任的基础设施，我们整个系统也是一套AI系统。不管是语义层的基建，工程引擎的确定性生成，还是Skill中的门禁等等，都是为了信任而构建的一全套基础设施。在AI时代，从AI系统的角度来说，工程师最重要的能力不是使用 AI，而是设计让 AI 值得信任的系统

信任基建可以参与构建其他的信任系统：有了AI取数的这个值得信任的基建，下游数据消费想象空间非常丰富。运营、产品各个业务就可以直接快速的获取到自己想要的数据；下游的分析Agent可以直接对接我们的这个取数skill，直接产出分析结论；更进一步，甚至运营工作台也可以接入，看取数基建作为行为系统的一部分，信任基建可以参与构建其他的信任系统

传统协作关系的变革

研发工作重心变革：信任的不断建立，让数据开发同学从"写 SQL 的人"变成了"建语义层的人",核心工作从重复性的取数开发，转变为高价值高复用性的语义资产建设和数据质量管理

组织协作变革：随着技术的发展，信任程度越来越高，一台机器可能重塑一个行业的协作方式：比如一台印刷机就代替了传统的印刷行业，印刷的效率极大提高，让用户更专注于你要印什么，而不用花太长时间去和印刷工人沟通交流这些要怎么排版，去怎么印，这个用户自己在印刷机就可以自行决定，让价值更着眼在用户要印什么～～～

08 团队介绍

本文作者踏雨，来自淘天集团–直播技术数据团队。我们是一支在 AI 赛道上高速成长的技术先锋队，致力于用大数据与人工智能重塑数据生产关系。在直播场景中，团队率先走通了 AI Native 的数据研发范式，实现研发全流程的高质高效与数据的高可信；同时沉淀出面向 AI 的数仓规范、可信数据语义层与知识底座，将数据研发能力抽象为可复用的智能体资产，并进一步把 AI 从取数工具升级为懂业务的分析伙伴，推动数据消费从"提需求取数"走向"与 AI 对话做分析"，服务直播全域产运团队，实现规模化的认知普惠与确定性的数据增长。

¤ 拓展阅读 ¤

3DXR技术 | 终端技术 | 音视频技术
服务端技术 | 技术质量 | 数据算法

大淘宝技术
大淘宝技术官方账号
966篇原创内容
公众号

阅读 2511

留言

写留言

还没有留言，来写首评