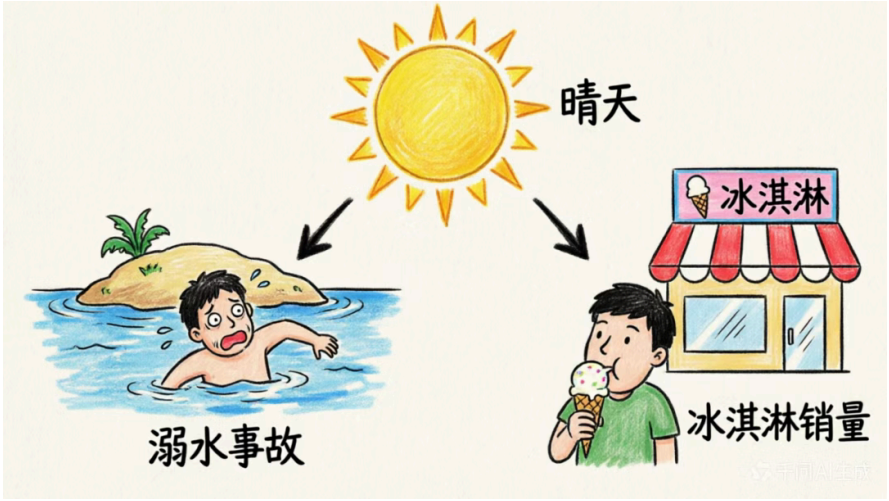
AI 评测还在看准确率？数据科学早就用因果推断做归因分析了

营销&交易技术 大淘宝技术 2026年8月10日 03:41 浙江 10人

本文旨在解决传统AI评测仅关注相关性而忽略因果性的局限，引入数据科学中的因果推断与博弈论方法进行归因分析，以精准量化LLM及Agent系统中各组件对结果的真实贡献度。文章首先厘清了相关性与因果性的区别，介绍了Rubin潜在结果模型与Pearl因果图两大理论框架，以及DoWhy、EconML、SHAP等主流工具库；随后针对AI评测场景，构建了基于完整Trace日志的高精度组件级归因、无中间数据时的扰动式黑盒归因、以及控制混杂变量的因果推断A/B测试三种实战策略，并通过具体案例演示了如何定位工具选择、参数构造、Prompt设计及Query复杂度等因素的影响；最后总结了当前面临的挑战、算法优化方向及常见陷阱，强调通过剥离混杂变量和量化纯净贡献度，实现从“发生了什么”到“为什么发生”及“如何优化”的深度洞察，从而精准定位系统瓶颈并指导迭代优化。

01 引言



从 "冰淇淋 与 溺水" 说起

在因果推断的经典案例中，有一个广为人知的现象：**夏天冰淇淋销量越高，溺水事故也越多**。

如果仅看数据相关性，很容易得出荒谬的结论——"吃冰淇淋会导致溺水"。

但常识告诉我们，这两者之间并无直接因果关系，真正的幕后推手是**气温**：天气越热，既促使人们购买冰淇淋，也吸引更多人去游泳，从而增加了溺水风险。

这个案例揭示了一个核心问题：**相关性不等于因果性**。在数据分析中，如果我们不能识别并控制混杂变量（如气温），就会被表面相关误导，做出错误的决策。

将这一逻辑类比到 AI 评测中：
假设我们观察到"使用新版 Prompt 的 Agent 任务成功率更高"。如果直接归因于 Prompt 改进，可能会忽略一个关键混杂因素——**Query复杂度**。也许新版 Prompt 恰好被分配给了更多简单**Query**，而旧版处理的是复杂任务。如果不控制这个混杂变量，我们就会高估 Prompt 优化的真实效果，甚至可能将一个实际上退化的版本误判为改进。
这正是**归因分析**要解决的核心问题：在众多交织的因素中，剥离出每个因素的纯净贡献度，回答"**到底是哪个环节真正驱动了结果变化？**"

> **核心目标**：用因果推断与博弈论方法，量化“因”对“果”的贡献度，精准定位复杂 AI 系统（LLM、Runtime Env、Tools等）的优化瓶颈。

研究背景

在数据科学领域，**因果分析（Causal Analysis）**是量化"因"对"果"贡献度的核心方法。其本质目标是识别不同输入变量（因素）对目标结果的影响权重，回答"**哪些因素在驱动结果？贡献占比分别是多少？**"这一关键问题。

随着人工智能从预测走向决策，传统的相关性分析已无法满足需求。因果推断（Causal Inference）提供了从"发生了什么"到"为什么会发生"再到"如果干预会怎样"的跃迁能力，成为现代归因分析的理论基石。

调研范围

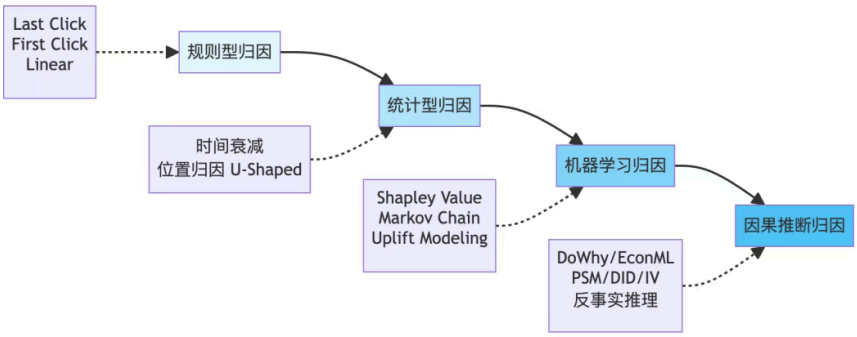
本报告聚焦三个维度：

- **工具框架**：主流因果推断库与归因分析工具的技术选型
- **经验方法论**：从经典统计到机器学习的归因方法体系
- **AI 评测应用**：如何将数据科学的归因范式应用于 LLM/Agent 评估（深度实操版）

02 归因分析的演进路径

从规则模型到算法驱动

归因分析经历了从简单规则到复杂算法的演进：

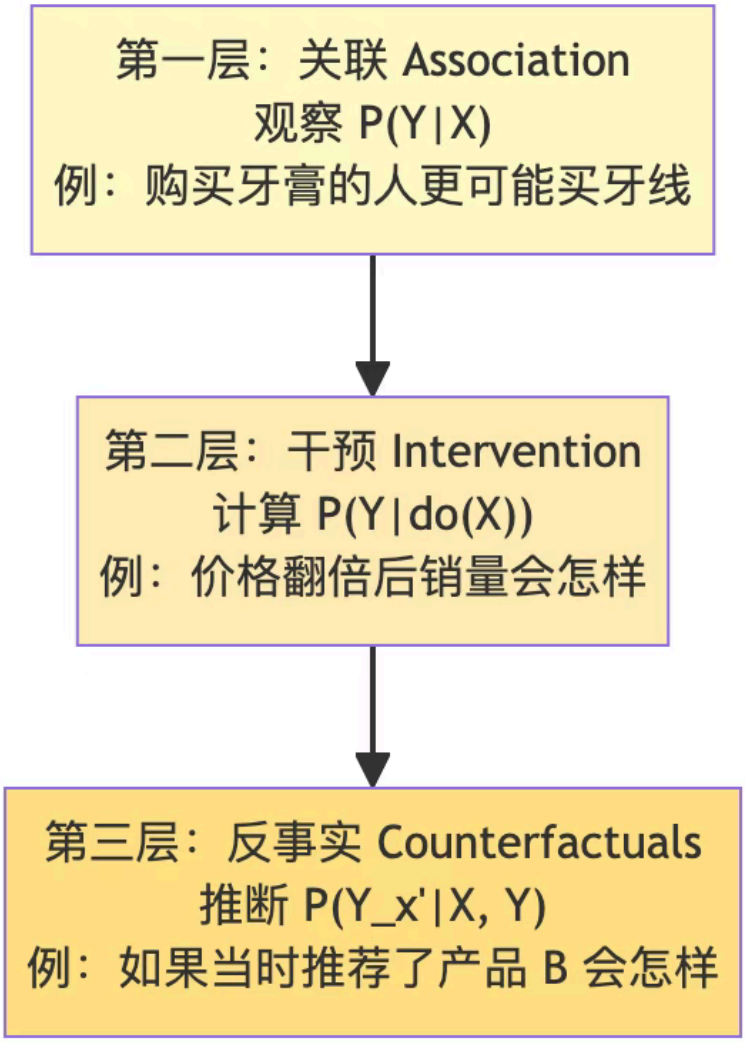


传统规则型归因基于先验业务逻辑设计，无需复杂计算，但灵活性差，易忽略因素间的交互作用。**现代算法驱动型归因**则基于机器学习、博弈论和因果推断构建，能够捕捉高维、非线性、强交互场景下的真实贡献度。

核心挑战：相关性与因果性的鸿沟

机器学习擅长回答"X 条件下 Y 会怎么样"（关联层），但无法回答"如果改变 X，Y 会如何变化"（干预层）或"如果当时做了不同的选择，结果会怎样"（反事实层）。这正是因果推断要解决的核心问题。

Pearl 提出的**因果阶梯理论**将推理能力分为三层：



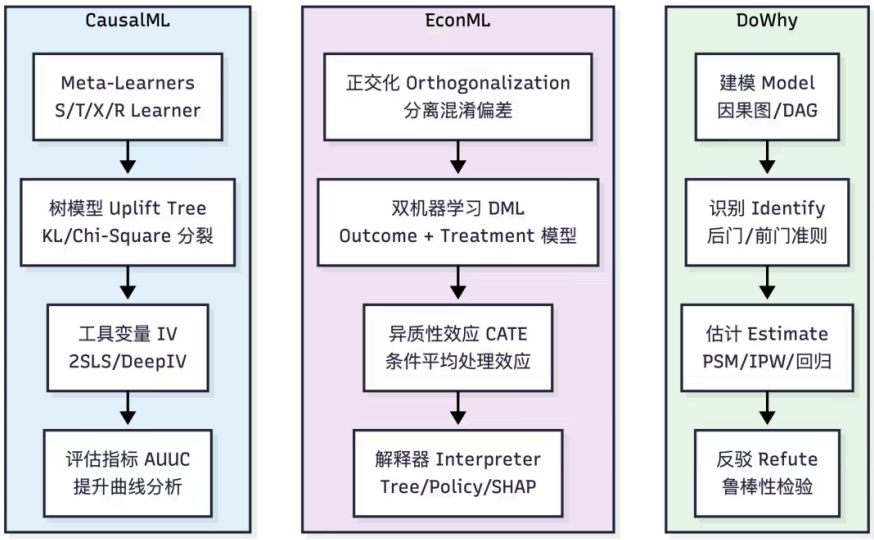
03 主流工具框架对比

Python 生态核心库

当前因果推断工具库生态呈现多元化发展，主要代表包括：

工具库	开发机构	核心特点	最佳适用场景
DoWhy	Microsoft	因果图模型，四步框架（建模→识别→估计→反驳）	因果发现、假设检验、端到端流水线
EconML	Microsoft	正交机器学习，深度学习集成	经济学研究、高维数据、异质性处理效应
CausalML	Uber	Meta 学习者框架，树模型为基础	营销效果评估、Uplift Modeling
PyCausalSim	社区开源	模拟驱动的因果发现，内置验证模块	A/B 测试分析、结构因果模型

三大框架技术对比



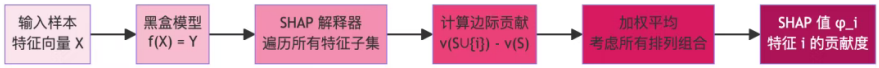
DoWhy 的优势在于提供原则性的因果图建模框架，确保所有假设的明确性，并通过自动化反驳检验增强结果的可信度。

EconML 则专注于利用正交机器学习解决高维数据中的因果效应估计问题，特别适合需要精细刻画异质性处理效应的场景。

CausalML 以 Meta-Learner 为核心，提供了简单易用的 API，在营销归因和 A/B 测试分析中表现优异。

可解释性工具：SHAP 值

SHAP（SHapley Additive exPlanations）基于博弈论中的 Shapley 值，为每个特征分配公平的贡献度。其满足四个公理：效率性、对称性、哑元性和可加性，被视为模型解释的"黄金标准"。



在归因分析中，SHAP 值可用于量化每个营销渠道、实验参数或模型特征对最终结果的贡献，支持树模型、神经网络等多种预测模型。

04 核心方法论体系

两大理论框架：Rubin vs Pearl

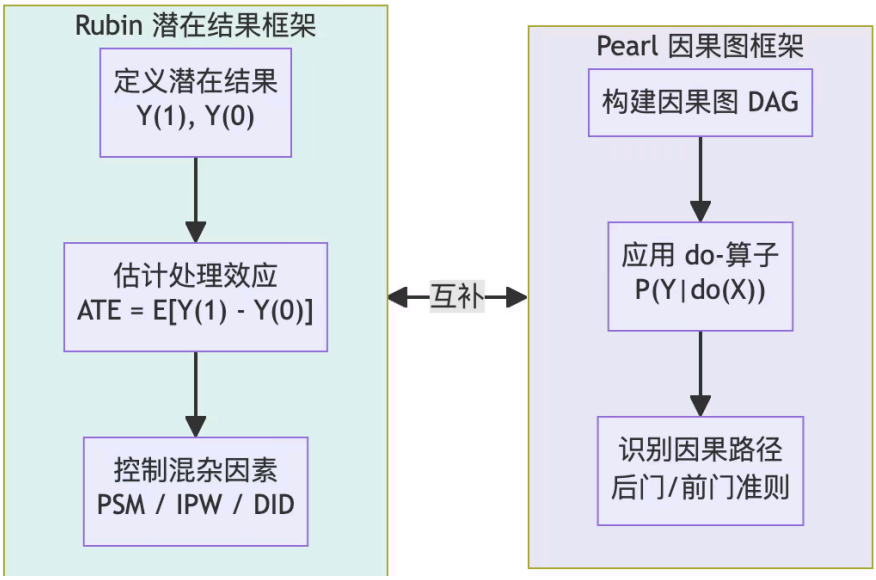
因果推断领域存在两大主流框架：

Rubin 潜在结果模型（RCM）：

- **核心思想**：为每个个体定义在所有可能干预下的潜在结果
- **关键概念**：处理效应（TE）、平均处理效应（ATE）、条件平均处理效应（CATE）
- **典型方法**：倾向得分匹配（PSM）、双重差分（DID）、工具变量（IV）
- **优势**：统计推断严谨，适合效应估计

Pearl 因果图模型：

- **核心思想**：使用有向无环图（DAG）表示变量间的因果关系
- **关键工具**：do-算子、后门准则、前门准则
- **典型方法**：结构因果模型（SCM）、因果发现算法（PC/GES/LiNGAM）
- **优势**：因果关系识别清晰，适合机制探索



两大框架的目标一致——计算存在混淆变量时干预对结果的影响，但侧重点不同：Rubin 框架侧重因果效应的估计和统计推断，Pearl 框架更偏向因果关系的识别和机制理解。在实际应用中，二者常结合使用（如 DoWhy 同时整合了两种框架）。

主流归因方法详解

（1）Shapley Value 归因

基于合作博弈论，计算每个参与者在所有可能联盟中的边际贡献均值。在营销归因中，将每个渠道视为"参与者"，转化视为"总收益"，通过 Shapley 值公平分配各渠道的贡献。

优点：理论保证完备（满足效率性、对称性等公理），能捕捉特征间的交互效应

缺点：计算复杂度随特征数指数增长，需采用近似算法（如 Kernel SHAP、Tree SHAP）

2）Markov Chain 归因

将用户转化路径建模为马尔可夫链，通过计算移除某渠道后转化概率的变化来衡量其贡献。突出接触点的先后顺序，适合分析多触点用户旅程。

优点：天然考虑时序依赖，能识别关键转化节点

缺点：计算成本高，需大量随机路径模拟

（3）Uplift Modeling

关注干预带来的增量效应，将用户分为四类：Persuadables（被说服者）、Sure Things（必然转化者）、Lost Causes（无望者）、Sleeping Dogs（反感者）。核心目标是精准定位 Persuadables 群体。

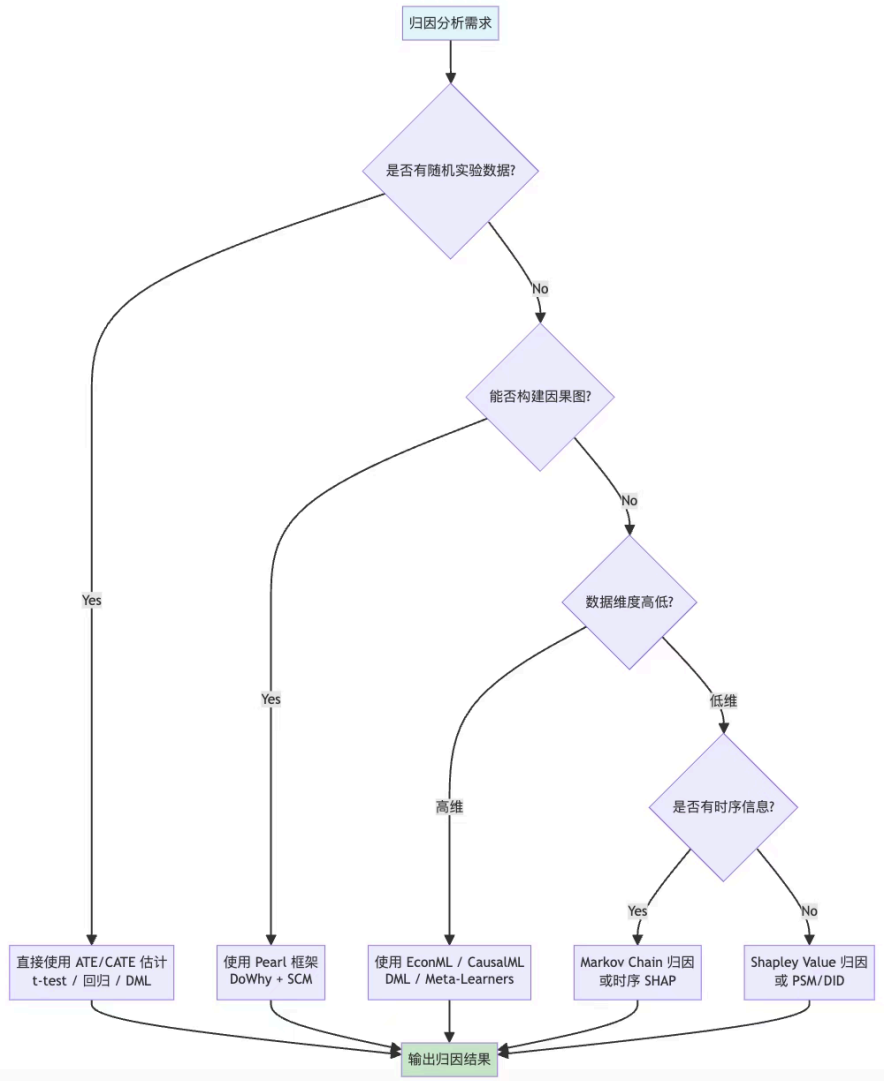
优点：直接优化干预 ROI，避免资源浪费

缺点：需要随机实验数据或强假设支撑

（4）因果推断方法

- **倾向得分匹配（PSM）**：通过匹配处理组和对照组的倾向得分，模拟随机实验
- **双重差分（DID）**：利用面板数据消除固定效应，要求平行趋势假设
- **工具变量（IV）**：引入外生变量解决内生性问题，要求相关性和排他性约束
- **双重机器学习（DML）**：结合机器学习灵活性与计量经济学严谨性，适合高维数据

方法选择决策框架



05 AI 评测中的归因分析实战

> **说明**：以下案例中的数据均为示例性数据，用于演示归因分析方法的应用流程。实际应用中需根据具体业务场景收集真实数据。

为什么 AI 评测需要归因分析?

传统 LLM 评测聚焦于任务完成率和输出质量，但面对复杂的 Agent 系统时，这种黑盒评估无法回答关键问题：

- **工具调用失败**：是模型选错了工具，还是参数传递错误?
- **规划失误**：是任务分解不合理，还是执行顺序错误?
- **推理缺陷**：是知识缺失，还是逻辑链条断裂?

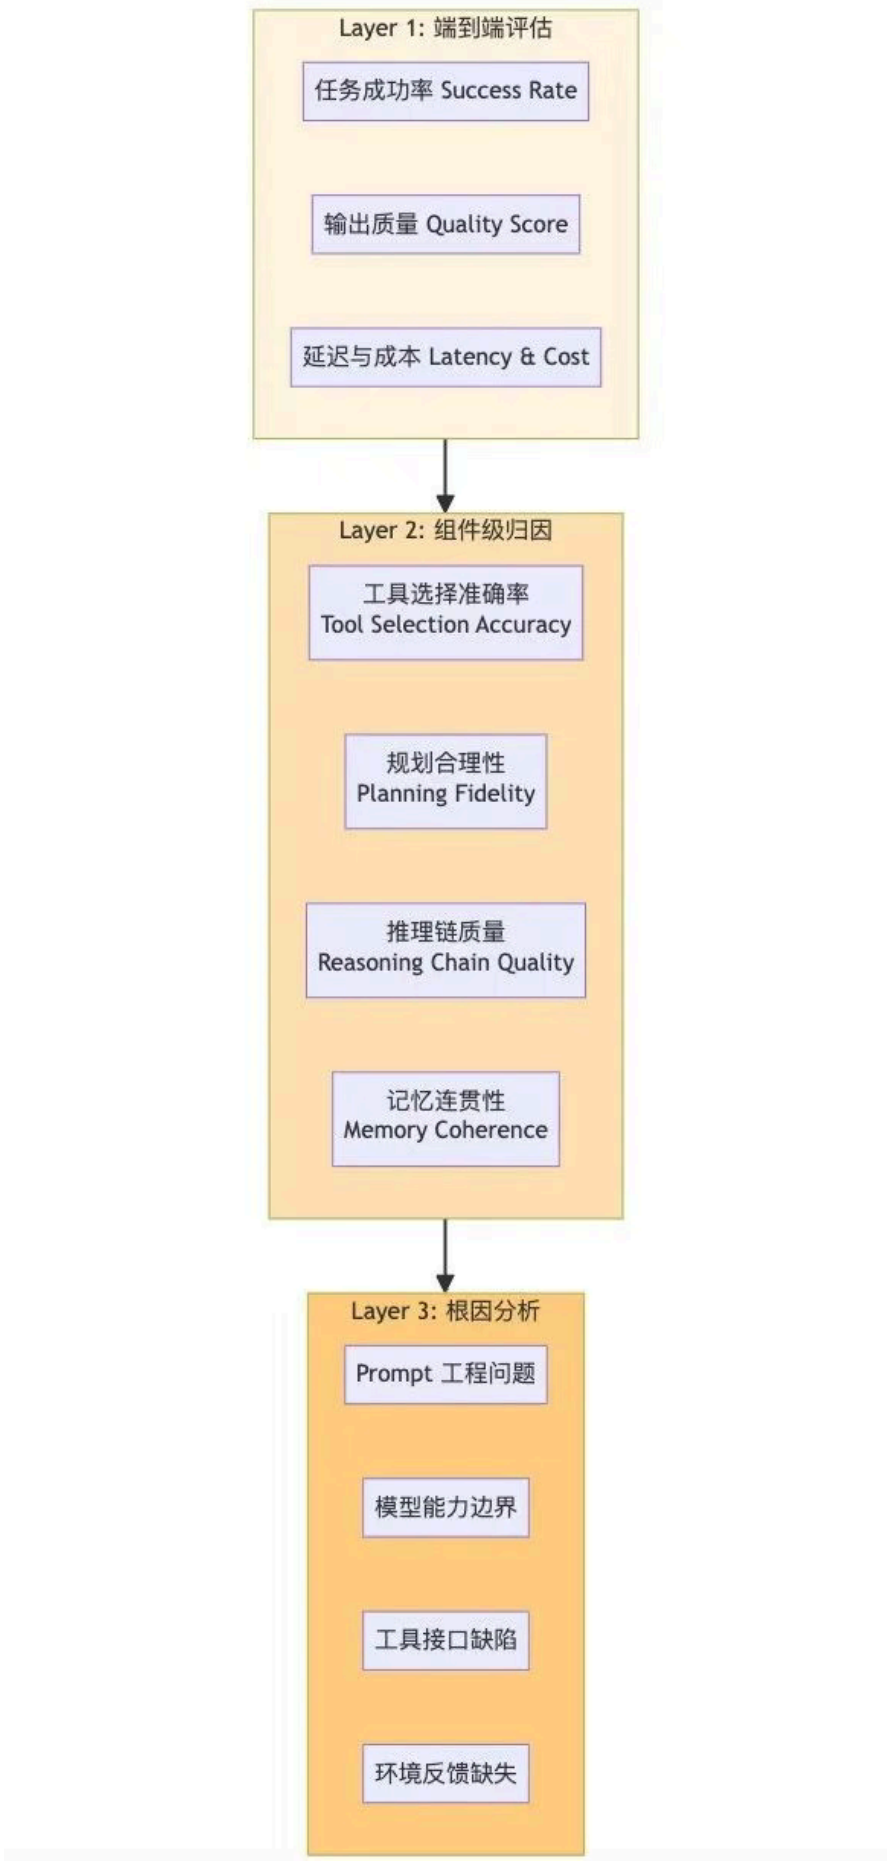
组件级归因评估将 Agent 拆解为独立模块，分别评估工具选择准确率、规划合理性、推理链质量等，从而精准定位瓶颈。

三种数据形态下的归因策略矩阵

根据数据可获得性，归因分析可分为三种路径：

数据形态	适用场景	核心方法	关键工具	精度等级
Full Trace	有完整执行轨迹日志（LangSmith/DeepEval）	组件级指标分解 + SHAP 值计算	DeepEval `@observe`、LangSmith SDK	⭐⭐⭐⭐⭐
I/O Only	只有输入输出对，无中间过程	扰动式归因（Prompt/Tool Perturbation）	Prompt-Perturbation-Simulator、ToolMaze	⭐⭐⭐
A/B Test	可设计对照实验	因果推断（反事实推理、双重稳健估计）	DoWhy、EconML、Neural Orthogonal Learning	⭐⭐⭐⭐

Agent 评测的分层归因框架



Trace 日志归因实操（高精度方案）

- 方法论框架

当拥有完整的 Agent 执行轨迹（Trace）时，归因分析的核心思路是：**将端到端的失败拆解为各组件的贡献度**。这种方法类似于软件工程的"分布式追踪"，但针对的是 AI Agent 的思维链和工具调用链。

核心指标体系设计：

组件维度	关键指标	业务含义	计算方法
工具选择	Tool Selection Accuracy	模型是否选对了工具	对比实际调用工具与预期工具的匹配度
参数构造	Parameter Construction Quality	传递给工具的参数是否正确	检查参数字段完整性、格式合规性、语义合理性
规划能力	Plan Adherence Score	多步任务是否按合理顺序执行	评估步骤间的逻辑连贯性和依赖关系
生成质量	Answer Relevancy	最终回答是否准确相关	使用 LLM-as-Judge 或人工标注评分
资源效率	Token Efficiency	成本与性能的平衡	Completion Tokens / Prompt Tokens 比率

- 操作步骤详解

Step 1：定义组件级评估标准

在打点之前，必须明确每个组件的"成功"定义。例如：

- **工具选择成功**：不仅要求调用的工具在可用列表中，还要求它是完成当前子任务的最优选择（可通过历史成功率或专家规则定义）
- **参数构造成功**：参数字段无缺失、数据类型正确、且语义上与用户意图匹配（如查询"北京天气"时 location 字段应为"北京"而非"Beijing"）

Step 2：实施分层打点策略

不要试图一次性监控所有指标，建议分阶段推进：

1. **第一阶段**：只监控工具调用序列和最终结果，建立基线
2. **第二阶段**：增加参数质量检查和规划合理性评估
3. **第三阶段**：引入 SHAP 值计算，量化各组件对最终得分的贡献权重

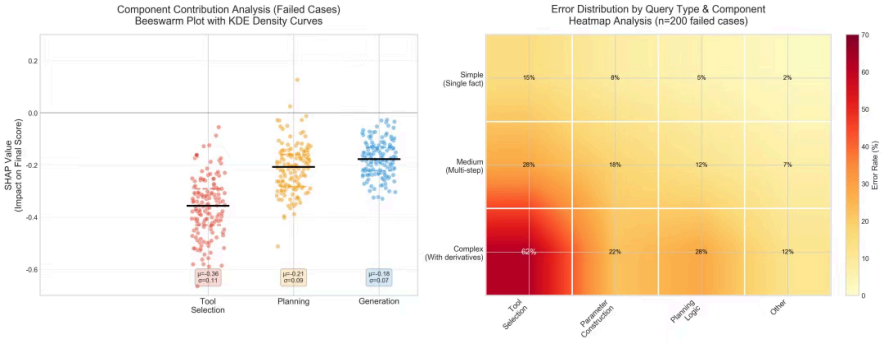
Step 3：构建根因诊断矩阵

将历史 Trace 汇总为特征表，每一行代表一次执行，列包括各组件指标和最终得分。通过相关性分析或回归模型，识别哪些组件与失败强相关。

- 典型案例解析

案例 1：工具描述模糊导致选错

场景：用户询问"帮我查一下杭州明天的气温并推荐穿衣建议"。Agent 错误调用了 `general_search` 工具而非 `weather_api`，导致返回了杂乱的网页摘要而非结构化天气数据。



Trace 分析：

- 工具选择准确率：0（选错工具）
- 参数构造质量：N/A（未进入参数构造阶段）
- 规划合理性：0.3（未能识别出需要两步：先查天气再给建议）
- 最终得分：0.2（回答不可用）

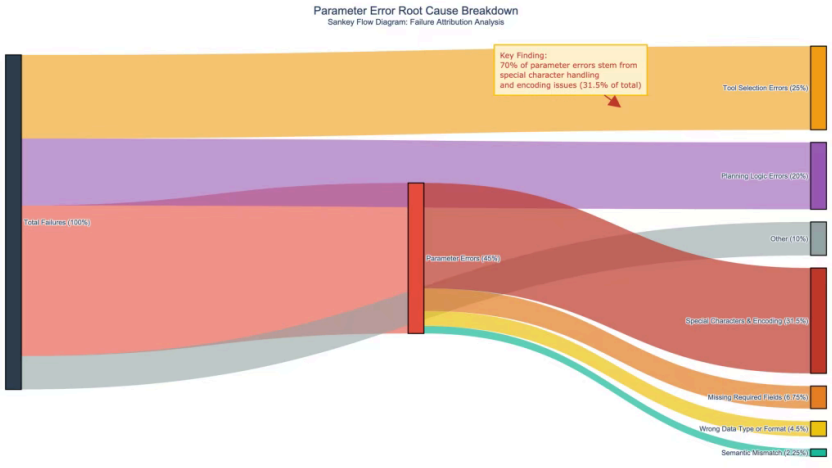
归因结论：

- 通过对比 50 次类似**Query**的 Trace，发现当用户同时提到"地点+时间+衍生需求"时，工具选择错误率高达 60%。
- 进一步分析工具描述发现，`weather_api` 的描述中未明确提及支持"穿衣建议"场景，导致模型犹豫后选择了更通用的搜索工具。

优化建议：在 `weather_api` 的工具描述中增加示例："适用于查询天气信息及基于天气的衍生建议（如穿衣、出行）"。

案例 2：参数格式错误导致调用失败

场景：用户要求"把这份销售报表转换成 PDF"。Agent 正确选择了 `doc_to_pdf_converter` 工具，但传递的文件路径参数包含了特殊字符（如空格和中文），导致工具抛出"File Not Found"错误。



case2_parameter_error_root_cause

Trace 分析：

- 工具选择准确率：1（选对工具）
- 参数构造质量：0（路径未做 URL 编码）
- 规划合理性：1（单步任务，无需复杂规划）
- 最终得分：0（完全失败）

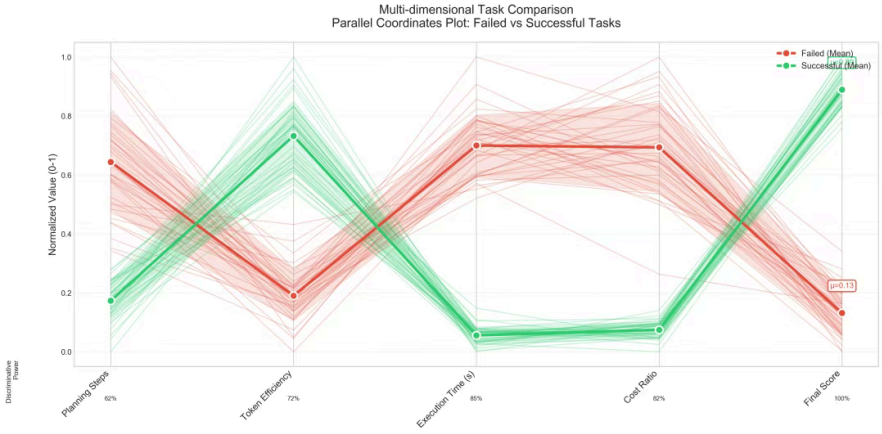
归因结论：

- 检查最近 100 次文件处理任务的 Trace，发现参数构造失败占所有失败的 45%，其中 70% 是因为路径包含特殊字符。
- 这说明模型在构造参数时缺乏对文件系统规范的认知。

优化建议：在 System Prompt 中增加参数构造规范："当传递文件路径时，必须对空格进行 %20 编码，对中文字符进行 UTF-8 编码"。或在工具层增加自动转义逻辑。

案例 3：规划步数过多导致超时

场景：用户要求"分析过去三个月的销售数据并给出下季度预测"。Agent 生成了一个包含 8 个步骤的详细计划（数据提取→清洗→聚合→可视化→趋势分析→季节性分解→模型训练→预测），但由于每步都调用 LLM，总耗时超过 120 秒触发超时。



case3_task_comparison_multidimensional

Trace 分析：

- 工具选择准确率：1（所有工具选择正确）
- 参数构造质量：1（参数无误）
- 规划合理性：0.4（步骤过于细化，可合并）
- 资源效率：0.2（Token 消耗过高）
- 最终得分：0（超时未完成）

归因结论：

- 对比成功完成的同类任务 Trace，发现平均规划步数为 3-4 步。
- 当前 Agent 的规划模块倾向于过度分解任务，导致执行链过长。通过分析规划生成的 Prompt，发现缺少"步骤合并原则"的指导。

优化建议：在规划阶段的 Prompt 中增加约束："优先合并可并行执行的步骤，总步数控制在 5 步以内。对于数据类任务，优先考虑使用支持多操作的工具（如 pandas_agent）而非分步调用。"

扰动式归因实操（无 Trace 场景）

- 方法论框架

当缺乏中间过程数据时，归因分析退化为**黑盒实验**：通过微调输入要素（Prompt、工具配置），观察输出变化的幅度，反向推断各要素的贡献度。这种方法类似于物理学中的"控制变量法"或化学中的"滴定实验"。

核心思想：如果移除某个要素后输出质量大幅下降，说明该要素是关键贡献者；如果移除后影响很小，说明该要素冗余或噪声。

- 扰动策略设计原则

扰动类型	操作方式	适用场景	注意事项
指令扰动	替换提示词中的指令表述（保持语义不变）	测试指令清晰度对输出的影响	避免改变任务本质，如将"总结"改为"翻译"
示例扰动	随机删除、替换或重排 Few-shot 示例	评估示例的质量和数量敏感性	保留至少 1 个示例以防完全失效
上下文扰动	移除部分检索到的文档片段或调整排序	测试 RAG 检索质量的影响	记录被移除文档的相关性分数
格式扰动	改变输出格式要求（如从 JSON 改为 Markdown）	测试格式约束的必要性	确保解析器能适应新格式
温度扰动	调整 Temperature 参数（0.0 → 0.7 → 1.0）	评估随机性对稳定性的影响	每次运行固定 seed 以便复现

- 操作步骤详解

Step 1：建立基线输出

使用原始配置运行 N 次（N ≥ 10），记录平均得分和标准差。这将成为后续扰动的参照基准。

Step 2：设计对照实验组

为每种扰动类型设计 3–5 个变体。例如：

- 指令扰动：变体 A（简化指令）、变体 B（详细指令）、变体 C（强调约束）
- 示例扰动：变体 D（删除 50% 示例）、变体 E（替换为低质量示例）、变体 F（重排示例顺序）

Step 3：批量运行与数据收集

对每个变体运行 M 次（M ≥ 20），记录：

- 输出与基线的文本相似度（使用 Embedding Cosine Similarity）
- 任务完成度评分（人工或 LLM-as-Judge）
- 响应时间和 Token 消耗

Step 4：计算归因分数

贡献度 =（基线平均分 − 扰动后平均分）/ 基线平均分 × 100%

正值表示该要素有正向贡献，负值表示移除后反而提升（说明原要素可能是噪声）。

- 典型案例解析

案例 1：Prompt 中缺少输出格式约束导致解析失败

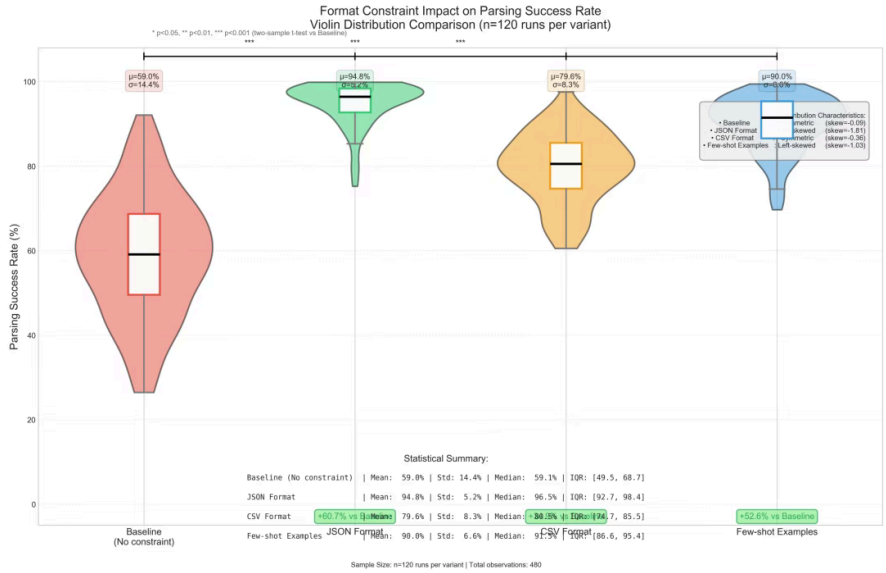
场景：一个客服 Agent 需要从用户消息中提取订单号和问题类型。原始 Prompt 只说"请提取关键信息"，未指定输出格式。

扰动实验：

- 基线：无格式约束，100 次运行中只有 60% 的输出能被解析器正确提取
- 变体 A：增加"请以 JSON 格式输出，包含 order_id 和 issue_type 字段"
- 变体 B：增加"请用逗号分隔订单号和问题类型"
- 变体 C：提供 Few-shot 示例展示期望的输出格式

结果：

- 变体 A 的解析成功率提升至 95%
- 变体 B 提升至 80%
- 变体 C 提升至 92%



case4_format_constraint_parsing_success

归因结论：格式约束的贡献度为（95% − 60%）/ 60% = 58.3%，是所有 Prompt 要素中影响最大的。这说明对于结构化提取任务，明确的格式指令比示例更重要。

优化建议：在所有涉及信息提取的 Prompt 模板中强制加入格式约束，优先使用 JSON Schema 而非自然语言描述。

案例 2：RAG 检索到的文档噪声太大干扰生成

场景：一个法律问答 Agent 使用 RAG 检索相关法条。用户询问"劳动合同解除的经济补偿如何计算"，系统检索到 10 篇文档，其中 3 篇高度相关，7 篇是噪声（如社保政策、税务规定）。

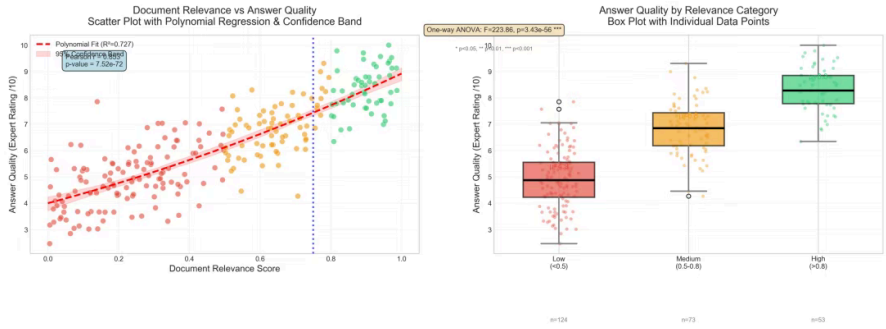
扰动实验：

- 基线：使用全部 10 篇文档作为上下文

- 变体 A：只保留相关性分数 > 0.8 的文档（剩 3 篇）
- 变体 B：随机删除 50% 的文档（剩 5 篇）
- 变体 C：将所有文档按相关性降序排列后只取前 5 篇

结果（由律师专家评分，满分 10 分）：

- 基线平均分：6.2（回答冗长且包含无关信息）
- 变体 A 平均分：8.5（精准引用相关法条）
- 变体 B 平均分：7.1（有时删掉了关键文档）
- 变体 C 平均分：8.0（平衡了准确性和完整性）



case5_document_relevance_quality_correlation

归因结论：高质量文档筛选的贡献度为（8.5 − 6.2）/ 6.2 = 37.1%。这说明 RAG 系统的检索质量直接影响生成效果，简单的 Top-K 策略不如基于相关性阈值的动态筛选。

优化建议：在 RAG 检索后增加一步"相关性过滤"，只保留分数 > 0.75 的文档。同时调整检索模型的召回策略，减少低相关性文档的混入。

案例 3：Few-shot 示例的顺序影响推理链质量

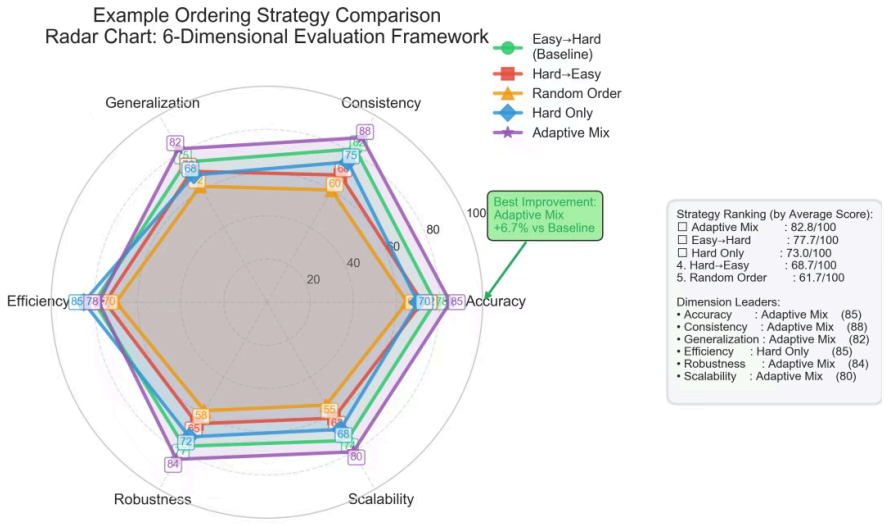
场景：一个数学解题 Agent 使用 Chain-of-Thought（CoT）Prompt，提供了 3 个示例展示解题思路。

扰动实验：

- 基线：示例按难度递增排列（简单→中等→困难）
- 变体 A：示例按难度递减排列（困难→中等→简单）
- 变体 B：示例随机排列
- 变体 C：只保留最困难的 1 个示例

结果（在 50 道测试题上的准确率）：

- 基线准确率：78%
- 变体 A 准确率：72%
- 变体 B 准确率：65%
- 变体 C 准确率：70%



case6_example_ordering_strategy_evaluation

归因结论：示例顺序的贡献度为（78% − 65%）/ 78% = 16.7%。虽然影响不如格式约束那么大，但说明"由浅入深"的示例排列能帮助模型更好地学习推理模式。随机排列会显著降低效果，可能是因为模型难以捕捉规律。

优化建议：在设计 CoT Prompt 时，严格按照难度递增或逻辑递进的顺序排列示例。避免随机化或逆向排列。

因果推断 A/B 测试实操

- 方法论框架

传统 A/B 测试只能看到相关性（"新版 Prompt 的得分更高"），但无法排除混杂因素（"可能是新版测试的用户本身经验更丰富"或"新版测试时服务器负载更低"）。因果推断通过**控制混杂变量**，估计干预的净效应。

核心概念：

- **处理变量（Treatment）**：你主动改变的因子（如 Prompt 版本、模型选择、Temperature）
- **结果变量（Outcome）**：你关心的指标（如任务成功率、用户满意度、响应时间）
- **混杂变量（Confounders）**：同时影响处理和结果的第三方变量（如**Query**复杂度、用户领域知识、时间段）
- **平均处理效应（ATE）**：剥离混杂因素后，处理变量对结果的纯净影响

- 操作步骤详解

Step 1：绘制因果图（DAG）

在实验设计前，先用有向无环图梳理变量关系。例如：

```
Query复杂度 → Prompt 版本（因为复杂Query可能分配给新版）
```

```
Query复杂度 → 任务得分（复杂Query天然更难）
用户经验 → 任务得分（经验丰富的用户提问更清晰）
时间段 → 服务器负载 → 响应时间
```

通过 DAG 识别出需要控制的混杂变量（这里是**Query**复杂度和用户经验）。

Step 2：设计随机对照实验

为确保两组分布一致，采用以下策略：

- **完全随机化**：将同一批**Query**随机分配给 V1 和 V2 Prompt，确保**Query**复杂度分布相同
- **分层随机化**：按**Query**复杂度分为高/中/低三层，每层内随机分配，确保各层样本均衡
- **配对设计**：对每个**Query**，分别用 V1 和 V2 运行，直接对比得分差异（消除**Query**本身的影响）

Step 3：选择估计方法

根据数据特点选择合适的方法：

- **简单 t-test**：仅当确认无混杂变量时使用（如完全随机化且样本量足够大）
- **倾向得分匹配（PSM）**：当无法完全随机化时，通过匹配相似样本来模拟随机实验
- **双重稳健估计（Doubly Robust）**：结合回归模型和 PSM，即使其中一个模型有误仍能保持一致性
- **神经正交学习（NOL）**：当混杂变量维度很高（>10 个）时使用，通过深度学习自动提取特征

Step 4：敏感性分析

检验结论对未观测混杂变量的鲁棒性。如果加入一个假设的未观测混杂变量后，处理效应仍然显著，说明结论可靠。

- 典型案例解析

案例 1：发现新版 Prompt 在简单Query上表现更好但在复杂Query上更差

场景：团队开发了新版 Prompt（V2），声称能提升 Agent 表现。初步 A/B 测试显示 V2 的平均得分比 V1 高 5%，但上线后用户反馈两极分化。

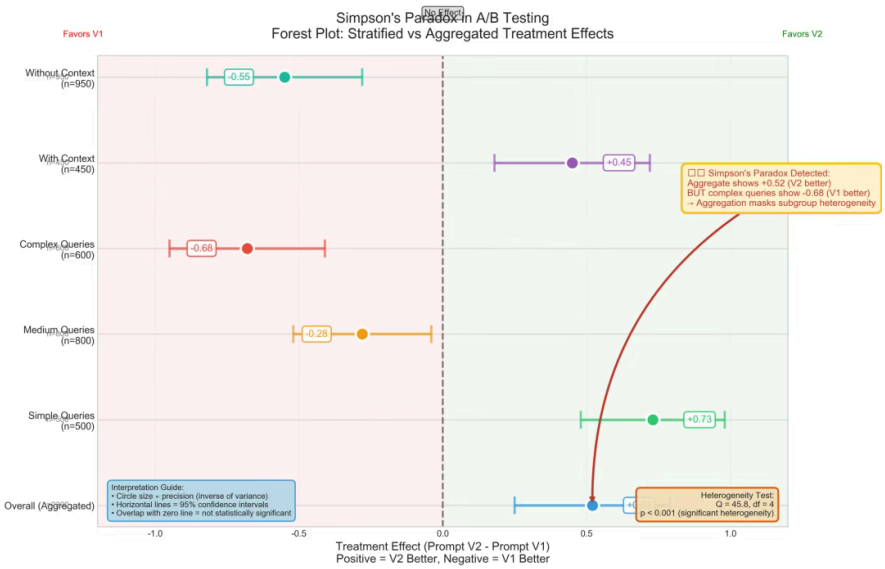
因果分析问题：初步测试未控制**Query**复杂度，可能导致 Simpson's Paradox（辛普森悖论）。

重新设计实验：

1. 将**Query**按复杂度分为三类：简单（单步事实**Query**）、中等（多步推理）、困难（需要工具调用和规划）
2. 在每类内部分别计算 V1 和 V2 的得分差异

结果：

- 简单**Query**：V2 得分 8.5 vs V1 得分 7.8（+8.9%）
- 中等**Query**：V2 得分 7.2 vs V1 得分 7.5（−4.0%）
- 困难**Query**：V2 得分 5.8 vs V1 得分 6.5（−10.8%）



case7_simpson_paradox_stratified_effects

归因结论:

- V2 Prompt 通过简化指令提升了简单**Query**的效果，但牺牲了对复杂任务的处理能力（可能是因为删减了规划指导）。
- 整体平均提升 5% 是因为测试集中简单**Query**占比 70%，掩盖了在复杂查询上的退化。

优化建议：采用动态 Prompt 策略：对简单**Query**使用 V2，对复杂**Query**保留 V1 或开发专门的 V2-complex 版本。

案例 2：通过 PSM 匹配后发现 Temperature 调整的真实效应

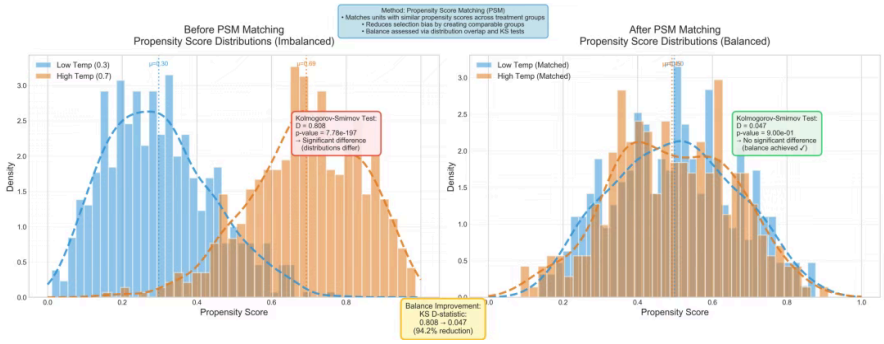
场景：团队想验证"降低 Temperature 从 0.7 到 0.3 是否能提升回答一致性"。但历史数据中，低 Temperature 主要用在客服场景（**Query**较简单），高 Temperature 用在创意写作场景（**Query**较复杂），直接比较有偏差。

因果分析设计:

1. 构建因果图：Temperature → 回答一致性；**Query**类型 → Temperature（客服场景倾向用低 Temp）；**Query**类型 → 回答一致性（创意任务天然变化大）
2. 使用倾向得分匹配：为每个低 Temp 样本找到一个**Query**类型相似的高 Temp 样本

匹配后结果:

- 未匹配的原始差异：低 Temp 一致性得分 0.85 vs 高 Temp 0.72（看似提升 18%）
- PSM 匹配后差异：低 Temp 0.82 vs 高 Temp 0.78（真实提升仅 5%）



case8_psm_covariate_balance_check

归因结论：

- 原始观察到的 18% 提升中，13% 是由于查询类型不同导致的混杂效应，Temperature 本身的净效应只有 5%。
- 这说明降低 Temperature 确实能提升一致性，但效果远小于表面观察。

优化建议：不要盲目降低 Temperature，需权衡一致性与创造性。对于客服等标准化场景可使用 0.3，对于创意任务保持 0.7。

案例 3：使用 NOL 评估多参数联合优化的效果

场景：团队同时调整了 5 个参数：Prompt 版本、Temperature、Top-p、最大 Token 数、重试次数。传统回归无法处理如此高维的交互效应。

因果分析设计：

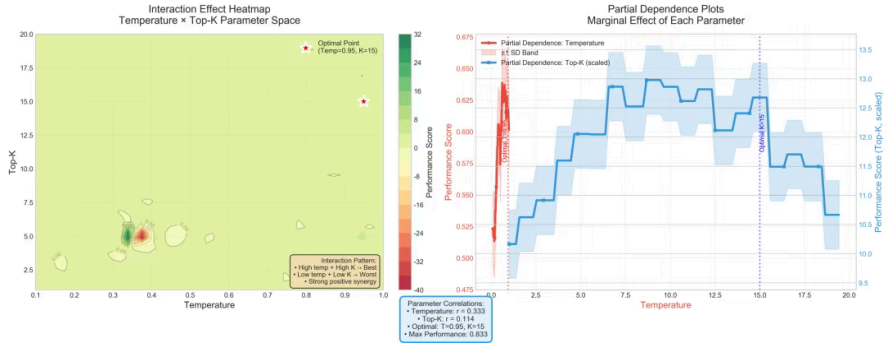
1. 收集 1000 次实验数据，记录 5 个参数值和最终得分
2. 使用 EconML 的 LinearDML 模型，将 5 个参数作为 Treatment，**Query**特征作为 Confounders

结果：

- Prompt 版本的 ATE：+0.12（显著提升）
- Temperature 的 ATE：−0.03（轻微负向，但不显著）
- Top-p 的 ATE：+0.01（几乎无影响）
- 最大 Token 数的 ATE：+0.08（中等提升，但边际递减）
- 重试次数的 ATE：+0.15（显著提升，但成本增加 3 倍）

交互效应发现：

- Prompt V2 + 低 Temperature 的组合效应为 +0.18，高于单独效应之和（0.12 − 0.03 = 0.09），说明二者有协同作用
- 重试次数 > 2 后，额外收益急剧下降（从 +0.15 降至 +0.02）



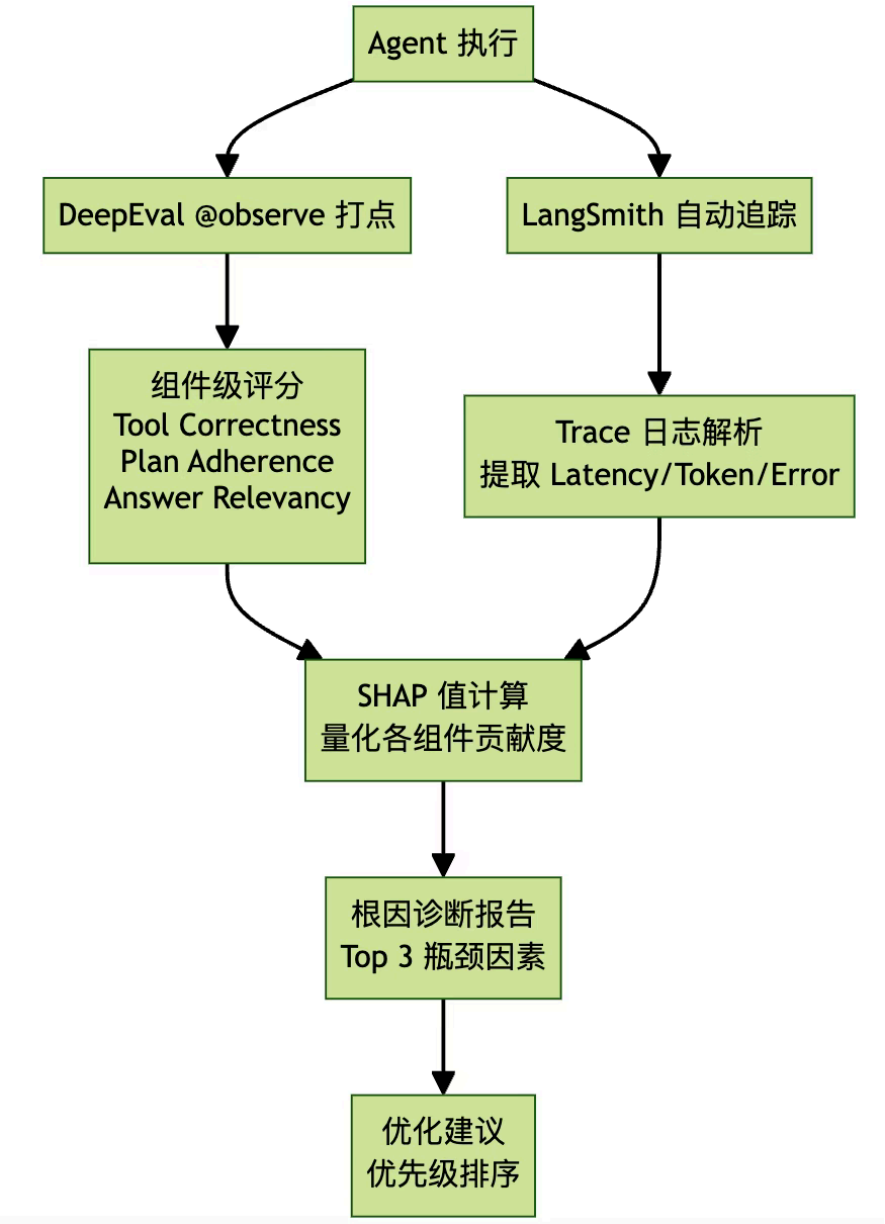
case9_parameter_interaction_optimization

归因结论：最优策略是采用 Prompt V2 + Temperature 0.3 + 重试 2 次，预计综合提升 0.18 + 0.08 + 0.15 = 0.41 分，同时控制成本。

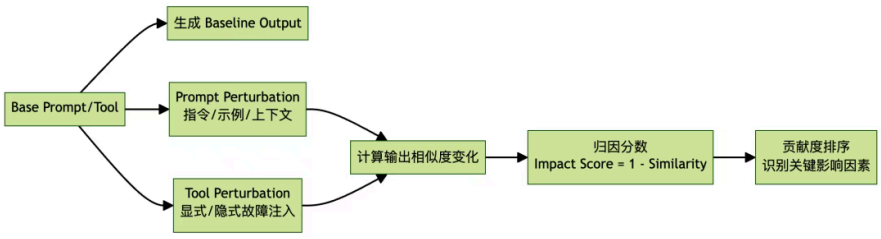
优化建议：放弃单独优化单个参数的思路，转向参数组合的联合优化。建立参数配置的 Pareto 前沿，平衡效果与成本。

综合归因工作流可视化

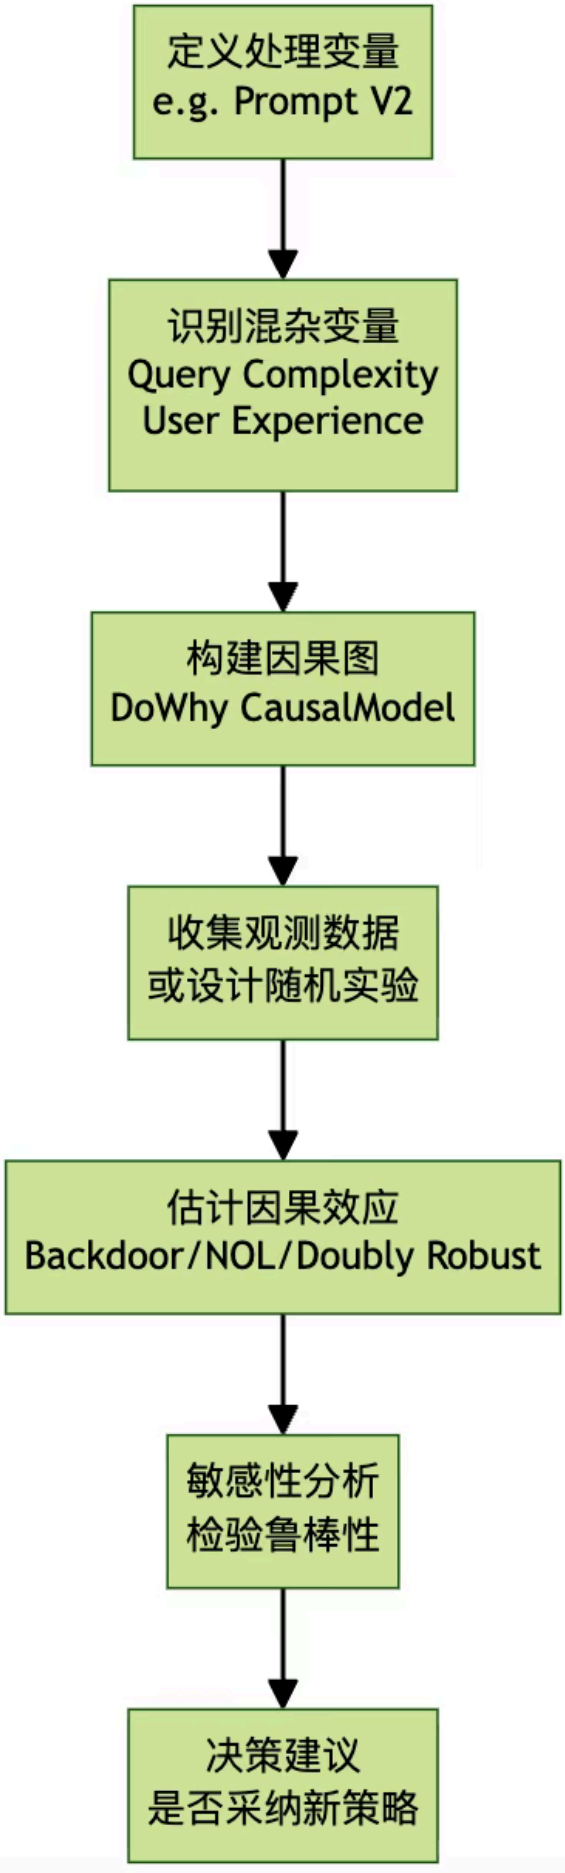
- Trace 归因 Pipeline



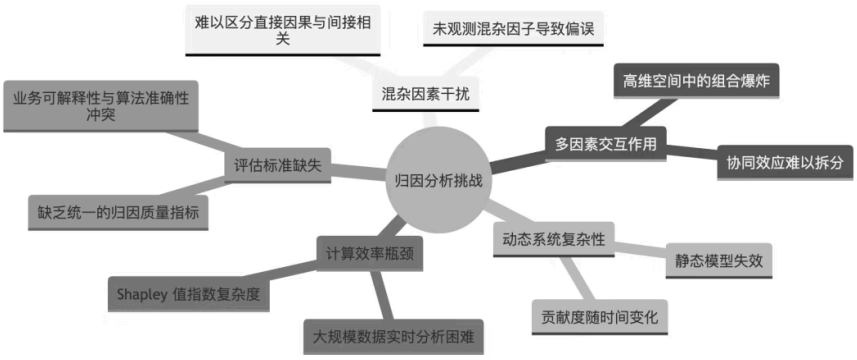
- 扰动式归因工作流



- 因果 A/B 测试设计


定义处理变量
e.g. Prompt V2
识别混杂变量
Query Complexity
User Experience
构建因果图
DoWhy CausalModel
收集观测数据
或设计随机实验
估计因果效应
Backdoor/NOL/Doubly Robust
敏感性分析
检验鲁棒性
决策建议
是否采纳新策略

当前面临的核心挑战



算法优化方向

1. **因果推断与机器学习融合**：先通过因果图识别变量间的因果关系，再用 SHAP 等算法量化贡献度，解决"相关≠因果"的问题
2. **交互作用显式建模**：在归因模型中引入特征交互项，或使用图神经网络（GNN）捕捉因素间的交互结构
3. **高维数据降维归因**：先通过 PCA、AutoEncoder 等方法降维，再对主成分进行归因
4. **动态归因模型轻量化**：采用增量学习或在线学习策略，实时更新因素的贡献度权重

AI 评测中的前沿探索

- **现实反馈机制**：用实用替代方案取代 ground-truth 反馈，集成验证、置信度校准或人机协作设计
- **跨范式工作流集成**：在非验证的工具使用工作流中纳入可选反馈源，在单一范式内组合不同反馈机制
- **世界建模集成**：与规划工作流集成，实现更复杂的基于模拟的推理，减少对昂贵环境交互的依赖

07 常见陷阱与避坑指南

陷阱	症状	解决方案
过度依赖单一指标	只看最终得分，忽略组件分解	必须同时监控 Tool Correctness + Plan Adherence + Generation Quality
Trace 数据噪声大	同一 Prompt 多次运行结果差异大	增加运行次数（≥30），使用均值+标准差而非单次结果
扰动幅度过大	Perturbation 改变了任务本质	控制扰动幅度（如只替换同义词，不改变语义）
忽略混杂变量	A/B 测试中两组用户分布不均	使用因果推断方法（PSM、NOL）校正混杂效应
归因结果不可解释	SHAP 值计算复杂，业务方看不懂	提供自然语言解释："工具选择错误导致 40% 的失败案例"

08 术语表

术语	英文	解释
平均处理效应	ATE (Average Treatment Effect)	干预对整体人群的平均因果效应
条件平均处理效应	CATE (Conditional ATE)	在给定协变量条件下的异质性处理效应
倾向得分	Propensity Score	个体接受干预的概率，用于匹配或加权
后门准则	Back-door Criterion	Pearl 框架中识别因果效应的图论条件
do-算子	do-operator	表示主动干预而非被动观察的数学符号
双重机器学习	DML (Double Machine Learning)	通过正交化消除正则化偏误的因果估计方法
Meta-Learner	Meta-Learner	通过组合多个机器学习模型估计因果效应的框架（S/T/X/R Learner）
Shapley 值	Shapley Value	博弈论中公平分配合作收益的方法，用于特征归因
马尔可夫链归因	Markov Chain Attribution	基于状态转移概率计算渠道贡献度的方法
Uplift Modeling	Uplift Modeling	预测干预带来的增量效应，用于精准营销

09 参考文献

1. Causal Inference in Data Science: A Framework for Attribution Systems
2. PyCausalSim: 基于模拟的因果发现的 Python 框架
3. 因果推断框架 DoWhy 入门
4. 如何用 EconML 与 DoWhy 构建端到端因果推断流水线
5. Shapley value: from cooperative game to explainable artificial intelligence
6. Advanced Machine Learning Models for Attribution Modeling
7. Evaluation and Benchmarking of LLM Agents: A Survey
8. LLM Agent Evaluation Metrics in 2026
9. 实测 28 款大模型：CaLM 评测体系揭示 AI 因果推理能力的真实水平
10. CounterBench: Evaluating and Improving Counterfactual Reasoning
11. LLM attribution analysis across different fine-tuning strategies
12. 归因分析（Attribution Analysis）详解
13. Prompt Perturbation for Reliable LLM Evaluation
14. ToolMaze: Dynamic Path Discovery in TIR Agents

10 团队介绍

本文作者尔湾，来自淘天集团–营销&交易技术团队。

我们致力通过评测工程与 Agent 全栈优化技术，打造领先的 AI Native 应用质量提升能力，服务于淘天 AI 应用规模化落地与持续迭代，面向各业务线构建从“度量问题”到“解决问题”的一体化优化方案，负责「秒杀红包」/「营销大促」/「购物助手」/「本体建设」等淘天核心 AI 应用场景的评测与 Agent 优化，帮助业务方看清 Agent“好不好”、找到“怎么变好”，让 AI Native 应用可衡量地持续变好。

拓展阅读

3DXR技术 | 终端技术 | 音视频技术

服务端技术 | 技术质量 | 数据算法



大淘宝技术

大淘宝技术官方账号

967篇原创内容

公众号

内容含AI生成图片

阅读 3608

留言

写留言

还没有留言，来写首评