MNN-Sana-Edit-V2：端侧运行的图像漫画风编辑大模型

原创 Meta技术团队 大淘宝技术 2026年4月22日 02:02 浙江 1人

MNN-Sana-Edit-V2 是由淘宝 Meta 团队联合杭州电子科技大学研发的端侧图像漫画风编辑大模型，基于 Sana 和 MetaQuery 学术成果创新构建，采用 Qwen3-0.6B 作为冻结的预训练 LLM，通过 Learnable Query 和 Connector 模块桥接文本理解与图像生成，结合 Linear DiT、Deep Compression Autoencoder 等高效架构设计，并依托 MNN 框架实现 4/8bit 量化部署，使全部模型可在手机端本地运行；该模型在 iPhone 17 Pro 上仅需约 15 秒即可完成 512×512 图像的漫画风格转换，较云端方案提速 2.5 倍，同时保障用户隐私与推理效率，目前已集成至 MNN Chat 应用（支持 iOS/Android），相关代码与模型权重已在 GitHub、HuggingFace 及 ModelScope 全面开源。

01 前言

随着生成式人工智能技术的持续演进，端侧部署能力逐渐成为模型落地的重要考量。在图像编辑领域，兼顾隐私安全与推理效率，一直是技术探索的重点方向。

MNN-Sana-Edit-V2 是淘宝业务技术 Meta 团队联合杭州电子科技大学研发的端侧图像编辑大模型，该模型在参考 Sana 和 Metaquery 等学术界论文的基础上，基于文生图框架，创新性地增加了图像编辑功能，基于淘宝 MNN LLM 和 MNN Diffusion 的端侧量化部署能力，做到了所有模型本地运行，既能保护隐私，避免用户信息泄漏，又能做到快速运行，减少等待时间。通过测试，在 iPhone 17 Pro 上，MNN-Sana-Edit-V2 模型能够在 15 秒内完成任意图像的漫画风格转换，相比 OpenAI 的图像编辑能力，提速 2.5 倍。目前该功能已经在 MNN Chat 应用中正式上线，支持 Android 平台和 iOS 平台，同时所有模型和推理代码已经在 MNN 仓库进行开源，欢迎大家尝鲜使用。



MNN-Sana-Edit-V2 漫画风编辑效果

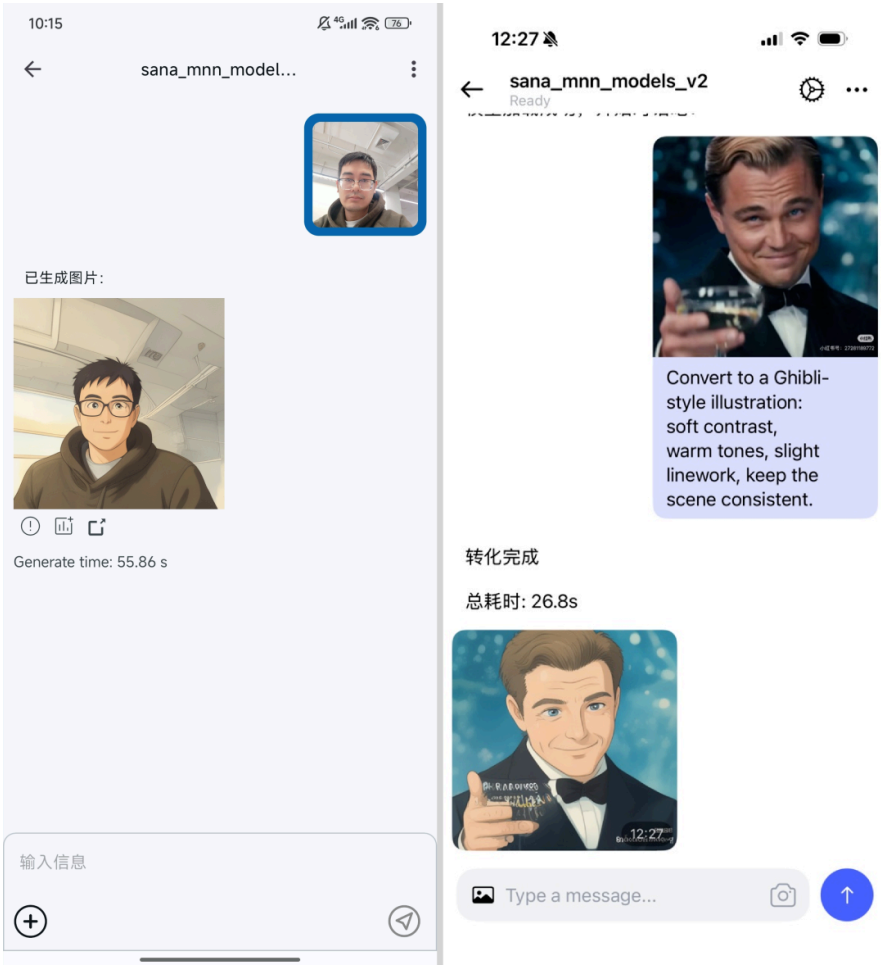
MNN Chat App下载地址：

iOS: https://apps.apple.com/us/app/mnn-chat/id6748348797

Android (Google Play)：

https://play.google.com/store/apps/details?id=com.alibaba.mnnllm.android.release

MNN Chat Android 和 iOS App 使用 MNN-Sana-Edit-V2 效果截图：



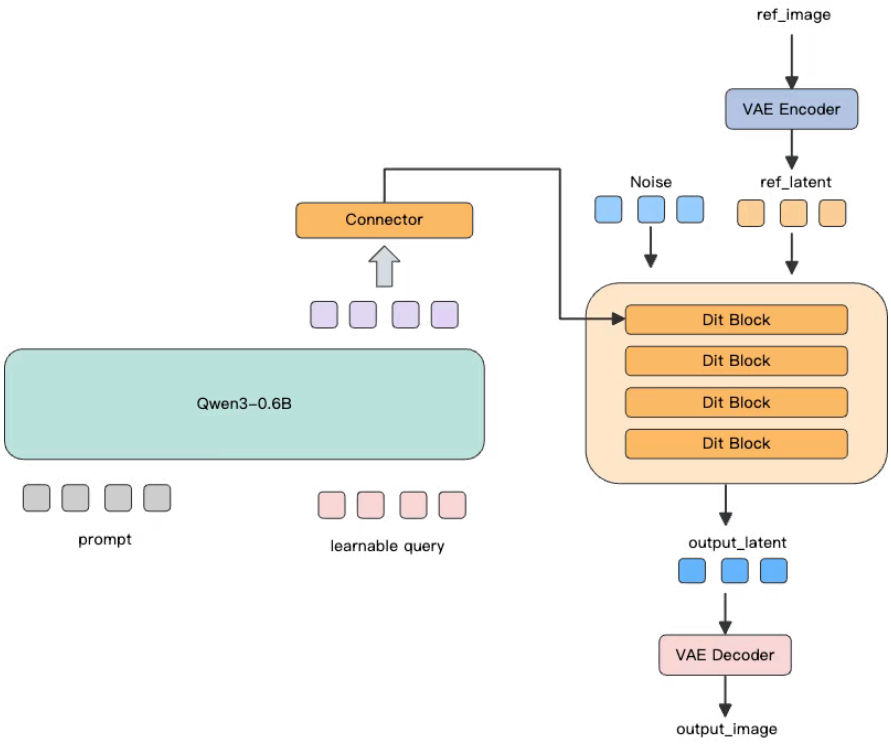
下面我们将从网络框架设计，核心技术详解，训练策略，MNN 端侧部署优化几个方面对这个工作进行介绍。

02 网络框架设计

系统架构设计

MNN-Sana-Edit-V2 整体采用 Sana 图像生成模型的网络架构，同时为了更好地利用预训练 LLM 对 Prompt 的理解能力，我们结合 MetaQuery 论文中提出的 Learnable Query 思想，利

用可学习的一组网络参数来桥接预训练 LLM 与图像生成与编辑过程。



具体来说，MNN-Sana-Edit-V2网络包括下面组件：

1. 预训练 LLM 采用 Qwen3-0.6B，使用保持 freeze 状态，参数不变，用于更好地理解 Prompt
2. Learnable Query: 256 维的可学习参数，用于桥接文本理解和图像生成
3. Connector 模块：负责将 LLM 的语义表示对齐到 DiT 的输入空间
4. Reference Image: 输入参考图像
5. Noise: 输入的高斯噪声
6. DiT 模块：将输入的高斯噪声与参考图进行联合去噪声，得到编辑后的图像

03 核心技术详解

Learnable Query: 连接理解与生成的桥梁

Learnable Query是可学习的"问题"向冻结的 LLM "提问"，提取适合图像生成的条件。

具体实现上，Learnable Query 作为一组可学习参数，采用正态分布进行初始化。在提取条件时，Learnable Query与 Text Embedding 一起输入到 LLM 模型中。模型输出的最后 N 个 Hidden States 参数即为生成条件。

实际使用时我们选择 N = 256 个 Learnable Query 参数。

Connector 模块: 跨模态对齐

Connector 负责将 LLM 的语义表示对齐到 DiT 的输入空间，为图像生成过程中提供了强大的文本理解能力。

网络设计上，Connector 模块包含 Connector 网络和 Projector 网络。Connector 网络采用 Transformer 结构，用来高效提取信息；Projector 网络采用线性层作为实现，用来将 Connector 网络输出的特征对齐到 DiT 的维度。

Deep Compression Autoencoder

传统的 AE 压缩倍数大多为 8 倍，而 Sana 网络中采用了 32 倍的压缩设计（DC-AE-F32C32），相比别的8x的AEs, latent token的数量大大减小，既加速了训练，又减少了推理时的开销，适合端侧场景使用。

Linear DiT

线性注意力机制是 Sana 论文中的关键创新。传统注意力的计算复杂度为 $O(N^2)$，而 Sana 论文中将 DiT 中的 Attention 层都修改为了 Linear Attention， 计算复杂度为 O(N)，减少计算量，加速推理，且通过实验验证，生图无质量损失。

Mix-FFN 模块在传统 FFN 的基础上，增加了 Depthwise 卷积，用于更好地捕捉局部信息。具体来说，Mix-FFN 包含三个组件：倒残差块、3×3 深度卷积、Gated Linear Unit。采用 Mix-FFN 的目的是去掉 Position Encoding，达到 NoPE 的效果。NoPe 即 No Positional Encoding，也即移除位置编码。

文本编码器: Qwen3-0.6B

Sana 论文中采用选择Gemma-2 作为文本编码器具，我们的方案中，采用 Qwen3-0.6B 作为预训练 LLM。Qwen3-0.6B 相比 Gemma-2 的 2.6B，参数量更小，且文本理解能力更强，尤其是在中文 Prompt 场景。

另外，训练稳定性也至关重要。Sana 发现，直接使用 Decoder-only LLM 的文本嵌入会导致训练不稳定，原因在于传统的生图算法采用 T5 等模型，Embedding 层数值较小，而 Decoder-only LLM Embedding 层权重较大，直接沿用之前的训练方案，会导致数值爆炸。

为了解决这个问题，我们也采用 Sana 中的方案，增加RMSNorm 层，归一化文本 Embedding，同时引入小的可学习缩放因子，进一步稳定训练。

Reference Latent

图像编辑需要原始图像作为输入，在我们的方案中，我们通过 VAE Encoder 获取源图像的 Latent，作为参考输入 DiT 生图网络，引导编辑过程，保持图像结构一致性，实现更精确的图像编辑。

04 训练策略

三阶段训练

为了达到最佳的编辑效果，训练过程中我们分三个 Stage 来训练网络。

Stage 1 是预训练阶段，针对文本到图像任务，目标是对齐预训练 LLM 和图像生成任务。具体来说，该阶段只训练Learnable Query 和 Connector 部分的权重，别的模块保持权重固定。这个阶段，我们采用 2 M 的文本–图像对数据训练约 100K Step。

Stage 2 是图像生成微调阶段，训练 Learnable Query，Connector以及图像生成 DiT 模块的权重。基于内部收集的 60K 文本–图像对数据训练约 10K Step。

Stage3 是图像编辑微调阶段，在 Stage2 的基础上，增加参考图像作为额外输入，可训练参数同 Stage2。基于内部收集的 10K 图像编辑数据对训练约 100K Step。

05 MNN 端侧部署优化

模型转换

在 Pytorch 中训练好权重后，我们先将 Pytorch 模型转换为 ONNX 格式，然后再转换为 MNN 格式。由于 MNN 在长期的迭代中已经支持了绝大部分的 ONNX 算子，因此模型转换部分的流程比较顺畅。更多转换细节请参考MNN文档。

量化技术

MNN–Sana–Edit–V2 推理流程涉及多个模型，包括预训练的 LLM，VAE 的 Encoder 和 Decoder，以及去噪模型 DiT 等。通过合理的量化设置，能够显著减少模型内存占用，提高推理速度，且不对最终效果造成明显损失。

具体来说，对预训练的 LLM 模型权重，我们采用了 4Bit 非对称量化，别的模型均采用 8Bit 非对称量化。这个配置能最好地平衡推理性能和生图效果。

真机速度测试

我们在真机上，测试了 512x512 配置下的图像编辑速度：

操作系统	机器型号	芯片版本	生成图片整体耗时(s)
iOS	iPhone 17 Pro （2025 年 9 月发布）	A19 Pro	14.7
iOS	iPhone 16 Pro （2024 年 10 月发布）	A18 Pro	18
iOS	iPhone 15 Pro （2023 年 9 月发布）	A17 Pro	20
Android	一加13 (2024 年 10 月发布)	Snapdragon 8 Elite	45
Android	Xiaomi 12 Pro （2021 年 12 月发布）	Snapdragon 8 Gen 1	62

经测试，OpenAI 的吉卜力风格图像生成耗时 38s–45s，我们在 iPhone 17 Pro 上，以端侧模型比云端模型的配置，做到了 2.5 倍的提速。

运行要求

内存占用：5.5G

系统要求：iOS A16 及以上版本，Android 骁龙 8 及以上版本

最优超参说明

- 输入图像尺寸：建议使用是以正方形图片作为输入，非正方形图片生成效果可能会有下降。
- 输入图像内容：建议输入单张正脸人像，效果最佳，多人或者非人场景效果可能会有下降。
- 输出分辨率：目前模型输出分辨率固定为 `512x512`。
- 图像编辑提示词：本模型流程中已固定提示词，无需额外设置，修改提示词可能汇降低效果。
- 图像生成 step：建议使用 `10` 步，步数过低会有效果损失，步数增加效果无明显提升，且增加运行耗时。

源码和模型下载

源码：https://github.com/alibaba/MNN

文档：

https://github.com/alibaba/MNN/blob/master/apps/sana/README.md

模型权重：

huggingface: https://huggingface.co/taobao-mnn/MNN-Sana-Edit-V2

modelscope: https://modelscope.cn/models/MNN/MNN-Sana-Edit-V2

06 参考论文

- SANA: Efficient High-Resolution Image Synthesis with Linear Diffusion Transformers
- Transfer between Modalities with MetaQueries

07 团队介绍

本文作者蔚山，来自淘天集团-Meta技术团队。本团队目前负责面向消费场景的3D/XR基础技术建设和创新应用探索，创造以手机及XR 新设备为载体的消费购物新体验。团队在端智能、端云协同、商品三维重建、真人三维重建、3D引擎、XR引擎等方面有着深厚的技术积累，先后发布深度学习引擎MNN、商品三维重建工具Object Drawer、3D真人数字人TaoAvatar、端云协同系统Walle等。团队在OSDI、MLSys、CVPR、ICCV、NeurIPS、TPAMI等顶级学术会议和期刊上发表多篇论文。欢迎视觉算法、3D/XR引擎、深度学习引擎研发、终端研发等领域的优秀人才加入，共同走进3D数字新时代。

拓展阅读

3DXR技术 | 终端技术 | 音视频技术

服务端技术 | 技术质量 | 数据算法

大淘宝技术

大淘宝技术官方账号

967篇原创内容

公众号

阅读 2154

留言

写留言

还没有留言，来写首评