CCIG 2026｜TaoAvatar：3D真人数字人在淘宝Vision领域的应用

原创 Meta技术团队 大淘宝技术 2026年6月5日 00:53 浙江 1人



2026年5月29日至31日，中国图像图形大会（CCIG 2026）在广州召开，论坛内容涵盖大模型、三维建模生成与具身智能、空间智能、脑机接口、机器视觉等热点方向，覆盖学术前沿、产业应用和技术创新，与会学术界和产业界同仁近4200余人。

作为中国图像图形学学会的常任理事单位，淘天业务技术Meta技术团队连续第四年受邀出席大会，在专属展位区展示了Meta技术团队介绍与核心技术成果。此外，Meta技术团队受邀在“三维建模生成与具身智能”学术论坛上发表演讲，分享**3D真人数字人在淘宝Vision领域的应用**，报告现场有诸多相关方向高校老师和学生主动联系，表达未来加强交流合作，深化产学研协同创新，共同攻克关键核心技术难题的愿景。

以下为本次论坛分享报告全文——

01 数字人的多元风格与应用场景

我们知道，数字人的风格非常多样，比如我们现在比较常见的，有偏轻量化的2D数字人，也有基于视频生成或视频驱动的视频数字人。最近像Seedance、LPM这类工作都非常火，代表了视频数字人在表现力和生成效率上的快速提升。而如果进一步往3D方向看，像Meta的Codec Avatar也在往3D生成和驱动大模型方向上走，追求更低成本的生成和部署。应用场景也是比较丰富。数字人的形态也很多元，涵盖了二次元、超写实、真人等不同风格，其应用领域包括影视、游戏、通信、电商等，前景广泛。





Meta技术团队陈志文(塞远)在CCIG2026报告现场

02 TaoAvatar技术体系总览

去年淘天集团推出了TaoAvatar这样一种3D真人数字人形态，并且已经在XR眼镜端做出了完整体验。今年TaoAvatar的发力方向主要有两个：第一，是继续扩充它能支持的形象和服饰类型；第二，是围绕一些重点数字人IP，提升它们可驱动动作的丰富度和质量。

具体来说，团队现在主要有三类能力：

第一类是TaoModel——3DGS人体静态建模。 它通过标定、分割、几何重建和高斯静态重建，快速生成高质量的3D人体静态模型。这个能力一方面可以帮助业务方快速预览建模效果，另一方面在一些特定场景下，也可以直接作为最终交付物使用。

第二类是TaoAvatar——3DGS可驱动数字人重建。 它基于多视角拍摄、SMPLX++几何重建和3DGS动态重建，生成可以被语音、手势、动作等方式驱动的3D真人数字人资产。不过目前

它对素材还有一定要求，比如服饰需要相对紧身，动作幅度不能太大，手部末端也要尽量清晰可见。

第三类是TaoVideo——4DGS人体体积视频。 它可以支持任意服饰、发型和身材的模特拍摄，并且通过时间轴做动态重建，比较完整地记录像裙摆这类复杂动态效果，所以能给业务创意带来更大的空间。当然，这类方案目前也需要在重建质量和存储成本之间做一定平衡。



03 核心技术详解

3D真人数字人技术框架

TaoAvatar是一套基于3D Gaussian Splatting（3D高斯泼溅技术）的3D真人数字人方案。它主要解决的是传统3D建模里几个比较典型的问题，比如计算量大、细节还原不够，以及在移动端运行比较困难。



在能力上，TaoAvatar集成了3D高斯重建、语音口唇驱动、身体姿态和手势驱动、端侧实时渲染，以及大语言模型推理引擎MNN-LLM。基于这些能力，它可以服务电商导购、虚拟陪伴等场景，提供更拟真的数字人形象。

这里也补充一下，为什么选择用XR设备来呈现。因为人眼本身就是天然双目的，XR设备更能体现3D数字人的立体感。而在目前的眼镜设备里，Apple Vision Pro在分辨率和稳定性上表现比较好，虽然它也有一些问题，但现阶段来看，仍然是比较适合用来呈现这类体验的设备。

TaoAvatar的核心技术指标包括：清晰度PSNR大于35、稳定性高；实时表情和身体驱动，自然程度高、实时性达到90 FPS；高精度实时渲染，双目分辨率2K、实时性90 FPS；多模态智能交互，首字延迟小于2秒、内存占用小于2.5GB。整体方案实现了高分辨率2K、实时驱动和渲染90fps、制作成本低于2万元、交付效率低于1周，并且已经从ToB的特定IP形象重建扩展到ToC的用户数字分身构建。

真人体型和动作捕捉

这里主要讲TaoAvatar的第一个算法核心：真人体型和动作捕捉。它的输入是多视角视频，输出的是和被拍摄者体型、姿态一致的SMPLX动捕数据，这些数据可以直接用来驱动3DGS数字人。



团队在SMPLX基础上做了几层扩展：比如SMPLX++用来表达头发和服饰Mesh的非刚性形变；SMPLX-Ace用来做自动骨骼绑定；再通过Retargeting，把动捕演员的动作迁移到目标数字人身上。

具体算法流程上，会逐帧提取分层监督信号：脸部用EMOCA，手部用HaMeR，身体用SAM-3DBody的3D关键点。然后先优化每一帧的SMPLX初值，再结合图像和监督信号做mesh tracking，保证时序平滑、减少抖动（Tracking模型还提供了非常丰富的语义parsing结果）。最后再基于图像学习服饰Mesh的非刚性形变，产出最终的SMPLX++动捕数据。

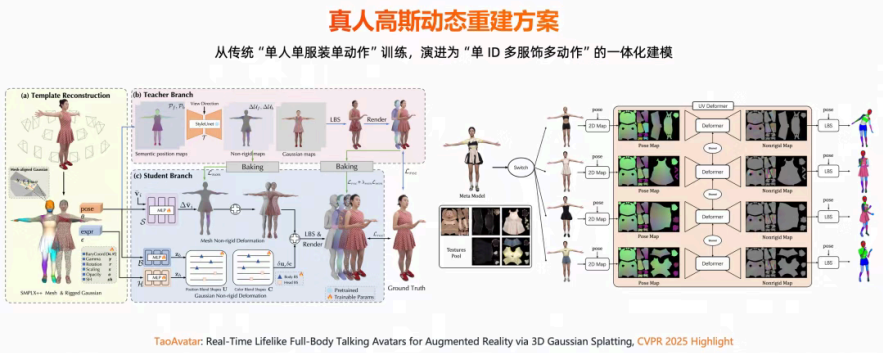
这里有两个比较关键的创新点：第一是脸、手、身体分层解耦监督，分别约束再做时序跟踪，让动捕结果更稳定；第二是小棚和大棚联动，也就是大棚负责大范围动作驱动，小棚负责叠加非刚性形变，从而实现跨棚一致的迁移和驱动。

在大小棚联动上，具体做法是：小棚先用1帧重建锁定统一的骨架和体型，大棚再复用这套骨架和体型去采集更大范围的动作。同时，为了增强稀疏视角下的tracking稳定性，要求至少5个全身可见视角来稳定身体绑定，至少3个手部可见视角来稳定手势绑定。效果上，客观指标显示平均PVE误差在6到7毫米，整体精度优于开源SOTA框架EasyMocap，动捕更全面，体型估计也更准确。

真人动态重建

这里讲一下TaoAvatar在可驱动3DGS数字人重建上的新思路。团队之前的核心做法，是通过教师–学生框架、轻量化设计，以及非刚性形变烘焙和轻量化BS补偿，让数字人资产既能保持较高清晰度，又能控制资产大小，从而实现端侧实时渲染。

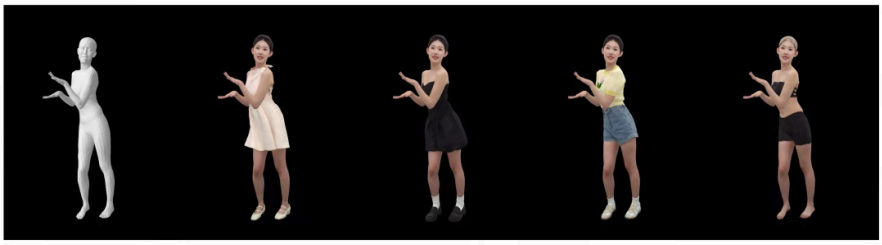
但新的问题是：同一个数字人ID，如何支持不同服饰、不同动作的统一驱动。为了解决这个问题，团队从过去的"单人、单服装、单动作片段"的训练，升级到"单ID、多服饰、多动作"的一体化建模。



具体来说，会先基于多视角影棚数据，对同一个ID采集多套服饰和多段动作，完成SMPLX++绑定和tracking。然后通过人体部件Parsing，把身体、服饰、发型等区域做细粒度分割，并在UV空间里统一学习肌肉和服饰的非刚性形变。不同服饰之间可以共享权重，实现跨服饰复用。

最后，会把这些形变通过PCA烘焙成端侧可实时运行的几何形变场和高斯形变场。这样在推理时，只要输入这个ID的姿态驱动信号，就可以驱动它在不同服饰下产生自然运动，包括肌肉形变和服饰形变。整体资产规模大约400MB，并且可以在端侧做到90 FPS的实时推理和渲染。

展示效果方面，团队展示了不同Pose下衣服几何的非刚性形变效果，以及用同一组驱动信号驱动相同ID不同服饰的效果。虽然还是会有一些穿模，但整体的驱动效果是比较一致的。

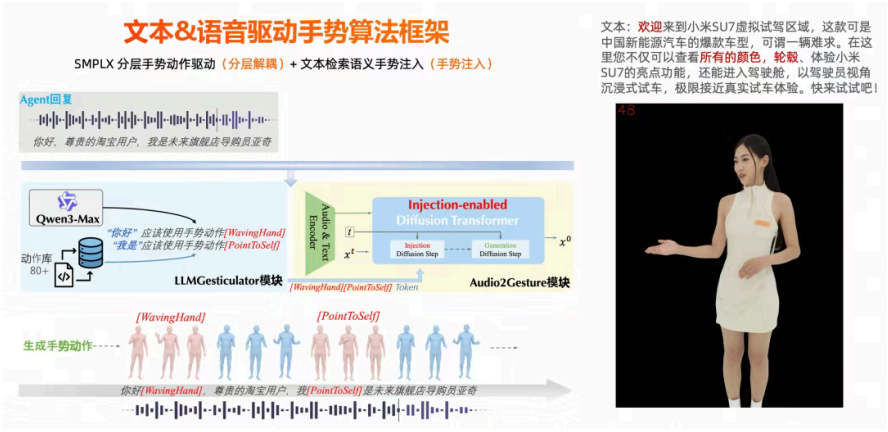


同时也展示了在相同ID、相同服饰，但不同动作下的驱动效果，包括走路引导、互动游戏、店铺讲解等应用场景。



真人语音驱动手势

这里讲一下TaoAvatar的语音和文本驱动手势算法框架。简单来说，系统接收语音和文本输入后，会生成两类动作：一类是基础手势，比如说话时自然的节奏型肢体反应；另一类是强语义手势，也就是根据文本含义触发特定动作，最后再通过SMPLX驱动3DGS数字人。



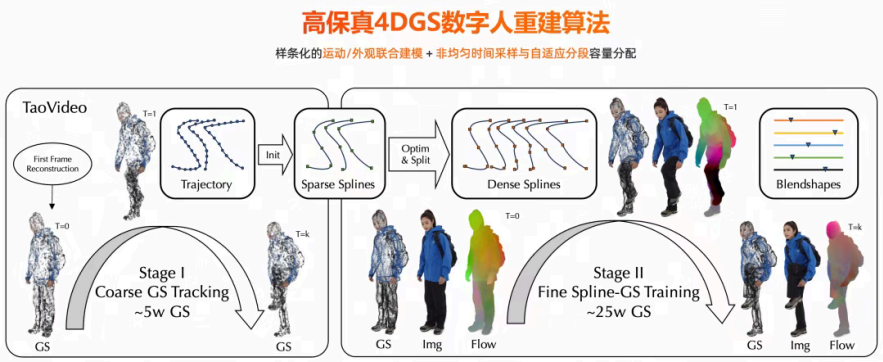
在算法上，基础手势主要由GestureDiT生成，它会结合语音和文本特征，对SMPLX人体结构做分层建模：先生成上半身动作，再预测手指姿态，下半身则根据上半身动作条件化生成。这样可以让"原地讲话"场景下的动作更自然、更稳定。

对于强语义手势，团队会用Qwen-LLM理解文本内容，检索匹配的预制语义动作，并在GestureDiT的去噪过程中注入进去，让数字人在说到关键语义时能做出更匹配的手势。

训练上，团队使用了单目视频动捕数据和3D影棚多模态数据。推理时，模型一次预测1秒的动作，并且可以实时运行，RTF小于1，在3090这类消费级显卡上也能部署。效果上，系统在相同语义下用中文和英文表达都能生成对应的手势效果。

TaoVideo：真人4DGS体积视频

这里讲一下TaoVideo-4DGS人体体积视频重建。它的特点是输入多视角视频，不限制人物和服饰，也不依赖SMPLX这类显式人体模型，直接输出一段4DGS动态重建序列。



核心思路是把高斯点的运动和外观都做成"样条曲线"。运动上，用样条曲线来描述高斯点的位置和旋转变化；外观上，也用样条来描述颜色变化，并加入生命周期机制，表示高斯点什么时候出现、什么时候消失。这样就能更好地还原衣服飘动、裙摆变化这类复杂动态。

同时，团队引入了非均匀时间控制点和自适应分段建模。简单说，就是动作快、细节多的地方分配更多控制点和高斯容量，动作慢的地方就减少冗余，从而在质量和存储之间取得平衡。

训练上，一段20到25秒的多视角视频会先用静态3DGS初始化，再通过coarse-to-fine的方式逐步优化动态细节。推理时，端侧可以实时渲染到约90 FPS，单段资产在FP16存储下大约400MB。整体来看，这个方案更适合任意服饰、复杂外观和动态效果丰富的数字人视频重建。

主观效果上，对帽子、复杂发型及裙摆等宽松服饰的外观细节与摆动形变刻画稳定，资产内部无明显闪烁。客观指标方面，TaoVideo平均重建清晰度PSNR为31至35，LPIPS为0.06至0.1。团队也展示了TaoVideo和TaoAvatar的效果对比，特别是裙摆动态效果方面的差异。



04 淘宝Vision落地应用

从去年到今年，团队把基于XR眼镜的3D版淘宝体验，从线上扩展到了线下，在杭州、上海、长沙、深圳等城市陆续开业了淘宝Vision未来旗舰店。

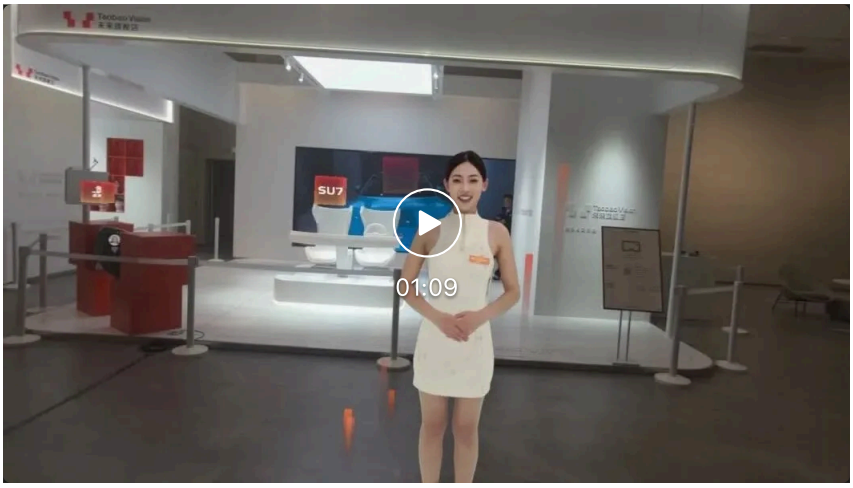
淘宝Vision（线上）是基于Vision Pro的空间购物App，荣获2025年度Apple Design Awards。该奖项设立36年来，这是国内互联网平台首次获奖。淘宝Vision以3D沉浸式体验呈现商品造型、尺寸、材质等细节，支持多商品同屏对比，提升购买决策效率。依托自研AI的三维重建能力，并提供语音搜索、图片搜索等自然交互，让购物更直观、更流畅。

淘宝Vision未来旗舰店（线下）打造了全新的未来购物空间，融合"AI+3D+XR"技术，为品牌提供提升线下门店效率的一体化解决方案：在有限空间内实现海量SKU的沉浸式展示，支持消费者自由选配，带来更真实、更具参与感的到店体验。目前已在杭州、上海、长沙、郑州、南京、深圳开业。

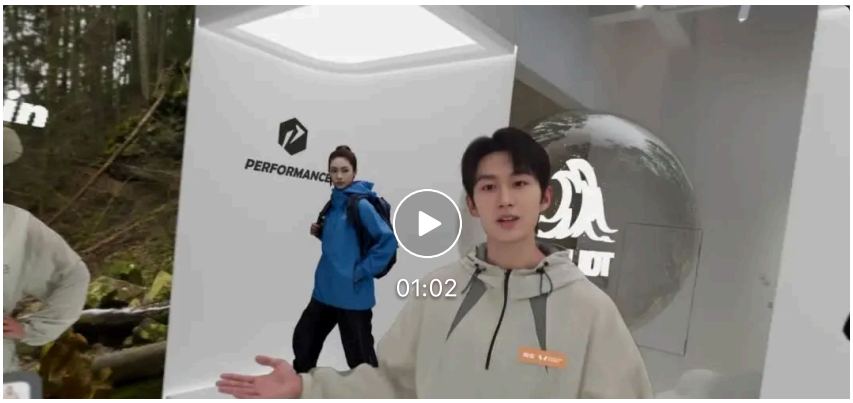


在具体的品牌合作案例中，伯希和虚拟服装店提供了3D人工智能导购和多模态智能问答服务。此外，团队还为米兰冬奥会打造了服饰数字人，在意大利米兰开设了虚拟服装店，提供3D服饰模特展示。

淘宝 Vision 未来旗舰店3D智能导购

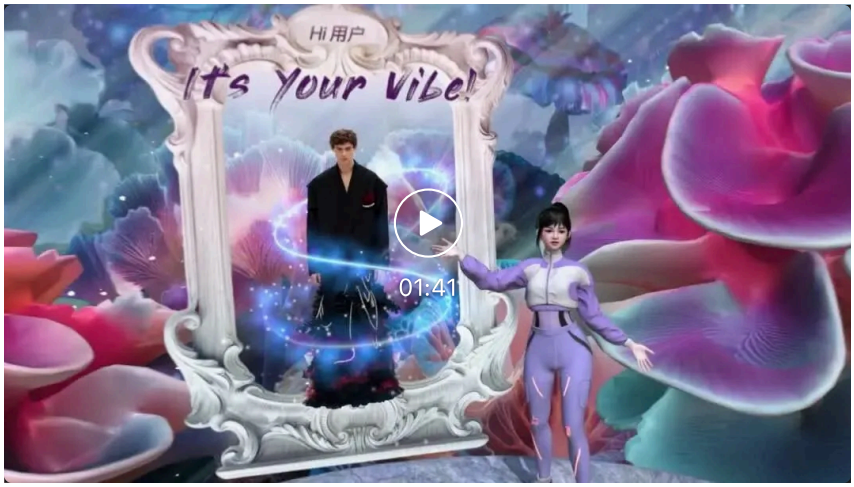


淘宝 Vision 伯希和3D虚拟服装导购





淘宝 Vision 米兰冬奥会3D服饰数字人



05 未来技术演进

相较于影棚拍摄数字人，团队也在探索用单图/稀疏视角的低成本数字人生成方案，进一步降低门槛、扩大规模。

今年CVPR团队提出了FHAvatar：从任意数量的视角快速重建可组合的3D高斯人头，并把人脸和头发在纹理空间拆开建模——面部用平面高斯，头发用Strand高斯。只要少量照片，几分钟就能做出高质量结果，还能实时驱动表情嘴型、轻松换发型、做风格化编辑等。

06 团队介绍

淘天Meta技术团队，核心做的事情是面向消费场景的3D基础技术和XR创新应用，打造以手机和XR设备为载体的购物新体验。如手机淘宝里的AR试商品，以及基于XR眼镜的纯3D版淘宝——淘宝Vision等。围绕这些场景，团队沉淀了TaoAvatar 3D数字人、Taobao3D商品重建与生成技术、Ace渲染引擎以及AI推理引擎MNN等核心技术产品。欢迎关注我们的主页：https://github.com/alibaba/Taobao3D



我们27届毕业的实习生招聘还在火热进行中，欢迎感兴趣的同学投递简历至 zhiwen.czw@taobao.com

拓展阅读

3DXR技术 | 终端技术 | 音视频技术

服务端技术 | 技术质量 | 数据算法

大淘宝技术

大淘宝技术官方账号

967篇原创内容

公众号

阅读 1164

留言

写留言

还没有留言，来写首评