淘宝TaoMate-H3开源：三步生成「分钟级」音视频连续创作

直播技术团队 大淘宝技术 2026年10月13日 19:27 浙江 2人

TaoMate-H3 是由阿里巴巴 TaoLive AIGC 团队研发的音视频联合流式生成模型。基于 MiniMax H3，TaoMate-H3 将三步 LoRA 推理与自回归生成相结合，能够根据文本描述，连续生成包含人物对白、歌声或环境音的视频，支持分钟级续写，以及 480p、768p、1080p 级横竖屏输出。

与整段视频反复去噪的生成方式相比，TaoMate-H3 以小片段为单位推进，每个片段仅需三步去噪，无需等待整段视频完成生成。这一方式显著缩短了首段内容的产出时间，也为直播讲解、虚拟角色表演和交互式视频应用提供了新的技术基础。

目前，TaoMate-H3 推理代码与 LoRA 权重已正式开放。 开发者可通过 GitHub 和 Hugging Face 下载体验，在此基础上开展应用开发与流式生成研究。以下是本次发布的演示效果。

- 开源代码：github.com/TaoLiveAIGC/TaoMate-H3
- 模型权重：huggingface.co/TaoLiveAIGC/TaoMate-H3

01 什么是 TaoMate-H3?



TaoMate–H3 面向需要持续生成声音与画面的创作场景。用户可以用一条提示词描述完整场景，也可以按段安排台词、动作和情节；模型在保留历史上下文的基础上继续生成，使相邻段落共享人物、声音和场景信息。

这次发布主要围绕三个核心能力展开。

三步流式生成，降低等待时间

通过少步 LoRA，TaoMate–H3 将每个小片段的去噪过程压缩为三步。模型优先完成当前片段，再生成后续内容，无需等待整个视频完成去噪。对于需要及时反馈的内容生产，这种逐段产出方式有助于缩短等待，并为边生成边播放提供基础。

音视频联合生成，丰富人物与场景表现

TaoMate–H3 在同一生成过程中处理声音与画面，既支持人物讲话、歌唱和角色对白，也支持海浪、车辆运动、爆炸等环境与动作音效。声音参与模型的生成过程，为口型、表情和动作提供时间上的配合。

分钟级连续续写，支持分段内容编排

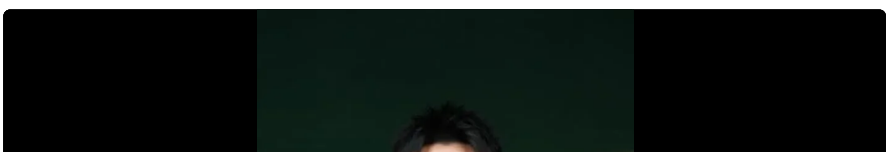
借助持续更新的音视频 KV 缓存和分段音频引导，模型能够跨越提示词边界延续前面的内容。创作者可以逐段调整讲解重点或表演内容，组织更完整的商品介绍和角色叙事。

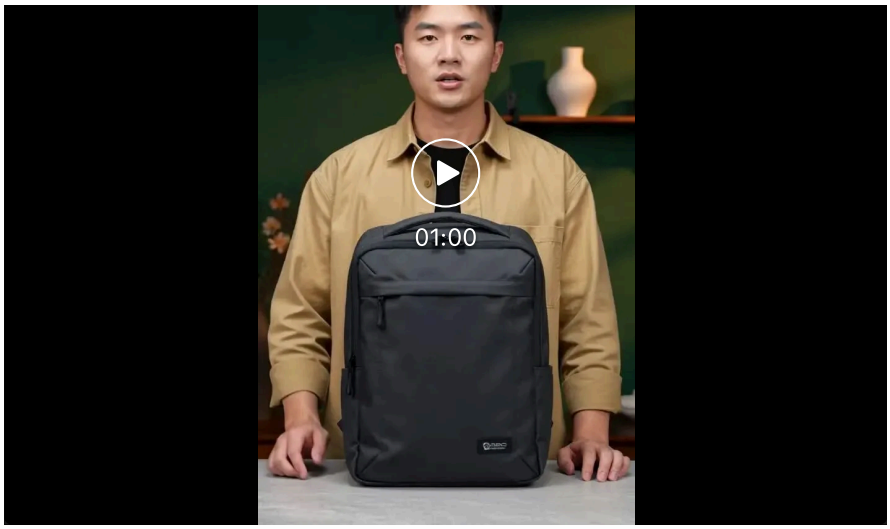
02
应用效果

电商讲解：从商品展示到完整介绍

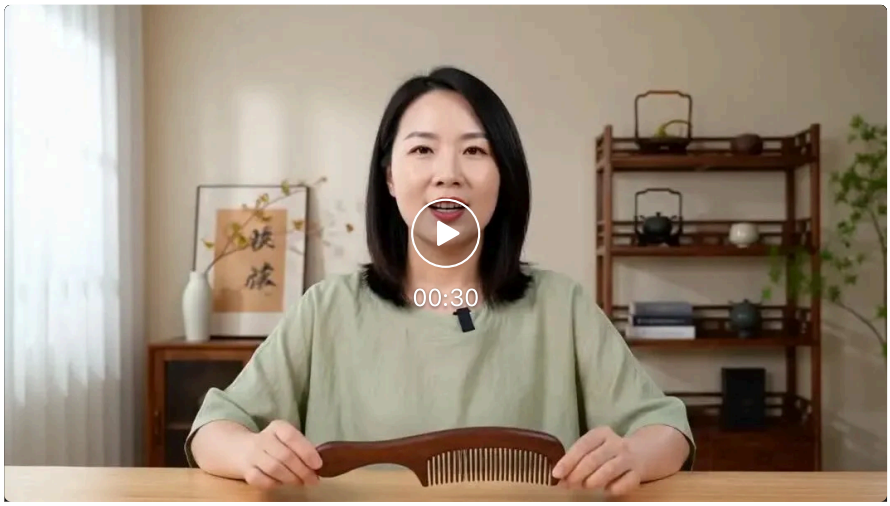
商品介绍通常包含外观展示、功能细节和使用场景等多个环节。TaoMate–H3 支持用分段提示词编排这些内容，在连续镜头中推进讲解，适用于商品短视频、选品介绍和品牌内容制作。

本次展示包含一分钟的竖屏背包介绍，以及横屏木梳讲解。两组案例呈现了不同画幅下的人物口播与商品展示效果，其中背包视频保留了完整的一分钟生成结果。





背包讲解 | 60 秒 | 1080p 竖屏 | 原声。

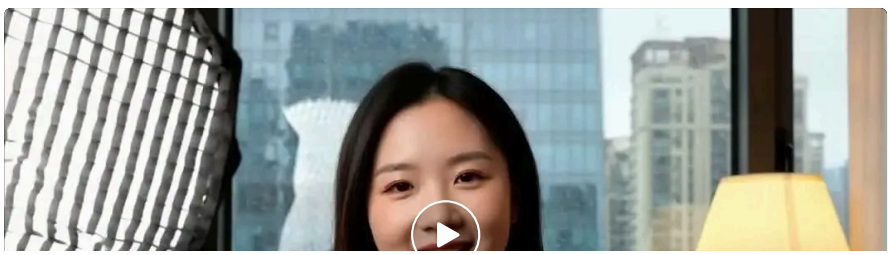


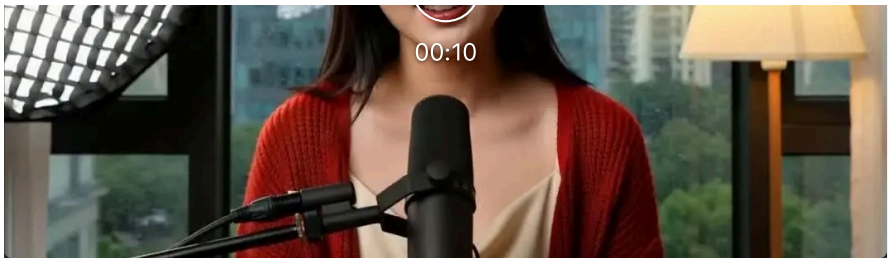
木梳讲解 | 30 秒 | 1080p 横屏 | 原声。

围绕同一件商品，创作者还可以针对不同人群调整讲解内容，例如突出通勤收纳、旅行携带或日常使用等需求。分段编排让卖点顺序与台词节奏更容易控制，也便于制作不同版本的商品内容。

演唱与角色表演：声音、表情和动作共同呈现

除了商品口播，TaoMate–H3 还支持包含歌声与音乐的表演场景。窗边演唱案例展示了写实人物的歌唱过程，将旋律、口型和身体动作组织在同一段视频中。

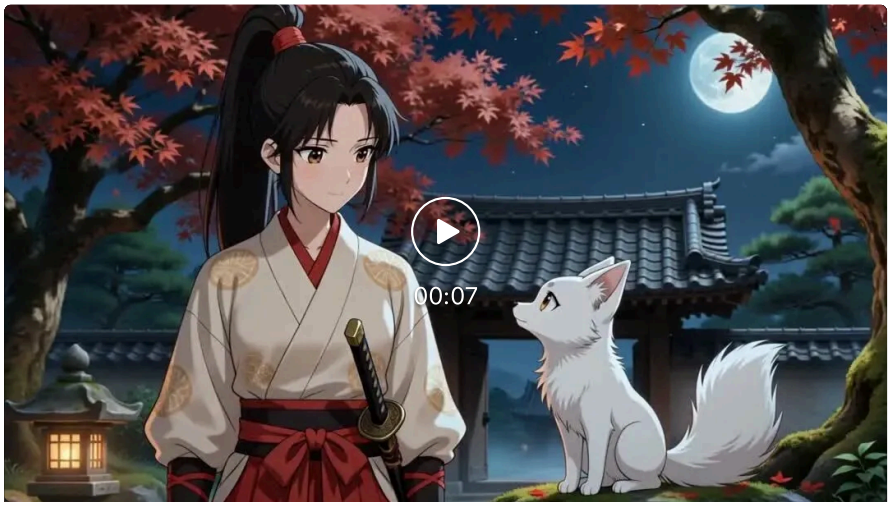




窗边演唱 | 10 秒 | 1080p 横屏 | 原声演唱。

动漫对白：拓展风格化角色创作

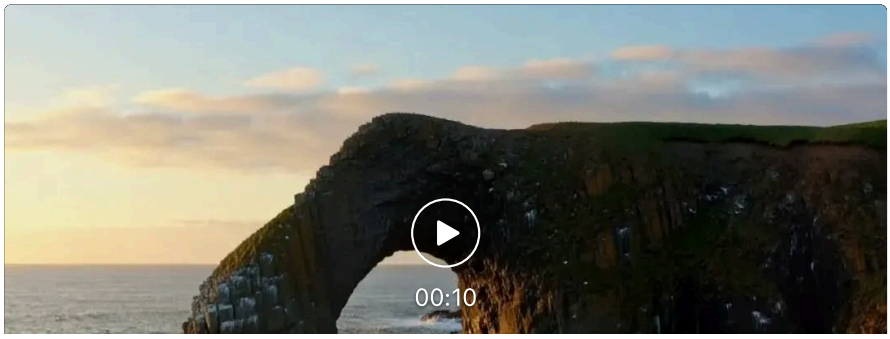
音视频联合生成同样适用于动漫内容。在月夜少女与白狐的案例中，风格化的人物、场景与角色对白共同构成了一个短剧情片段。创作者可以通过提示词设定角色形象、环境氛围与台词，再逐段推进故事情节。

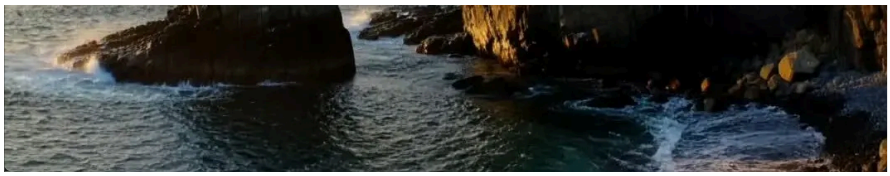


月夜少女与白狐 | 7 秒 | 1080p 横屏 | 原声对白。

环境与特效：让场景拥有自己的声音

TaoMate–H3 的生成范围还包括没有人物对白的场景。日落海岸案例以海浪和环境原声表现空间氛围；电影爆炸案例则将人物运动、建筑爆炸与冲击音效结合起来，呈现更强烈的视听节奏。





日落海岸与海蚀拱门 | 10 秒 | 1080p 横屏 | 环境原声。



人物向前，身后建筑爆炸 | 20 秒 | 1080p 横屏 | 原生音效。

这些案例覆盖了商品讲解、人物演唱、动漫对白、风景与电影特效等不同内容类型。模型提供横竖画幅和多档分辨率，便于适配移动端内容与横屏展示。

03 TaoMate-H3 整体流程

从提示词到最终视频，TaoMate-H3 的推理流程主要包含四个环节：

1. **分段组织内容。** 根据目标时长读取提示词序列，确定每个段落的场景、动作和声音描述。
2. **准备音频引导。** 为当前段落生成音频去噪轨迹，并利用上一段尾部的声音信息衔接音色与语气。
3. **联合流式生成。** 将段落拆成小片段，每个片段执行三步音视频去噪，并持续更新历史 KV 缓存。
4. **解码输出。** 生成的 latent 通过 VAE 解码为画面与声音，完成媒体输出。公开推理入口会自动运行整套流程并保存最终视频。

其中，latent 是模型生成过程中使用的音视频压缩表示。模型先在这一表示空间中完成生成，再通过解码得到可观看、可收听的内容。

04 TaoMate-H3 关键技术

三步 LoRA：减少每个片段的生成开销

TaoMate–H3 通过少步 LoRA 适配，将流式推理压缩到三个去噪区间。在当前五秒提示词配置下，每个段落分为四个 chunk，主体 chunk 约为 1.4 秒，尾部片段较短。模型依次完成这些片段，并利用历史上下文继续生成。

三步更新沿 `0→16→33→49` 的时间状态推进。每个片段完成后，模型基于最终生成的音视频状态更新 KV 缓存，供下一片段使用。少步生成减少了反复迭代的计算量，分块处理则使模型能够更早产出第一段内容。

Self Forcing：面向连续续写的自回归训练

在训练阶段，TaoMate–H3 采用 Self Forcing 的自回归训练思路 [1]，让模型以自身生成的历史片段为条件，继续生成后续内容。这使训练过程能够接触实际续写中的历史状态，缓解仅依赖真实历史训练所带来的训练与推理分布差异。

这一训练方式与少步推理、KV 缓存共同构成了流式续写的基础：模型既学习当前片段的生成，也学习如何利用此前的输出延续人物、动作和场景。

[1] Huang et al. Self Forcing: Bridging the Train–Test Gap in Autoregressive Video Diffusion. NeurIPS 2025.

音视频 KV 缓存：支持长视频连续记忆

为维持长视频的一致性，TaoMate–H3 持续复用音视频 KV 缓存，将已生成内容的上下文传递给后续片段。人物状态、近期动作和声音信息因此能够随时间延续，在切换提示词时仍参与后续生成。

缓存采用“起始视觉参照 + 近期音视频上下文”的组织方式。起始参照保留人物与场景的初始信息，近期上下文随生成进度滚动更新，使模型能够跟随最新的动作与声音继续创作。

这种方式将历史缓存控制在固定规模内，避免其占用随视频时长不断增长，为分钟级连续生成提供了稳定的上下文支持。

连续时间编码：改善跨提示词衔接

在长视频中，提示词可以变化，媒体时间线仍需连续。TaoMate–H3 使用全局连续的 RoPE 位置编码，随音视频进度移动当前文本的时间坐标，并将文本右边界对齐到当前媒体的起点，使新提示词对应正在生成的内容。

切换提示词时，系统保留已有音视频 KV，同时区分新生成内容与编解码所需的尾部上下文。历史内容仅用于衔接，不重复生成。针对长时间续写中的亮度和色调变化，模型还以首个片段的视觉统计为参照，对后续视频 latent 进行均值与方差对齐，减轻画面观感的漂移。

音频轨迹引导：稳定台词节奏与音色

流式生成将视频拆成了短片段，但一句台词的停顿、语速和结束位置需要在完整段落内安排。TaoMate-H3 在内部先准备覆盖当前提示词段落的音频去噪轨迹，再将对应时间位置的音频 latent 用于引导各个小片段，使局部生成始终具有段落级的声音参照。

三次去噪更新分别对齐音频轨迹中的三个状态，最终音频 latent 与引导轨迹的干净终点保持一致。音频引导贯穿生成过程，有助于稳定台词的展开节奏，减少短片段续写时的重复起句。

为衔接不同段落的音色与语气，系统将上一段最后约一秒的干净音频作为只读参考。新音频在这一参考下继续生成，参考本身保持不变；最后统一解码各段音频 latent，得到连续的声音输出。



在同一台 8 × NVIDIA H20 96 GB 机器上，我们对原版 MiniMax H3 与 TaoMate-H3 进行了测试，输出均为 480 × 864、十秒视频。

TaoMate-H3 的纯 DiT 计算耗时由 169.572 秒降至 14.810 秒，**加速 11.45 倍**；首段最终 latent 的就绪时间由 170.052 秒缩短至 6.148 秒，**加速 27.66 倍**。首段 latent 就绪对应模型完成第一段生成、可交给 VAE 解码的时间。

对比项目	MiniMax H3	TaoMate-H3	加速比
纯 DiT 计算耗时	169.572 秒	14.810 秒	**11.45×**
首个最终片段 latent 就绪	170.052 秒	6.148 秒	**27.66×**

在上述十秒配置下，TaoMate-H3 共生成八个小片段，执行 24 次生成前向和 8 次 KV 更新。单机八卡采用 TP2 × Ulysses4 并行，并结合高效注意力、算子融合及部分线性层的选择性低精度计算，降低推理开销。

这些优化既提升了整段内容的生成效率，也缩短了首段内容的产出时间，为分块解码、播放和交互应用开发提供了基础。

06 快速体验

环境与硬件

项目支持 Linux、Python 3.10/3.11、CUDA 12.8 与 PyTorch 2.8，提供单机 4 卡或 8 卡推理入口。已验证的运行配置为 8 × H20 96 GB，完整安装步骤见仓库 README。

运行示例

获取代码：

```
git clone https://github.com/TaoLiveAIGC/TaoMate-H3.git
cd TaoMate-H3
```

按照 README 完成环境安装和 MiniMax H3 基础权重下载后，即可运行仓库内的十秒示例。TaoMate-H3 LoRA 权重会在首次使用时自动下载：

```
python -m taomate_h3 \
  --model-root models/MiniMax-H3 \
  --prompt-json examples/prompts_10s.json \
  --duration 10 \
  --resolution 768x1376 \
  --gpus 8 \
  --output outputs/demo_10s
```

结果保存在 `outputs/demo_10s/video.mp4`。替换提示词文件即可修改场景、台词与动作；通过时长和分辨率参数，可以进一步生成更长的视频或切换横竖画幅。

07 开源与后续计划

本次发布包含推理代码、LoRA 权重及示例提示词，欢迎开发者下载体验，也欢迎围绕流式推理、音视频生成和应用集成与我们交流。

项目基于 MiniMax H3，遵循 MiniMax H3 Community License。感谢 MiniMax H3 及相关开源工具的贡献者。

团队仍在持续优化推理速度，进一步缩短首段内容与后续响应的等待时间。我们也计划在不久的将来陆续发布并开源新的 FL2AV 流式模型，进一步拓展到 Ref2AV，并同步开放相应权重，支持更丰富的音视频创作方式。

期待与社区一起推进音视频流式生成，让这项技术走进更多实际的创作场景。

08 团队介绍

本文作者祁隽，来自淘天集团–直播 AIGC 团队。本团队作为直播电商智能化领域的先行者，始终致力于通过 AI 原生技术创新重构电商直播场景中的人货场交互范式。团队基于对大语言模型研发、多模态语义理解、语音合成、数字人形象生成、AI 工程化部署及音视频处理技术的深厚沉淀和积累，已搭建起覆盖直播全链路的 AI 技术矩阵。自主研发的数字人直播解决方案通过商业化验证，成功实现从技术研发到商业变现的完整闭环，累计服务上千家商家。

拓展阅读

3DXR技术 | 终端技术 | 音视频技术

服务端技术 | 技术质量 | 数据算法

大淘宝技术

大淘宝技术官方账号

966篇原创内容

公众号

阅读 3035

留言

写留言

还没有留言，来写首评