面向智能导购的Agent评测实践

原创 场景智能技术团队 大淘宝技术 2026年5月15日 01:56 浙江 152人

本文提出一套面向家居导购Agent的自动化评估链路：基于结构化多维度（基础/专业/补充指令+用户画像）Benchmark，采用LLM-as-a-judge实现91.9%准确率的自动评分，并通过人工抽样校准；在“放我家”落地后，量化对比发现gpt51最优（总分0.680），较当前线上模型qwen3-vl提升16.4%；核心瓶颈为：无法识别已有家具、抓不住核心需求、推荐过度。

01 引言

随着大模型能力提升，智能 Agent 正在智能客服、个性化导购等交互式场景中承担从需求理解到多轮引导的关键工作。在家居导购领域，用户对空间设计、家具搭配与生活方式定制的诉求更复杂且高度个性化，传统规则/模板式推荐已难以满足。因此，具备多模态理解（图文）、上下文感知与工具调用能力的搭配 Agent 成为提升体验与转化的核心。

但 Agent 能力增强也带来新的挑战：**如何高效、稳定、可量化地评估其真实表现。**人工抽检成本高、主观性强、难复现，难以支撑高频迭代下的性能追踪与归因。版本更新后，也缺少可靠手段快速判断收益或发现隐性退化。

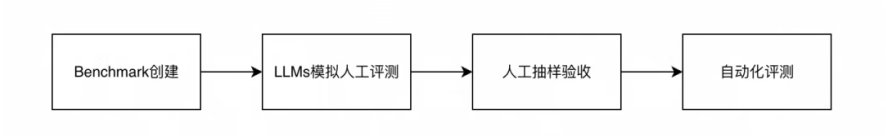
我们搭建了端到端自动化评估链路，基于 LLM-as-a-judge 实现自动评分，评判准确率达到91.9%，显著提升评测效率与准确性。一方面以标准化 Benchmark 覆盖多样场景与复杂约束，客观衡量任务完成度。另一方面在每次模型/策略更新后自动全量评测，输出可对比指标，帮助快速定位波动与退化原因。

该链路已在“放我家”智能导购 Agent 的搭配任务中落地，“放我家”是家装领域的AI智能导购应用。基于该链路，我们可横向对比不同基座模型与方案，并分析错误以指导优化。本文将分享我们最新的研究进展，希望能给大家带来帮助～

02

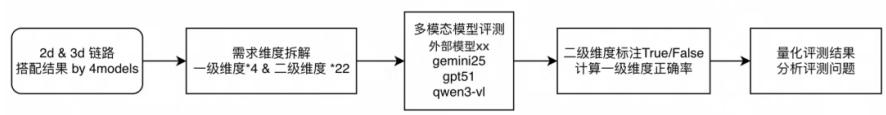
整体方案

我们将评估体系设计为一条从数据到指标的闭环流水线：先用 Benchmark 固化真实业务场景与难度梯度，再让 LLM 进行自动评审，随后用人工抽样对 LLM 评审结果进行验收校准，最后将整条链路工程化为可自动回归的评测系统。这样既能获得可量化、可对比的指标，又能通过抽样验证评测可信度。



方案由四个模块构成（从数据到指标闭环）

- Benchmark 创建：构建覆盖典型导购搭配任务的基准测试集，按场景类型、难度等级组织样本，既代表线上真实分布，也覆盖长尾与高难问题，为持续迭代提供稳定参照系。
- LLM 模拟人工评测：引入多个多模态大模型作为“评审员”，在统一评分规约下对 Agent 输出进行维度化判定与打分；并可通过多评审投票，提升评审稳定性与鲁棒性。
- 人工抽样验收：对 LLM 的评审结果进行抽样人工复核，计算准确率并分析误判类型；一方面用于校准评分规约与评审模型选择，另一方面为自动化评测结果提供可信“质量闸门”。
- 自动化评测与报告产出：将评测流程工程化，每次模型更新将进行全量评测，自动汇总低分样本与失败模式，支持快速定位退化原因。



落地执行路径（5 步）

1. 生成候选搭配结果：在 2D 与 3D 两条业务链路中，分别由多个方案/模型生成搭配结果，组成测试集数据，便于横向比较。
2. 需求维度拆解：将“用户需求 + 任务目标”结构化为可判定的评测清单：一级维度（4 项）用于衡量总体能力与任务完成度（宏观指标）。二级维度（22 项）用于检查细节质量（诊断指标）。
3. 多模态自动评测：评测模型结合图文输入，对每个二级维度逐项判定与给分，保证评价口径一致、可批量执行，并支持不同评测模型的结果对比与一致性分析。
4. 二级维度标注 & 一级维度汇总：二级维度以 True/False（满足/不满足） 形式输出；再按规则聚合到一级维度，计算一级维度准确率，得到更稳定、可追踪的核心指标。
5. 输出量化结果并进行问题分析：生成可对比的评测报表，并对低分维度与典型失败样本做归因分析，沉淀可行动的优化方向（能力短板、提示词/策略问题、工具链问题、数据覆盖

问题等）。

评测维度

为了对导购 Agent 的能力进行结构化、可量化的评估，我们构建了两级评价体系：一级维度用于衡量关键能力，二级维度用于检查细节完成度。所有评测任务均按照这套维度体系进行，使自动打分具备统一标准、可解释性与可复现性。

整个体系围绕导购场景中最核心的四类能力展开：基础指令响应（商品选择相关）；专业指令响应（空间设计相关）；补充指令响应（偏好与附加条件）；用户画像（识别典型场景和常见需求）。

一级维度	二级维度	具体内容
基础指令维度（商品选择相关）	品牌	用户是否指定或偏好某个品牌，是否要求高性价比、进口品牌、环保品牌等。
	类目	明确所需商品类型，例如：床、书桌、玩具收纳柜、展示柜、餐桌、吧台、办公桌、灯具、空气净化器、温湿度设备、智能设备等。
	预算	预算上限、期望价位带（如 500–2000）、性价比需求、是否接受定制。
	功能	可升降、带储物、折叠、移动轮、智能控制、护眼照明、防滑、安全防护、多功能切换、可扩展模块化、可拼搭等。
	尺寸	需要兼容现有空间大小、动线、儿童身高、老人使用便利等。
专业指令维度（空间设计相关）	房间类型	儿童房、客厅、餐厅、卧室、老人房、亲子空间、多功能房等。
	房间结构	现有家具（如“只有床和书桌”、“只有沙发和餐边柜”）、剩余空间大小、动线条件、光线条件、墙面可利用程度。
	分区需求	儿童房：玩具收纳、绘画角、阅读区、语言学习、编程桌、手工区、小舞台、午休帐篷、成长展示、照片墙、安全防护等 餐厅：早餐区、吧台、宝宝喂养区、防滑地垫、红酒区、烘焙区、节庆布置、宠物饮食区、作业区等 客厅：观影区、桌游区、宠物区、老人康复区、办公区、婴儿看护区、艺术创作区、节庆聚会区等 卧室：收纳、办公、阅读、冥想、晨练、观影、老人药品收纳、温湿度控制、亲子活动区等

	形态	直线型、L 型、U 型、可拼接、可折叠、封闭式 vs 开放式收纳等。
	布局	靠墙放置、角落利用等
	风格	现代简约、北欧、原木、儿童活泼风、清新明亮、轻奢、温馨居家、极简功能主义等。
	色彩	亮色、柔和、中性、木色系、多彩儿童风、沉浸观影氛围灯光等。
	材质	环保板材、实木、金属、玻璃、安全圆角、可清洁材质、防滑材质、亲肤面料等。
	工艺	包角、圆角防撞、环保等级、手工工艺、耐磨处理、抗指纹面、易拆洗、隐藏式收纳等。
补充指令维度（偏好 & 附加条件）	人群偏好	儿童：护眼、启蒙、创作、安全防撞、色彩明快 老人：便利取物、柔光照明、安全扶手、低噪设备 宠物：易清洁、耐抓耐磨、独立饮食区 婴儿：柔软材质、安全可视、清洁分区 夫妻：观影、护肤区等
	场景偏好	摄影、编程、手工、语言学习、桌游聚会、节庆布置、烘焙展示、艺术创作等。
	商品偏好	用户可能希望：卖得最好的、口碑最好、儿童安全等级高、最耐用、最省空间、明星同款、网红同款等。
	健康环保	环保等级、无异味、抗菌、防霉、空气质量提升、温湿度控制等。
	智能需求	是否需要：智能照明、智能音响、智能展示屏、智能监控、智能温湿度、智能升降桌。
	使用维护	易打理、耐用性、可拆洗、可升级模块、可长期陪伴孩子成长等。
用户画像（典型场景 & 常见需求）		对某类用户的典型行为、需求、偏好和使用场景 进行概括描述的标签化信息

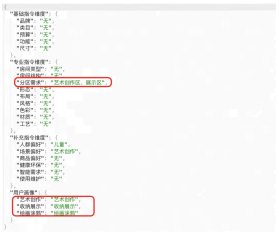
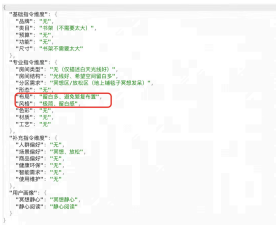
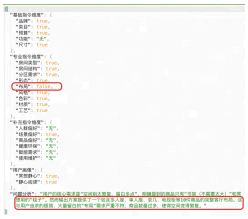
数据集构建

数据集的多样性与分布均衡：测试样本既包含单维度需求，也包含多维度叠加约束，覆盖卧室、客厅、餐厅等典型家居场景，同时从简洁指令到长文本表达、从纯文本到图文混合，均进行了充分设计，以保证测试的代表性与复杂度。

数据集的挑战性：在任务难度上，数据集覆盖简单和复杂样本。简单样本用于验证基础理解能力，数量较少；大多数样本为多维度、多约束的真实场景，用于考察模型在处理复杂需求时的稳定性与适应性。

所有输入都会经过结构化的多维度拆解，将用户描述映射到基础指令、专业指令、补充指令和用户画像四类需求标签。基于这些结构化需求与 Agent 的搭配结果，我们对输出进行逐维度评测，最终得到每条样本的准确率评分以及对应的问题分析，例如需求遗漏、风格冲突、尺寸不匹配等。

通过这套标准化构建方式，我们确保数据集能够真实反映业务场景，并为自动化评测提供清晰、可量化、可复现的参照基准。

输入信息	需求拆解	搭配结果	输出结果的评测
			
			

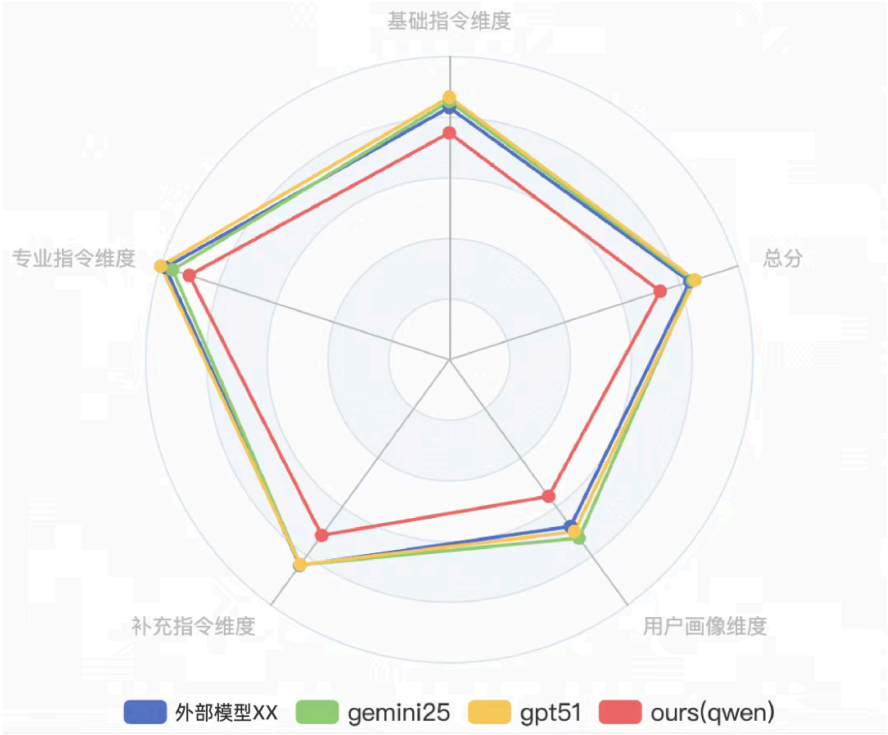
03 评估实践

量化结果

在数据集构建完成后，我们使用四种搭配模型生成最终的搭配结果，分别为：外部模型XX、gemini25 （gemini-2.5-pro-06-17） 、 gpt51 （gpt-51-1113-global） 、 qwen3-vl （qwen3-vl-235b-a22b-instruct） 。这些模型分别产出了对应的空间搭配方案，成为后续评测的输入。

随后，我们采用同样的四种模型作为评测模型，对全部搭配结果进行独立评分。每个评测模型都会对同一条样本进行多次评估，并取平均值以提升稳定性与一致性。评测结果按四大维度（基础指令、专业指令、补充指令、用户画像）以及总分维度输出，并通过与人工标注的 GT 对比计算准确率。每个模型的准确率均以 [0, 1] 区间呈现，用于衡量其判定结果与人工评审的一致程度。

搭配	基础指令维度	专业指令维度	补充指令维度	用户画像维度	总分
外部模型XX	0.665	0.786	0.670	0.543	0.666
gemini25	0.681	0.766	0.668	0.581	0.674
gpt51	0.692	0.799	0.668	0.560	0.680
qwen3-vl	0.598	0.720	0.572	0.445	0.584



对四种大模型基座的搭配能力进行量化评测，并使用四种评测模型交叉评审后发现：相较于当前线上方案 qwen3-vl（总分 0.584），最优基座 gpt51 的总分提升 16.4%（0.584 → 0.680）。

总分排名：gpt51 > gemini25 > 外部模型XX > qwen3-vl
从分维度结果来看，多基座搭配 Agent 的能力差异较为清晰：

- gpt51 综合表现最佳：总分 0.680 位列第一，优势主要体现在基础指令与专业指令两项核心能力上。

- gemini25 与 外部模型XX 处于第二梯队：其中 gemini25 在用户画像维度领先，外部模型XX 在补充指令维度相对更强。
- qwen3-vl 整体落后：四个维度得分均为最低，与前三名存在明显差距，属于当前最主要的提升空间来源。

我们将四种评测模型在同一批样本上的评分取平均值作为“基准分”（近似真实标签），并分别计算每个评测模型输出与该基准分之间的相关性；相关性最高的一组评测结果被选为后续分析与对比的最优评测口径。在该设定下，各评测模型的评测准确性（相关性）排序为：gemini25 > gpt51 > qwen3_vl > 外部模型XX。

评测方式	PLCC相关性
gemini25	0.962
gpt51	0.931
qwen3_vl	0.925
外部模型XX	0.896

问题分析

在对全部 960 条样本进行问题聚合后，我们识别出三类出现频率最高、影响最广的共性问题，它们几乎贯穿所有模型，是当前搭配 Agent 的主要瓶颈：

- 无法识别已有家具 → 导致重复推荐（出现频率最高）：模型经常忽略输入图片或文本中“已有家具”的信息，进而重复推荐床、沙发、收纳柜等，造成搭配方案与实际空间不符。
- 未抓住用户核心需求 → 输出跑题：部分模型在多维度需求输入下无法正确抓住“真正想解决的问题”，例如用户强调“光线与阅读区”，模型却转向推荐风格类饰品。
- 推荐过量无关商品 → 输出过度：在不需要大量补充家具的场景中，模型仍会给出超出需求的商品列表，增加成本、破坏空间节奏。

这三类问题揭示了当前大模型在多模态理解、需求抽取与约束控制方面的关键短板，也为后续的优化方向提供了明确指引。

评测准确率

从搭配评测集中随机抽取 100 条样本，我们对所有维度的自动评测结果进行了人工复核，并计算了大模型评估的整体准确率。准确率 =（评测维度总数 − 误判数）/ 评测维度总数 =（1927

– 156）/ 1927 = 91.90%。说明大模型在导购场景下已具备较高的一致性，可用于高质量的自动化标注与评估。

在总计 156 条人工确认的问题条目中（按“维度 → 修改后内容 → 原因”计数），误判主要集中于以下维度：尺寸、类目、房间结构、人群偏好、商品偏好、场景偏好。进一步分析后，我们将这些误判归纳为六大类问题：

- 重复/冲突搭配：未识别已有家具，导致方案重复推荐；或在同一方案内部出现类目冲突，如两张床、两张书桌等。
- 类目/功能缺失：用户明确提出的关键需求未被覆盖，例如收纳、遮光隔音、学习/画画区、观影区等功能要素缺失。
- 智能化需求未响应：智能照明、控温控湿、空气净化、网络覆盖、智能观影等需求未体现或响应不完整。
- 尺寸不合理：家具尺度与房间大小、家庭成员数量或活动场景不匹配，如床宽度不合适、餐桌人数不符等。
- 人群/画像不匹配：亲子、新生儿、老人、宠物、学生等典型人群偏好识别不足，导致推荐与用户画像不符。
- 场景定位或审美偏差：房间类型判断错误（如将亲子空间误作卧室），或出现风格不统一、色彩冲突、预算信息缺失等问题。

上述分析不仅明确了大模型在自动化评测中的误判来源，也为后续优化评审模型、补齐场景理解能力和提升搭配 Agent 的整体表现提供了方向。



在本次工作中，我们以导购搭配 Agent 为对象，构建了从 Benchmark、结构化需求拆解，到 LLM-as-a-judge 评分与自动化报告的完整评估链路。通过标准化的数据集与统一的多维度评价体系，我们能够以可量化、可复现的方式，对不同大模型基座的搭配能力进行横向比较，并在高频迭代下持续追踪能力变化。

从量化结果来看，目前四种基座模型呈现出明显的分层格局：gpt51 综合表现最佳，相比 qwen3-vl 提升 16.4%；gemini25 与 外部模型XX 属于第二梯队；qwen3-vl 相对落后。此外，在四个评测模型中，gemini25 与多评测方式的平均基准最为一致，可作为当前最稳定的自动化评审模型。

问题分析进一步揭示了大模型在真实搭配任务中的核心瓶颈：无法识别已有家具、难以抓住用户核心需求、以及过度生成无关商品。这些问题相对独立，又贯穿所有模型，是当前多模态理

解、需求抽取、空间推断和约束控制方面最需要突破的方向。

本次评估体系的价值，在于提供了一种可持续运行的“能力量化方法”。通过自动化评测流水线，我们不仅能够快速判断版本提升或退化，也能定位具体弱项，为训练数据增补、模型优化、工具链路改造提供依据。同时，随着更多场景的加入（如风格检测、动线规划、预算控制等），评估体系也能持续扩展，形成更丰富、更贴近真实业务的能力刻画。

未来，我们计划将评测范围延伸到更复杂的空间设计任务，引入更多多模态输入形式，并探索基于人机协同反馈的实时评测方式。希望这套体系能够在更大规模、更通用的 Agent 评估中发挥作用，为行业提供一套稳定可靠的参考框架。我们团队正在进行家装行业AIGC的相关研发，以提高家装AI模型的效果。我们希望与对此方向感兴趣的同学一起探讨和交流。

05 参考文献

- 《WideSearch》https://widesearch-seed.github.io/
- 《VisualAgentBench》https://github.com/THUDM/VisualAgentBench
- 《DeepResearch Bench》https://deepresearch-bench.github.io/

06 团队介绍

本文作者阿元，来自淘天集团 – 场景智能技术团队。一支专注于通过 AI 和 3D 技术驱动商业创新的技术团队，依托大淘宝丰富的业务形态和海量的用户、数据，致力于为消费者提供创新的场景化导购体验，为商家提供高效的场景化内容创作工具，为淘宝打造围绕家的场景的第一消费入口。我们不断探索并实践新的技术，通过持续的技术创新和突破，创新用户导购体验，提升商家内容生产力，让用户享受更好的消费体验，让商家更高效、低成本地经营。

大淘宝技术
大淘宝技术官方账号
967篇原创内容
公众号

阅读 8265

留言

写留言

还没有留言，来写首评