腾讯AngelSlim重磅升级！面向全模态的大模型压缩算法工具包，推理速度飙升 1.8倍！

腾讯程序员 腾讯技术工程 Jan 13, 2026, 12:56 AM 广东 11 listened



近年来，大模型正从能力竞赛走向工程落地，推理阶段的成本、时延与稳定性逐渐成为制约规模化应用的核心因素。在长上下文、高并发与多模态场景下，解码过程受限于算力与显存带宽，单纯依赖模型压缩或硬件堆叠的优化路径正逼近边际收益，促使业界重新审视推理机制本身的优化空间。

在这一背景下，投机采样（Speculative Decoding）通过“小模型多步生成 + 大模型并行验证”，在保证生成质量的前提下减少大模型的有效前向计算。腾讯混元近期升级的 AngelSlim 围绕 Eagle3 投机采样训练范式 构建系统化实现，将投机采样提升为可训练、可迁移的加速能力，并扩展至 LLM、视觉语言与语音等多模态场景，在实际部署中最高可实现 1.9× 的推理加速，为多模态 AI 的实时化与规模化应用奠定基础。

一、AngelSlim +投机采样

投机采样是一种通过**小模型多步预测 + 大模型一步验证**的推理加速技术，其核心思想是：使用一个轻量级的草稿模型生成多个候选 token，由目标模型对候选结果进行并行验证是否接受，以此来并行解码加速，在有效利用大模型解码阶段的算力冗余，提升推理吞吐并降低单请求延迟。

AngelSlim是一款集成了包括量化、投机采样等压缩算法，面向全模态的大模型压缩算法工具包。此次对投机采样训练进行了重磅升级，支持了大语言、多模态理解、语音等不同模态大模型投机采样草稿模型训练能力。

AngelSlim 以“**Eagle3训练即部署**”为设计核心，提供从数据处理、模型封装到投机采样算法训练的完整链路，帮助开发在不侵入现有模型结构的前提下，显著降低推理时延与计算成本，各模态、各类大模型加速可达**1.4-1.9倍**。

模态	开源模型	模型尺寸	Eagle3训练支持	vLLM部署支持	加速情况
文生文	Tencent HY	1.8B/4B/7B	✅	✅	1.6x
	Qwen3	1.7B/4B/8B/14B/32B/30B-A3B	✅	✅	1.7x
多模态理解	HunyuanOCR	1B	✅	✅	1.6x
	Qwen3-VL	2B/4B/30B-A3B	✅	✅	1.4x-1.9x
语音	Qwen2Audio	7B	✅	✅	1.9x
	Fun-CosyVoice3	0.5B	✅	🚧	1.6x

Github开源地址：https://github.com/Tencent/AngelSlim

二、核心亮点

1.覆盖从文生文、多模态理解到语音的全模态投机采样训练

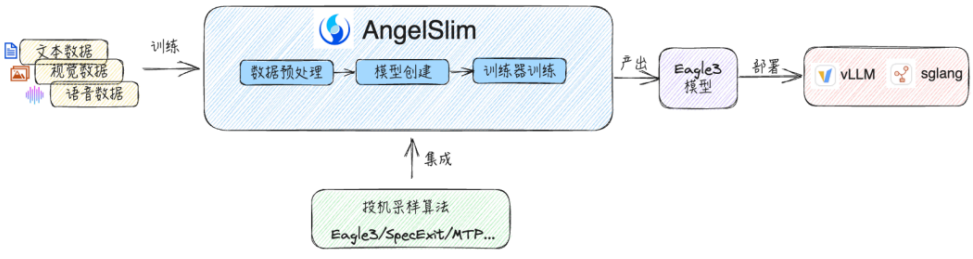
AngelSlim是一个从设计之初就支持全模态的投机采样训练框架，通过统一的训练接口，不同模态之间共享核心算法与工程能力，避免

重复造轮子。

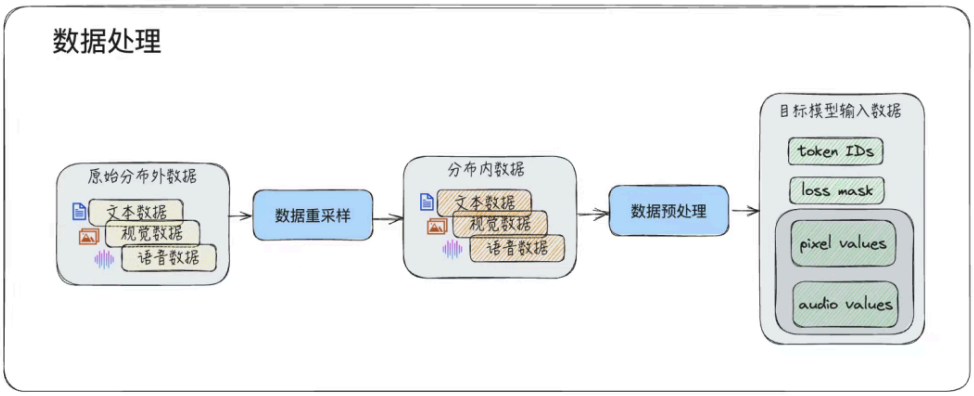
2.面向部署

AngelSlim 并不止步于“能训”，而是强调训出来就能用。AngelSlim训练产出的模型可以无缝用于vLLM/Sglang等框架进行部署。

三、核心训练组件解析



1.数据处理模块



数据处理模块为投机采样训练多个模态提供稳定、可复用的数据基础，主要包括：

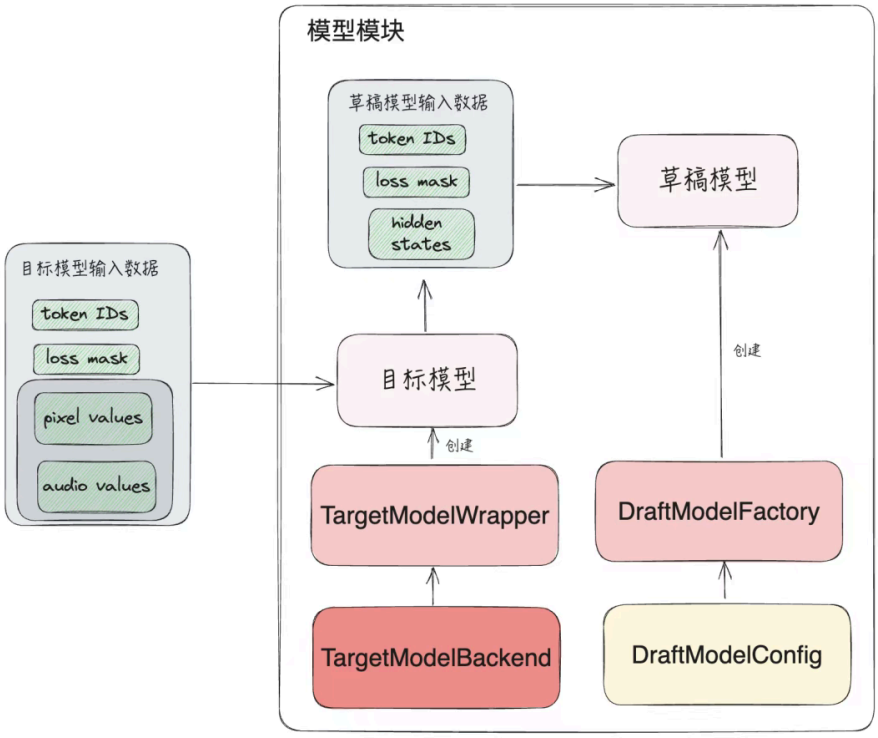
a. 数据重采样：针对分布外数据集重新采样，生成分布内数据集用以训练。

b. 数据预处理：

i. 统一不同模态的数据格式，将文本、图像、音频等输入标准化处理成token ids和loss mask。

ii. 草稿模型裁剪词表的映射。

c. 隐藏特征提取：根据处理好的token ids获取对应的隐藏特征。



2.模型模块

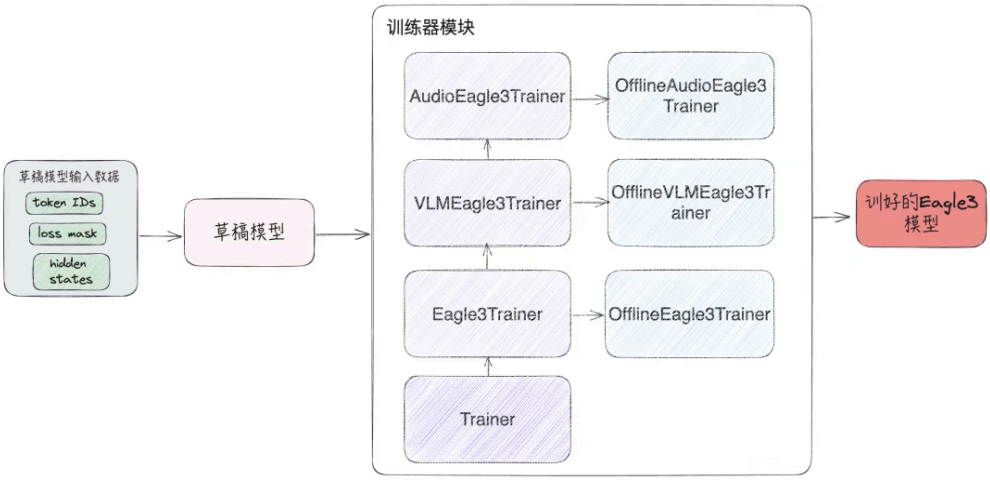
模型模块是 AngelSlim 实现高度扩展性的关键。

a.统一的 TargetModel 接口

i. AngelSlim提供统一的TargetModel接口，包括模型加载与权重管理、前向计算、中间层 / 隐状态特征提取等抽象方法；

b. 低成本扩展新的模型后端

ii. 对于新的模型架构或后端，用户只需实现 TargetModel 中定义的抽象方法即可完成模型注册并接入训练流程，无需修改训练器或核心算法代码。这一设计极大降低了对新模型、新模态的适配成本。



3.训练器模块

a.训练器针对Eagle3算法特点设计了两种训练模式：在线训练和离线训练。在线与离线训练的区别在于是否预先生成并存好全量数据的hidden states。在线训练适合小尺寸模型或显存足够的场景，离线训练适合大尺寸模型、低显存高磁盘空间机器。

b.训练器实现封装了Eagle3等投机采样算法训练的关键逻辑：

i. 训练时测试（training-time-test）：训练时模拟Eagle3模型多步生成过程，让Eagle3模型看到并学习使用自己的预测。

c.训练器原生支持断点续训能力，完整保存并恢复：

i.草稿模型参数

ii.Optimizer / LR Scheduler 状态以及训练进度

四、实践与部署

1.快速开始

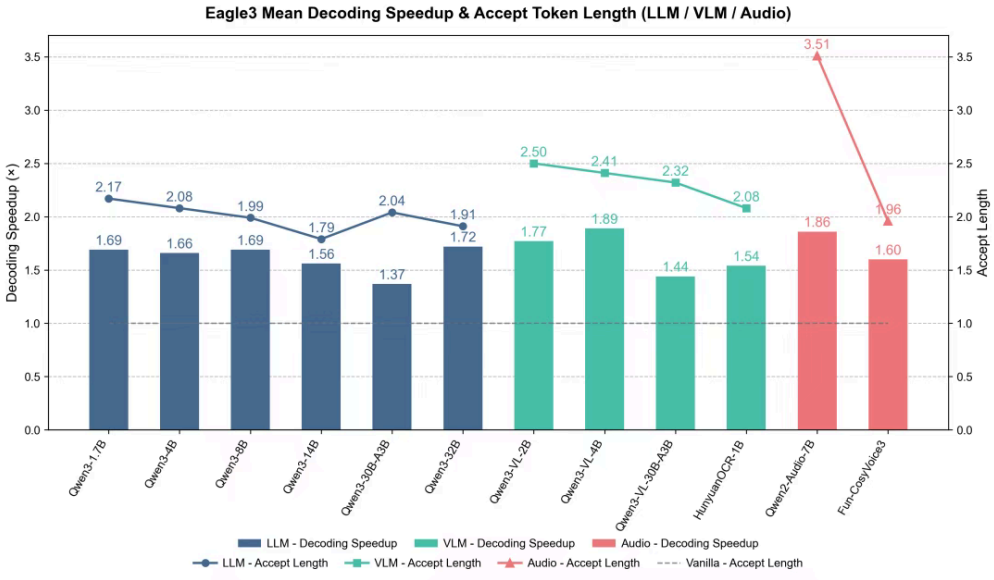
当安装好AngelSlim后，进入AngelSlim根目录按照如下命令可以快速开始Eagle3的训练：

```
# 启动vLLM服务
bash scripts/speculative/run_vllm_server.sh
# 生成训练数据
bash scripts/speculative/generate_data_for_target_model.sh
# 开始在线训练
bash scripts/speculative/train_eagle3_online.sh
```

其中前两条命令是准备数据，对训练数据进行重采样，生成目标模型分布内的数据。这一步是可选项，如果训练数据已经是来自目标模型的SFT数据或自身生成的数据，这一步可跳过。对Eagle3模型进行训练直接执行最后一条命令即可。并且我们提供了全面的多模态模型Eagle3 训练与部署指南，支持LLM / VLM / Audio（ASR & TTS），详见文档：LLM | VLM | Audio(ASR) | Audio(TTS)。

2.AngelSlim训练模型的加速表现

我们使用vLLM在代码、数学、指令跟随、文本生成、多模态理解等任务上评测了AngelSlim所训练的Eagle3模型，设置num_speculative_tokens=2 or 4下我们所训的模型接收长度可达1.8–3.5，最高加速可达1.4–1.9倍。



3.代码和模型链接

a. AngelSlim代码Github开源仓库：

https://github.com/Tencent/AngelSlim

b. Hugging–Face Eagle3模型与权重：

https://huggingface.co/collections/AngelSlim/eagle3

五、未来计划

在未来规划中，工具化方面，我们计划支持基于 vLLM 的离线 hidden states 生成，以进一步降低数据构建与训练成本，并通过系统性的训练加速优化提升整体训练效率；算法创新方面，将探索多模态理解与语音输入信息在Eagle3 模型中的深度融合，统一建模文本、视觉与语音特征，拓展投机采样在全模态场景下的适用性与加速潜力。



腾讯技术工程

腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。

688篇原创内容

公众号



阅读 3519

留言

写留言

还没有留言，来写首评