推理速度提升5倍+：腾讯TRS团队首创列表级生成式推荐HiGR

原创 腾讯程序员 腾讯技术工程 2026年2月6日 01:35 中国香港 10人



作者：李裕东 庞雲升 刘子健

导语

在信息流、短视频、电商等推荐场景中，用户真正感知的并非某一条内容的相关性，而是一整屏列表带来的「整体体验」。 为此，腾讯TRS团队在论文《HiGR: Efficient Generative Slate Recommendation via Hierarchical Planning and Multi-Objective Preference Alignment》中提出分层规划的端到端生成式推荐框架HiGR，将传统的级联推荐范式升级为「编码—规划—生成—对齐」的一体化新范式

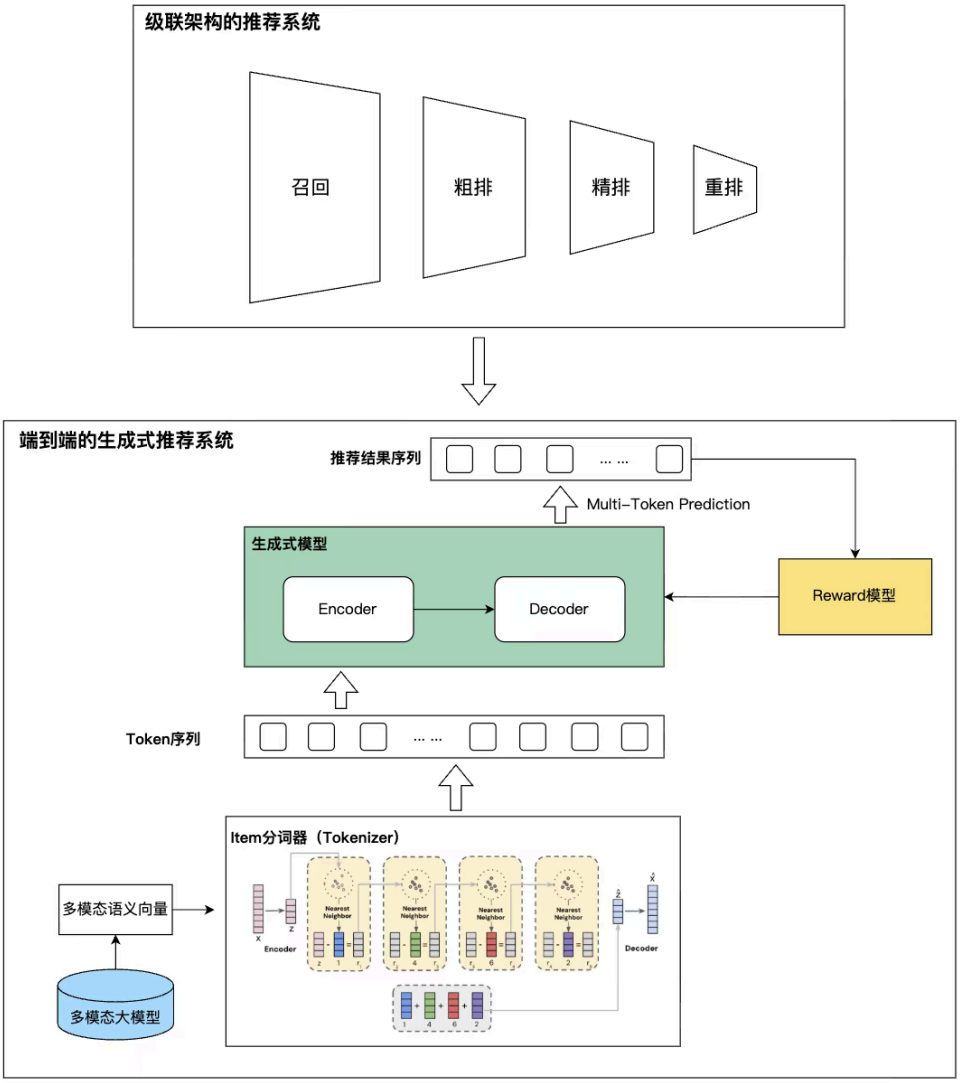
- 先做**列表级意图规划**
- 再做**物料级生成解码**
- 最后通过**列表级偏好对齐**，直接面向**隐式反馈**优化整列质量

该方法已在真实业务场景验证了显著收益：

- 离线推荐质量相对 **SOTA 提升超过 10%**
- 推理速度提升 **5 倍以上**
- 线上小流量 **A/B 实验**验证：用户观看时长与消费深度均有显著增长

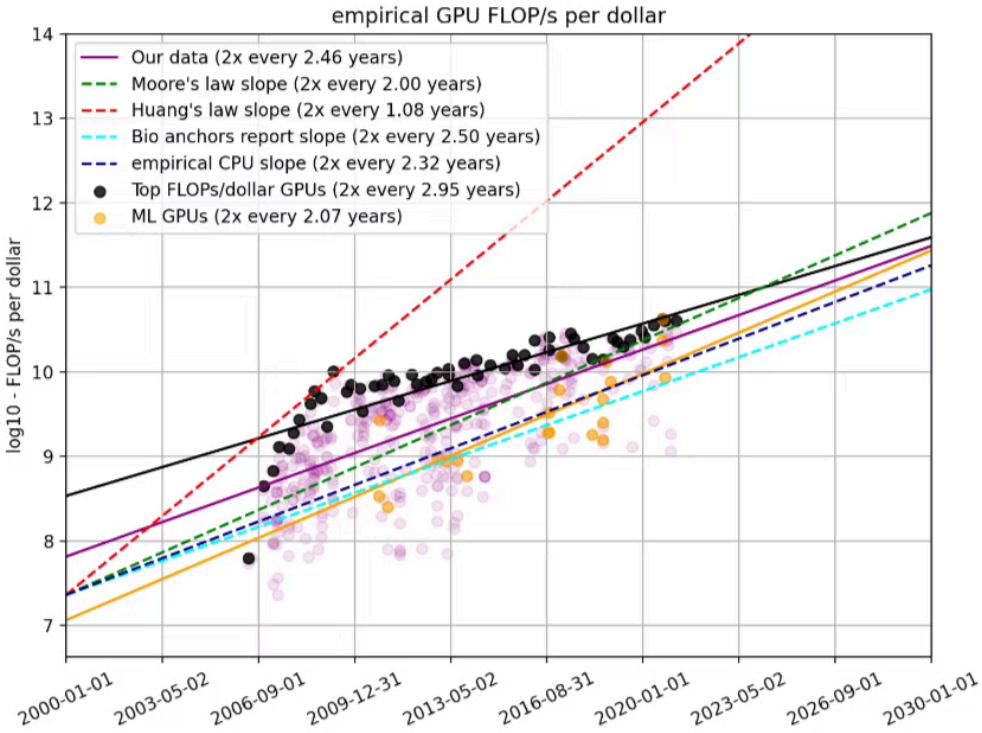
HiGR首创基于**“编码—规划—生成—对齐”**的列表级端到端生成式推荐一体化范式，为业务提供了一条**高性能、可规模化落地**的生成式推荐升级路径。

1. 为什么“列表级端到端”是下一代推荐的关键



传统的推荐系统通常采用级联架构（召回 -> 粗排 -> 精排 -> 重排），虽然这种漏斗式结构在基于CPU的计算效率上具有优势，但存在三个核心痛点：

- **目标不一致**： 级联推荐架构下，召回、粗排、精排这些层的模型都在优化点对点（Pointwise）的准确率，而用户最终消费的是一个列表（Listwise），局部最优并不等于全局最优。
- **误差累积**： 级联推荐架构下，上游模块的偏差会层层传递，导致重排阶段只能在有限且可能已经“偏航”的候选中进行微调。
- **GPU算力利用不足**： 如下图所示，单位成本下GPU计算性能每年在翻倍提升，未来确定性的趋势是GPU性能还会持续提升，而传统推荐模型的算力利用率（MFU）普遍偏低（大多不到1%）；相比之下，大语言模型领域已验证更高 MFU 的工程可达性，LLM的模型算力利用率（MFU）可以达到70%，推荐系统仍有显著“算力红利”空间。

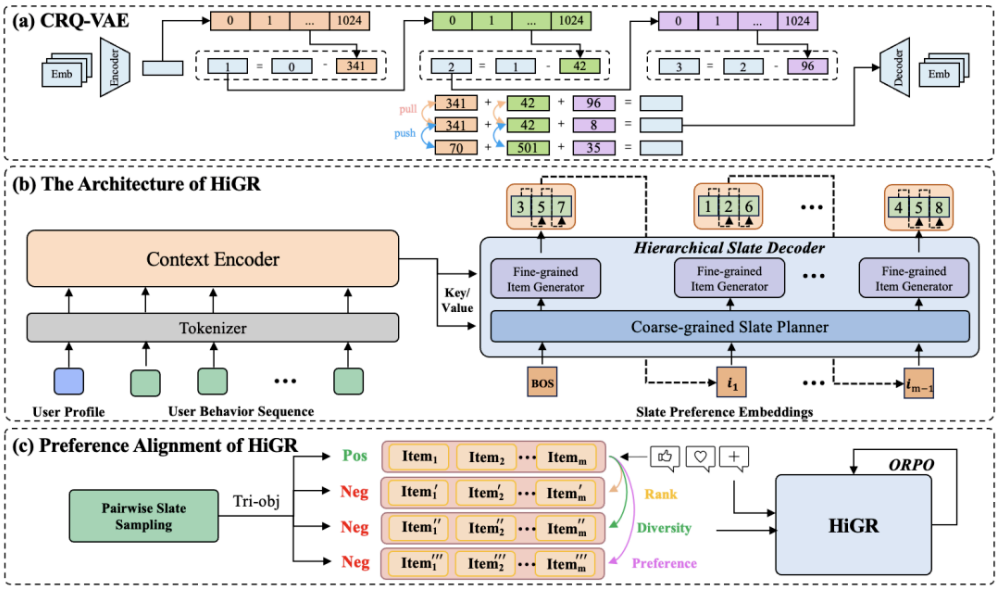


因此，业界都在积极探索端到端生成式推荐范式（比如OneRec，OneRec-Think等），期望进一步突破推荐模型的天花板，但当前大多数生成式推荐的研究还是基于NTP (Next Token Prediction) 范式，即像语言模型一样逐个 Token 地预测物料，这种方式在推荐场景下面临两个挑战：

- 推理效率受限： 自回归逐Token生成在推荐场景中面临严峻的延迟瓶颈。以生成一个包含10个物料的推荐列表为例，若每个物料ID需要4个Token表示，则需要40步自回归解码，难以满足在线推荐的毫秒级响应要求。
- 缺乏全局规划： NTP范式本质上仍是Token级别的交叉熵损失，与用户对整个推荐列表的隐式反馈（如停留时长、滑动深度）之间存在Gap，难以直接优化列表级用户体验。

为了突破这些瓶颈，我们提出了分层规划的端到端生成式推荐框架HiGR，其核心思路是从“逐 Token 填充”转向“分层规划与整列对齐”，先在列表层做“意图规划”（Plan），再在物料层做“生成解码”（Generate），最后用“列表级偏好对齐”（Align）把整列质量直接对齐业务指标。

2. HiGR一体化框架：从“编码—规划—生成—对齐”闭环优化整列质量



如上图所示，HiGR 框架主要包含三个核心模块：

- **语义编码**：提出 CRQ-VAE，解决前缀 ID 纠缠与残差坍塌
  针对 RQ-VAE 存在的 ID 纠缠和残差坍塌的问题，CRQ-VAE 引入对比学习和全局量化约束：
  - **前缀对比学习**：设计 InfoNCE loss 强制前缀 ID 成为语义锚点，实现“前缀聚类，后缀区分”，确保分层规划器能准确捕捉意图
  - **全局量化损失**：构造全局损失替代逐层累计损失，深层码本也能承载有效信息，保证语义 ID 表达的一致性
- **分层规划**：提出 Hierarchical Slate Decoding（HSD）先“定大局”，再“填细节”
  为了解决自回归生成的延迟问题并引入全局视野，HiGR 将生成过程解耦为两步：
  - **Layer 1：列表级意图规划（Corase-grained Slate Planner）**：模型首先不直接预测具体的视频 ID，而是根据用户的交互历史，生成一个“列表意图蓝图”(Slate Intent)。
  - **Layer 2：物料级生成解码（Fine-grained Item Generator）**：在确定的“列表意图蓝图”指导下，模型并行地填充具体的物料语义 ID。
- **列表级偏好对齐（Listwise Preference Alignment）**：用隐式反馈“直接优化整列体验”
  为了突破预训练“只能拟合分布，无法区分优劣”的局限，同时解决当前强化学习工业落地瓶颈，HiGR 采用了 ORPO 算法：
  - **免参考模型**：结合 SFT 和 Odds Ratio 损失，在单模型架构下实现偏好对齐，大幅降低显存占用和训练延时
  - **三元目标样本构造**：通过构造针对性样本对，同步优化保序性、真兴趣和列表多样性

2.1语义编码：CRQ-VAE 如何解决“语义ID纠缠”并让前缀可控

在生成式推荐中，我们物品ID化（tokenization）的质量直接决定了后续生成模型的上限。传统的RQ-VAE模型虽然能降低词表大小，但在工业落地中暴露出了“前缀语义纠缠”与“残差坍塌”的两大核心问题，导致生成模型难以精准把控推荐意图。

2.1.1 痛点深入：为什么传统的Semantic ID不好用？

- **ID纠缠**
  在标准RQ-VAE中，量化仅由重构误差驱动。这导致生成的Codebook缺乏语义拓扑结构——前缀相同不一定代表类别相同，而前缀不同的物品却可能非常相似。对于分层规划器来说，如果ID不具有明确的语义聚类特性，它就无法准确地规划出高层的“意图”。

- **残差坍塌**
  随着量化层数迭代，后续层级的残差向量往往趋近于零，导致深层码本实际上不承载信息，退化为噪声，浪费了编码容量。

2.1.2 核心方法：基于对比学习的残差量化编解码器（CRQ-VAE）

我们引入对比学习和全局量化约束，强制让语义ID的前缀成为可靠的语义锚点。

- **前缀对比约束**
  我们在量化器中的前D-1层引入InfoNCE loss，选择语义相似的item或共现率高的item作为正样本，选择批次内其他随机样本作为负样本。让前缀ID负责“聚类”，将相似物品拉到同一个ID前缀下；让最后一层ID负责“区分”，保持对具体物品的细粒度辨识能力。完美契合我们的“先规划，后生成”的分层策略。

- **全局量化损失**
  不同于传统逐层累计的量化损失，我们针对量化器前后的编码向量和量化重构向量构造全局损失，有效抵抗了残差消失现象，迫使深层码本必须承载有效信息，显著提升了ID的表达一致性。

2.2分层解码：HSD 如何先“规划”列表偏好再“生成”具体内容

2.2.1 痛点深入：“平铺”式的解码器为什么不是列表推荐的最优解？

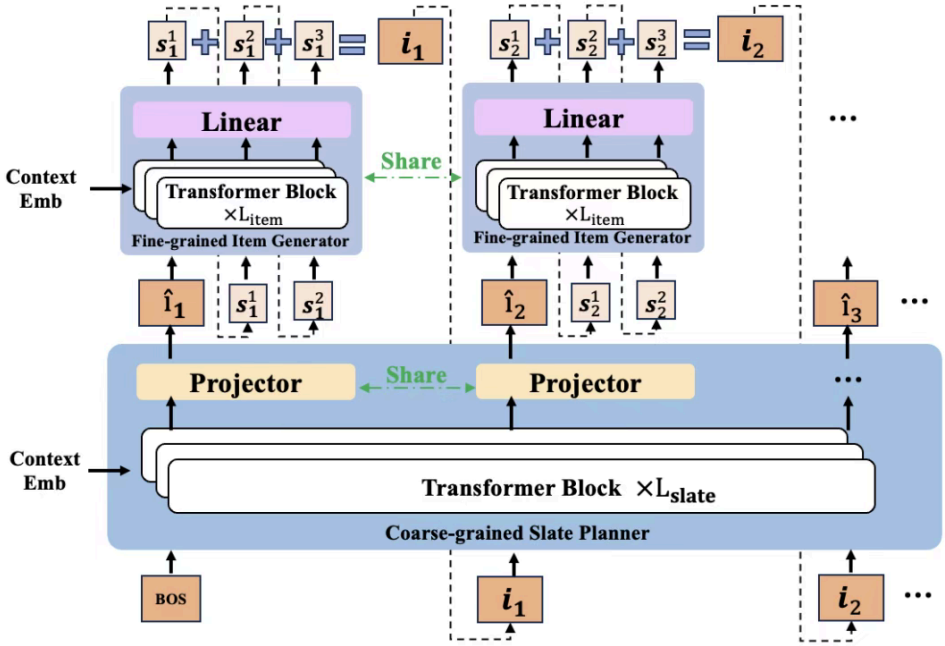
- **推理耗时长**
  在推理耗时极为敏感的推荐场景，传统的“平铺”式解码器，即把SID作为token，逐SID地生成列表难以满足耗时要求，因为推理长度为M的列表需要推理M*N次（一个item由N位SID表示），使得传统“平铺”式解码器几乎不可能在实际场景中落地。

- **难以建模item内和item间的关系**
  推荐场景中的SID token序列不同于语言模型中语义token序列，其有着明确的边界以及层级关系，如下图所示：假设3位SID构成一个item（<a_3><b_6><c_2>；<a_5><b_4><c_7>），则<c_2>和<a_5>有着明确的边界，即<c_3>属于第一个item，<a_5>属于第二个item；<a_3>位于item的第一位，代表着对item更粗粒度的刻画，<b_6>位于item的第二位，代表对item较细粒度的刻画。传统的“平铺式”解码器更适合建模没有明显边界和层级关系的文本语义token，但却难以捕获推荐场景中item内和item间SID的联系。



LLM中的语义token　　生成式推荐中的SID token

2.2.2 核心方案：基于分层解码的先规划，再生成方案



如图所示，基于分层解码的列表推荐方案将列表级偏好规划与具体的item SID序列生成相解耦，通过先规划，再生成的方式逐步生成列表序列。
具体来说，我们首先采用了一个较重的多层Transformer架构作为Coarse-grained Slate Planner，用于从item的粒度规划列表内用户对每个item的偏好，得到一个用户偏好embedding序列，经过投影映射后，每个item的偏好embedding作为较轻量的Fine-grained Item Generator的起始输入，替换常用的BOS token，指导该item生成具体的SID序列。

通过分层，用一个统一的Coarse-grained Slate Planner来规划整个列表内各item的偏好，再对每个item用Fine-grained Item Generator来生成，实现了规划和生成的解耦，对列表内待解码的某个SID token，其不仅能参考该item内已生成的前缀SID序列，还能参考该列表内已生成的完整前序item表示，提升了模型对item内和item间的建模能力。

相比传统的“平铺”式解码器将整个列表的SID序列都经过一个重量级的Transformer架构，分层解码只需将抽象后的item偏好序列经过较重的Transformer层，而将item解码成SID序列时采用了轻量级的Transformer架构，减少了推理耗时。
此外，在推理时，beam search只在每个item内累积logits概率，而不在整个列表累积，进一步降低了推理耗时。

2.3列表级偏好对齐：ORPO 如何用隐式反馈“直接优化整列体验”

监督微调（SFT）只能让模型学会拟合历史曝光分布，即像传统推荐系统那样推荐，但无法学会“什么是更好的推荐”。为了让模型真正理解用户的隐式偏好，我们需要引入偏好对齐技术。

2.3.1 痛点深入：为什么不用最经典的DPO和最火的GRPO?

在生成式推荐的工业级落地中，直接照搬LLM领域的对齐算法面临显著的效率收益瓶颈：

- **DPO（Direct Preference Optimization）**
  - 机制痛点：DPO的损失包含一项

$$\pi_\theta(y|x)/\pi_{\text{ref}}(y|x)$$

这意味着训练过程中，必须始终加载冻结参数的参考模型进行同步推理。

- 工业阻碍：推荐模型的参数量虽然不如LLM巨大，但是数据量极大。参考模型的存在导致显存占用翻倍，训练吞吐量减半。在小时级更新的推荐业务中，这种训练延时是不可接受的。

- **GRPO（Group Relative Policy Optimization）**
  - 机制痛点：Deepseek提出的强化学习方法GRPO，通过对同一prompt采样G组输出，计算组内相对优势，从而省去了critic model。其核心假设是环境能对每一次采样给予即时、准确的反馈。
  - 工业阻碍：GRPO在数据、代码任务中有效，是因为有明确的答案检查器。但在推荐场景中，离线训练无法实时把生成的G个推荐列表推给用户，在没有高保真用户模拟器的情况下，GRPO很难直接应用于离线推理策略学习。此外，列表序列推理是token-by-token生成的，生成G组完整列表极其耗时，会导致训练时长爆炸。

2.3.2 核心方案：列表级的多目标ORPO（Odds Ratio Reference Optimization）偏好对齐

1.损失函数设计：

将传统的监督微调损失和Odds Ratio损失结合

$$\mathcal{L}_{\text{ORPO}} = \mathcal{L}_{\text{SFT}} + \lambda \mathcal{L}_{\text{Odds}}$$

$$\mathcal{L}_{\text{SFT}} = -\log \pi_\theta(y_t^+ | x, y_{i<t}^+)$$

$$\mathcal{L}_{\text{Odds}} = -\log \sigma \left(\sum_{t=1}^{T} \log \left(\frac{\pi_\theta(y_t^+ | x, y_{i<t}^+)}{1 - \pi_\theta(y_t^+ | x, y_{i<t}^+)} \right) - \log \left(\frac{\pi_\theta(y_t^- | x, y_{i<t}^-)}{1 - \pi_\theta(y_t^- | x, y_{i<t}^-)} \right) \right)$$

- 直观理解：SFT负责让模型学习传统推荐的，而Odds Ratio损失让优势列表的生成赔率显著高于劣质列表。
- 工程收益：这种单模型、单向传播的架构，训练速度与普通SFT几乎持平，显存占用大大降低。

三元目标”样本构造策略：
为了解决推荐系统既要准、又要好、还要多样的复杂需求，我们在构造偏好对时采用了特殊的正负采样策略：

- 正样本：用户真实观看且高停留时长的序列，按照反馈强度重排
- 负样本：
  - Ranking Fidelity（保序性）：将重排样本随机打乱顺序。让模型学会“把好东西率先推出来”
  - Genuine Interest（真兴趣）：替换为用户曝光未点击或负反馈的物品。让模型学会剔除“标题党”和无效曝光
  - Slate Diversity（列表多样性）：取正样本中第一个物品作为锚点，后续全部填充与锚点相似的top-k物品。让模型学会惩罚“信息茧房”，主动追求多样性

3.实验效果与线上收益

为了验证HiGR在工业级场景下的有效性，我们进行了严格的离线评估和线上A/B测试，以下所有实验数据来自PCG实际内容推荐场景。

3.1 离线评估

类型	方法	Impressions		Effective Views		NDCG
		hit@5	recall@5	hit@5	recall@5	
传统列表推荐	ListCVAE	8.57%	1.78%	5.71%	1.17%	1.86%
判别式推荐	BertRec	9.11%	1.87%	6.32%	1.29%	2.01%
	SASRec	10.57%	2.18%	7.00%	1.43%	2.43%
生成式推荐	TIGER	18.12%	3.83%	12.04%	2.49%	4.06%
	HSTU	22.81%	5.06%	14.87%	3.10%	4.92%
	OneRec	24.38%	5.77%	16.03%	3.67%	5.89%
生成式列表推荐	HiGR-w/o RL-25M	26.41%	6.12%	18.10%	3.95%	6.31%
	HiGR-w/o RL-100M	29.94%	7.21%	20.12%	4.65%	7.53%
	HiGR-100M	31.63%	7.60%	21.45%	4.95%	8.31%

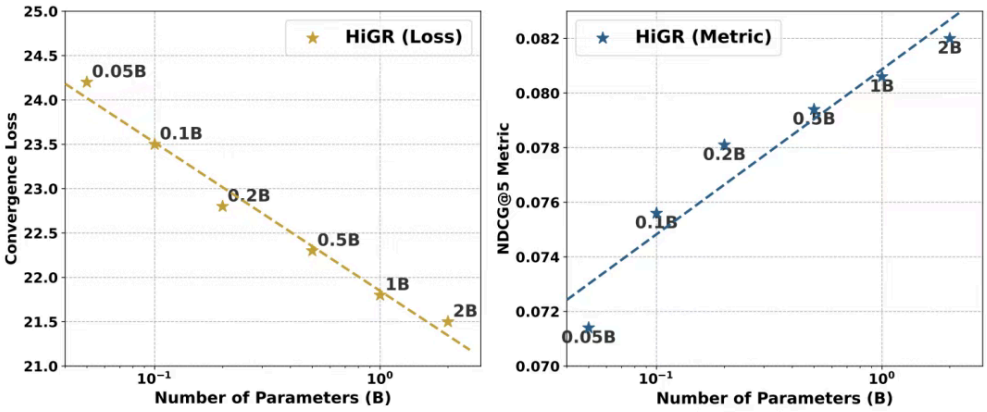
上表展示了HiGR在离线评估中的效果，与传统列表推荐方法和判别式模型相比，HiGR体现了生成式推荐模型的优越性，大幅优于传统模型；与最近提出的经典生成式推荐模型相比，得益于HiGR针对列表推荐的独特优化，HiGR也取得了更好的效果。

3.2 线上A/B测试收益

业务指标	提升幅度	业务价值解读
Avg. Watch Time	+1.22%	用户黏性提升：列表整体的相关性和吸引力更强，用户看得更久
Avg. Stay Time	+1.03%	大盘活跃度提升：用户在feed流的总耗时增加
Avg. Video Views	+1.73%	消费深度提升：内容多样性变好，激发用户的有效滑动和点击
Avg. Request Count	+1.57%	交互频率提升：更好的列表节奏减少用户的跳出率

我们将HiGR部署到实际场景的推荐系统中进行A/B实验，与当前的基线模型相比，在播放vv，播放时长和观看时长上均取得了正向显著收益，进一步证明HiGR的有效性。

3.3 Scaling Law实验

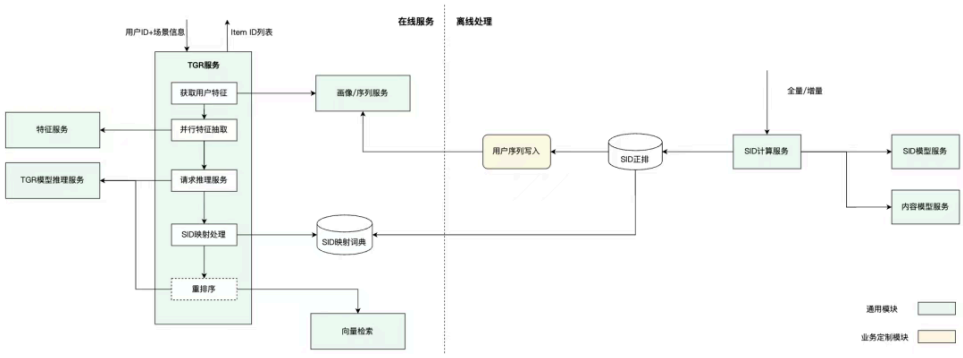


图：HiGR模型在收敛loss和NDCG度量指标上的扩展性

如上图所示，模型的收敛损失值随参数量呈现显著的幂律下降趋势；离线指标NDCG@5同样呈现出对数线性增长的趋势。并且斜率保持稳定，没有出现边际效应递减的瓶颈。证明HiGR具有可扩展性，性能收益符合预期。

4. HiGR一体化落地方案

4.1服务架构



如上图所示，HiGR模型部署在TRS的TGR服务，集成了画像、实时序列、模型推理、向量检索等一整套推荐基础服务，具有以下核心亮点：

1）支持并行化特征抽：支持万量级的序列特征抽取，可实现提升2倍以上速度提升。

2）跨场景实时序列融合：支持跨场景的用户实时行为融合与压缩。

3）高性能模型推理：基于无量3.0框架，相比原生框架可实现10倍以上加速。

4）高性能近线计算：支持基于 LLM 的“快/慢思考”两种计算模式（规划中）

4.2推理加速

为进一步降低训练和推理成本，我们还从多个角度对HiGR进行了系统性的工程优化，包括采用大语言模型中常用的加速手段，如Flash Attention，KV Cache等。此外，我们在实际落地中发现Beam Search仍是耗时最多的几个环节之一，因此我们也优化了Beam Search的整个流程，以及优化了整体的代码实现，减少不必要的重复计算和优化耗时操作，综合所有的优化手段，将推理速度提高了5倍以上。

加速方法	训练加速	推理加速	加速效果
Flash Attention	✅	✅	强，2-3倍提速
KV Cache	❌	✅	较弱
Memory Beam	❌	✅	强，2-3倍提速
其他工程优化	✅	✅	较强，1倍提速

1）Flash Attention：LLM中常见的加速手段：通过分块计算，极大减少了 GPU 显存（HBM）与片上高速缓存（SRAM）之间的数据读写次数（IO），从而突破显存带宽瓶颈，显著提升长序列推理的计算速度，在HiGR落地中加速效果明显。

2）KV Cache：通过缓存历史 Token 的 Key 和 Value 状态，使得模型在自回归生成新 Token 时无需重复计算前文所有 Token 的参数，避免了部分冗余计算，降低解码阶段的延迟。但由于推荐场景中的序列长度远不及LLM中的序列长度，推理加速效果不如flash attention明显。

3）Memory Beam：利用GPU的GEMM并行计算能力，优化beam search的实现流程，避免了当beam width很大时，需要将序列复制beam width份输入到模型中带来的额外巨大计算量，在HiGR落地中加速效果明显。

4）其他工程优化：优化具体代码实现中的不合理实现，避免重复计算，优化耗时操作。

4.3如何接入HiGR方案

目前提供两种接入方式：

1）全链路托管模式，提供一站式服务。

适用场景：业务方希望快速获得生成式推荐能力，减少开发成本。

接入方式：业务方仅需按规范提供离线数据表，并通过 API 调用 TGR 在线推　理服务即可获取推荐结果。

2）模块化组件接入，仅接入HiGR模型训练和推理、特征服务或实时序列服务。

适用场景：业务方已有成熟的推荐链路，仅需增强生成式推荐能力。

接入方式：支持按需接入 HiGR 核心组件，包括模型训练与推理算子、特征　抽取服务或实时序列服务，通过插件化方式融入现有架构。

5. 总结与展望

HiGR 针对传统级联推荐架构中**目标割裂**，以及现有生成式推荐**推理延迟高、缺乏全局规划**等痛点，提出了一套 **“编码—规划—生成—对齐”** 的完整解决方案：

- **CRQ-VAE**：提升语义 ID 的可控性与一致性；
- **HSD**：通过“先规划，后生成”的分层解码，降低在线延迟并增强列表建模；
- **ORPO**：用隐式反馈实现列表级偏好对齐，在**不引入参考模型**的前提下兼顾训练效率与效果。

该方案不仅在离线指标和小流量实验上取得了显著收益，还配合**Flash Attention、Memory Beam**等系统工程优化实现了**5倍+推理加速**，验证了其在工业级高并发场景落地的可行性。

HiGR只是我们在生成式推荐探索落地的开端，我们正在积极探索“快慢思考”推理、全域通用的推荐基础模型、对话式推荐等方向，未来会基于 LLM 推理能力进一步提升推荐效果的天花板。

招聘信息

腾讯TRS团队正在招聘「生成式推荐」方向研究实习生。 如果你对推荐系统、生成式模型、LLM 与排序/召回结合等方向感兴趣，欢迎投递简历，具体方式如下：

- 扫描下面二维码登陆join.qq.com
- 项目选择：日常实习生或应届实习生
- 岗位选择：技术研究-推荐算法方向
- 意向部门选择：PCG技术线-大数据平台方向





腾讯技术工程

腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。

688篇原创内容

公众号



阅读 4156

留言

写留言

还没有留言，来写首评