上线后差点“挤爆”服务器，Marvis凭什么让用户追着6只小马“上班”？

原创 腾讯程序员 腾讯技术工程 2026年7月15日 04:11 广东 44人



> 5月20日23点58分，Marvis 上线。
>
> 22号上午，用户量激增，官方紧急扩容
>
> 在冰冷的代码与闪烁的屏幕背后，是一席关于 AI 时代的产品真心话：
>
> “我们‘死磕’端云混布，就是在赌未来。”
>
> “即便在长途飞机或高铁上完全断网，你也能用AI处理工作，这就是真•本地模式。”
>
> “哪怕牺牲便利性、显得不够小白，我们也得把主权交给用户。”

当一个AI的工具因为有了拟人化的情感连接，让近半数用户每天乐此不疲地进来看6只小马干活，这背后究竟有着怎样的技术克制、架构考量、产品执念和设计思考？

本期我们邀请了 Marvis 的产品负责人 Eva 和技术负责人Nexthy，一起聊聊那些幸福的烦恼与鲜为人知的技术博弈。

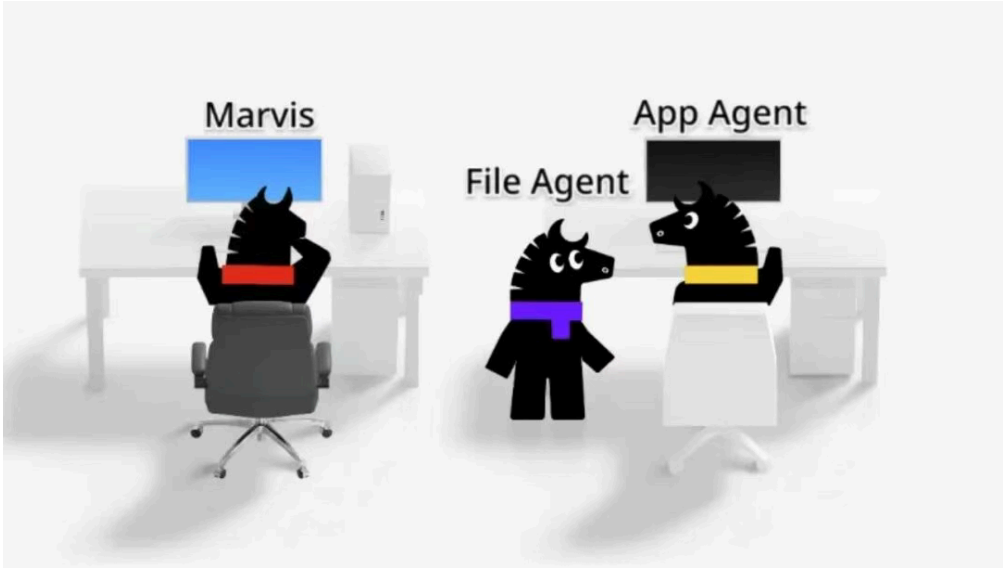
10个问题带你走近Marvis背后的故事

1. 六只小马的爆火是在预料之中吗？
2. 既然是生产力工具，为什么要在产品里养几只小马？
3. 现在大厂都在卷云端大模型，你们为什么选择“端云混布”这条路？
4. 为什么刚起步就选择Multi-Agent架构，而不是单智能体演进？
5. 与其他只给方案、只提供对话的 AI 相比，Marvis 的本质差异在哪里？
6. 面对“吃内存、老电脑跑不动”的用户吐槽，团队后续打算怎么解决硬件门槛？
7. 在“小白开箱即用”和“用户严格授权”之间，Marvis是如何做权衡的？
8. 为什么说“手机远程控电脑”这个跨端功能，不仅仅是一个桌面助手？

9. 为什么选择 520 这一天上线？上线这一个多月来，后台最让人意想不到的“神仙玩法”有哪些？
10. 如果向完全不懂技术的小白介绍 Marvis，你们会怎么定义它？

1. 六只小马的爆火是在预料之中吗？

Eva：完全没有预期！我们知道它是小白友好的，但没想到第三天上午服务器就挤爆了。发布才七八个小时资源就不够了，我们赶紧想办法找人、协调去扩资源。而且我比较意外的是，社交平台上有用户拿手机录了一下电脑里小马在干什么，点赞评论就上百，甚至过万，全都是自来水。



Nexthy：我们当时觉得小牛马可能会让大家有一些热度或讨论，但没想到是这个量级，好评度还这么高。我和团队以前做过很多产品，再到做 Marvis，这是第一个上线后虽然有外部用户和内部同事都在找过来反馈 bug，但最后还会对我说“你们产品做的真挺好、挺喜欢”的产品。

2. 既然是生产力工具，为什么要在产品里养几只小马？

Eva：我们有一个理念是想做到“开箱即用 、小白友好和 Agent 平权”，初期先去除掉各种复杂的模型切换等概念。另外，多 Agent 协作[Q]本身很复杂，我们就想着怎么做成仿生一点的故事线，让用户好理解且不枯燥。 但这只是一个故事线，跟实际能力没关系，所以前期我们与公众和媒体的沟通里，从头到尾都没提过“牛马办公室”，展开讨论的都是设备要求和跨端能力。不过用户对产品有了情感连接后，宽容度变高了，同时期待也更高了，会帮我们想很多，比如希望小马在办公室聊八卦、换皮肤、甚至打游戏看直播。

Nexthy：对，我们做的时候确实觉得小马会有意思一点。相比其他几个 Agent 产品，这几个小马拟人化的体验确实拉近了跟用户之间的距离，会让大家觉得很有趣，从反馈看，它恰恰也成了大家最容易记住 Marvis、也最愿意主动分享的点。



3. 现在大厂都在卷云端大模型，你们为什么选择“端云混布”这条路?

Eva：我们和市面上非常大的不一样点就是死磕端云混布或纯端侧，这确实会用到电脑的算力。虽然我们在第一步因为要确保输出效果，面临设备兼容的硬件门槛，但我们在“赌”端侧模型未来的趋势就是能力越来越强，用户对隐私和安全需求越来越迫切。 做 Agent 产品必须面向未来做。因为模型出新是一夜之间的事情，部署上马上就能运转，如果等生产力出来了再去搭生产环境和场景，那就来不及了，我们认同这个方向。

Nexthy：端侧模型有三个非常明显的优势，"经济 + 隐私 + 随时可用"。首先是降本，省Token，基于用户电脑本地资源运算，省去云端大模型API调用成本；第二是隐私，"数据绝对不能出门"，完全靠跑在用户电脑本地的端侧模型干活，数据不出用户本机；第三是网络环境，无网、弱网、断网都能用，在飞机或高铁上使用本地模型执行任务不受影响，这个诉求其实非常强。

4. 为什么刚起步就选择Multi-Agent架构，而不是单智能体演进?

Eva：通常市面上做 Agent 的新产品上来都会选择单一 Agent，一个主 Agent 接一个模型不断塞 skill，这样简单、架构清晰且快速迭代。但我们一开始是从系统底层能力往上做的，比如端侧文件知识库、和英特尔与微软对操作系统的理解、以及应用宝本身操作 APP 的运行能力，它们本就分属不同领域。如果全部塞在一个模型里，会导致上下文爆炸，任务只能串行不能并行，调度非常复杂，所以我们一开始就选了 Multi-Agent主从结构。

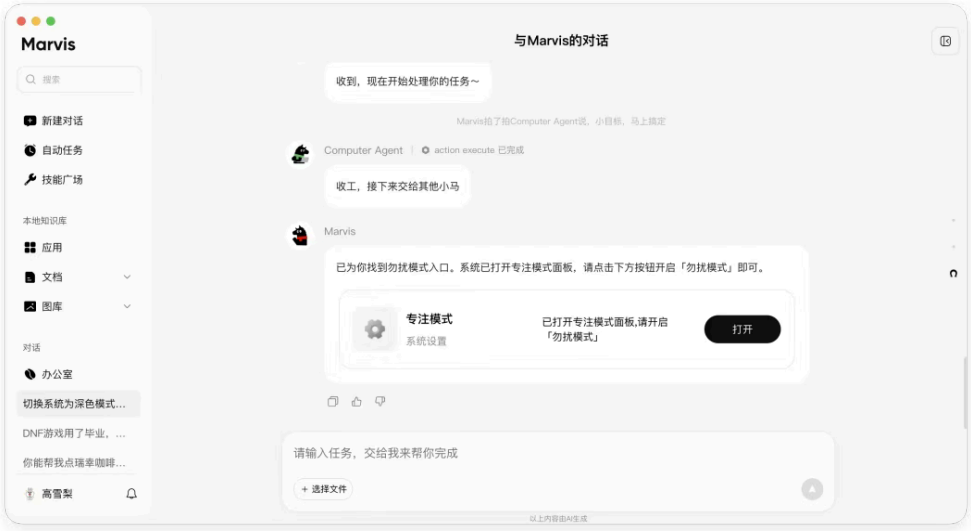
Nexthy：对，但这也带来了调度上的复杂性。

Eva：这种架构对模型的指令遵循率要求会更高，包括主子 Agent 的信息传递、结果传递、卡片传递等。大模型的迭代是慢于 Agent 应用场景发展的，这也是我们为什么没有轻易放开自由切模型的原因，我们必须得测市面上的模型在 Marvis 场景里的效果和质量达标了，才会提供切模型的选项。

5. 与其他只给方案、只提供对话的 AI 相比，Marvis 的本质差异在哪里？

Nexthy：大模型现在已经很会“聊”了，但它还不太会“干活”。以前大家遇到电脑使用问题，一般会用 AI 工具去搜方案， AI 只是告诉用户“该怎么做”，看完之后用户还得自己去找系统设置、翻好几层菜单，甚至有的还得改注册表，操作成本和难度大。而 Marvis 从“告诉你该怎么做”变成“直接把它做了”，这是很多用户之前没有体验过的，所以大家觉得很省心、很惊喜。

Eva：对，我们是连方案搜索带主题搜索一起做了。很多用户拿我们和 Codex、Claude Code 这类国外工具对比，Marvis 在这个点的速度、准确性和能力并不逊色。而且我们做了很多 GUI 和 ROI 的结合，市面上其他产品调完夜间模式或专注模式后，都是纯文字反馈一句“好，我完成了”。 而我们会把功能卡片拿出来，把开关按钮放在卡片里，用户过一会想关掉直接在卡片上操作就行，不用二次跟 AI 说话，这种结合在不可控的 AI 面前对用户的安全感很好。



6. 面对“吃内存、老电脑跑不动”的用户吐槽，团队后续打算怎么解决硬件门槛？

Nexthy：这确实是个问题，因为要保证模型实际效果，本地模型尺寸不能太小，我们现在端侧下发的是Qwen 35B-A3B，做了 4bit 量化，最后的包体大概 24G，对用户设备的显存、内存和存储有一定的要求。

Eva：为了兼顾更多设备，我们下面的拓展方向，一是伴随端侧模型本身的演进，体积变小能力变强；二是我们会做更细化的场景切分。因为用户查个信息或改个设置对隐私要求不高，但处理文件是一定涉及隐私的。所以我们会把文件相关的、高频的文档总结、PPT 生成、翻译等功能，做成多个垂直的、小 size 的大模型，目前我们深度合作中，正在针对垂直场景专门训这些小模型，这样就能降低对电脑硬件的要求，同时尽可能保留效果。

7. 在“小白开箱即用”和“用户严格授权”之间，产品是如何做权衡的？

Eva：原本本地知识库及其以下的功能全都是在端侧计算和展现的，我们本想直接帮用户干完就得了。但用户在不知道的情况下，会觉得“怎么没给你授权你都给我处理完了”。

所以为了把主动权还给用户，我们宁可牺牲一定的便利性、即便觉得“咋一直让我点确认”，也改成了一开始就提供一个全屏的解释说明和授权设置。用户必须自己圈定白名单范围并主动点击授权，我们才开始工作，不授权就不体验这部分。

8. 为什么说“手机远程控电脑”这个跨端功能，不仅仅是一个桌面助手？

Eva：我们应用宝团队以前做业务的时候就做了车载、移动和眼镜端，天生具备这个跨端基因和生态合作伙伴。Marvis的移动手机端能交叉系统连接：安卓端能连Mac端，iOS端也能连Windows端，如果你人不在电脑旁，给电脑发复杂指令怕它乱搞，你可以一边在手机上看它的操作屏幕，一边发指令，并且右下角会有正在连接的提示，方便管理。

Nexthy：Marvis 不会只当个"电脑里的助手"，它会变成一个你随身带着、随时能接管你电脑的入口。这个方向其实已经被用户验证过了。社媒上真实的分享不少，有人说"试了下 Marvis 就回不去了，人在高铁、酒店、开会现场，关键文件全在家里电脑上，现在手机直接就变成第二台电脑了"，他拿起手机连上家里那台电脑，语音发命令、实时看着桌面，远程指挥电脑上的 Marvis 帮你干活。未来的 AI 助手，一定是多端的、跨设备的，谁也不会只在一台设备上用 AI。



9. 为什么选择 520 这一天上线？上线这一个多月来，后台最让人意想不到的“神仙玩法”有哪些？

Nexthy：当时我们五一假期回来后，大家讨论过5月16号、5月20号、5月24号等好日子，最后选了520，本质上也是图个吉利。其实那天挺有意思的，按照黄历晚上 11 点到 12 点之间是最好的时间。其实我们原本想早一点发，但一直在优化迭代，最后 业务负责人 说不能等了，我们答应过内测媒体与用户520上线，那必须在 12 点之前发出去，所以是在 23:58 发的。

Eva：我是真没想到有那么多人拿它来写小说的，这是一种后端的、符合特定排版格式并自动生成文档的主题写作。还有人拿去用于游戏硬件问题的解决，比如有用户买新 Mac 电脑外接显示器，画面翻转了 180 度，他用手机连上跟 Marvis 说了一句直接就解决了。包括有同事电脑卡，Marvis 扫完直接告诉他一共四个卡槽两个是空的，建议加内存条，并给出了电商平台上哪款性价比最高，这种深入理解 Computer 的能力让我觉得挺神奇的。另外还有人拿去选股，或者做电商赚了钱，完全超出了我的预期。



10. 如果向完全不懂技术的小白介绍 Marvis，你们会怎么定义它?

Eva：如果面对完全小白的用户，我会说：“你在手机和电脑上都可以让 AI 帮你干活，你还能在一旁监督它。它可以帮你干上学上班的作业、汇报汇报、处理和修改文档；你电脑出了任何问题，问它，它都能帮你修；你要是打游戏，它还能帮你自动收个菜或查资料。”但是，如果没用过具备执行力的 Agent 产品，直接跟他们口头说“能帮你干活”而不是“回答问题”，他们往往 get 不到，必须要扔个具象的场景，比如修电脑，清理C盘，给他们对比，他们才能明白。

Nexthy： 至于具体怎么介绍，得看人。跟完全不懂的用户讲"操作系统层级"、"端侧模型"这些，确实有点抽象，很难理解，得换成大家能直接感知的使用场景。比如面对父母，我就直接说："能帮你把孙子的照片从一堆文件里翻出来、电脑坏了能帮你修、还能帮你下一个绝对不是假的 QQ"。说完这几个，他们立马就懂了。年轻人就换一套说法，比如"出差在外面，一句话就能让家里的电脑把文件找出来发给你"、"让它自动把乱七八糟的桌面归置好"。

结语

伴随模型的演进，Marvis 的场景还在不断生长。

这群主创并不急着给 AI 的终极形态下定义，而是选择把主动权还给用户，把精力留给具体场景里的执行力。 纯端侧模型的博弈仍在继续，吃内存的阵痛也正在被一件件拆解。就像他们所说，产品不是坐在办公室里想出来的，做 AI 产品必须面向未来做。

当下一次你在万米高空完全断网的机舱里，看着小马在本地顺畅地帮你改完系统、办妥任务时，你会发现，当初那些看似偏执的真心话，都已经落成了最具体的现实。





阅读 1.3万

留言

写留言

还没有留言，来写首评