腾讯发布1.58Bit大模型量化新算法Tequila！突破"死区陷阱"，效果性能刷新SOTA

原创 腾讯程序员 腾讯技术工程 2025年10月10日 02:36 广东 66人



针对大语言模型(LLM)的量化方法层出不穷，近期**三值量化**（1.58Bit）在LLM中使用的越来越广，比如BitNet等方法。腾讯近期发布了1.58Bit量化的新算法 Tequila，提出一种QAT阶段解决“死区陷阱”的新算法，性能效果达到新SOTA。模型使用 1.58Bit 的位宽达到的性能，能对标同参数量的全精度模型，潜力巨大。

github地址：https://github.com/Tencent/AngelSlim

论文地址：https://arxiv.org/abs/2509.23809



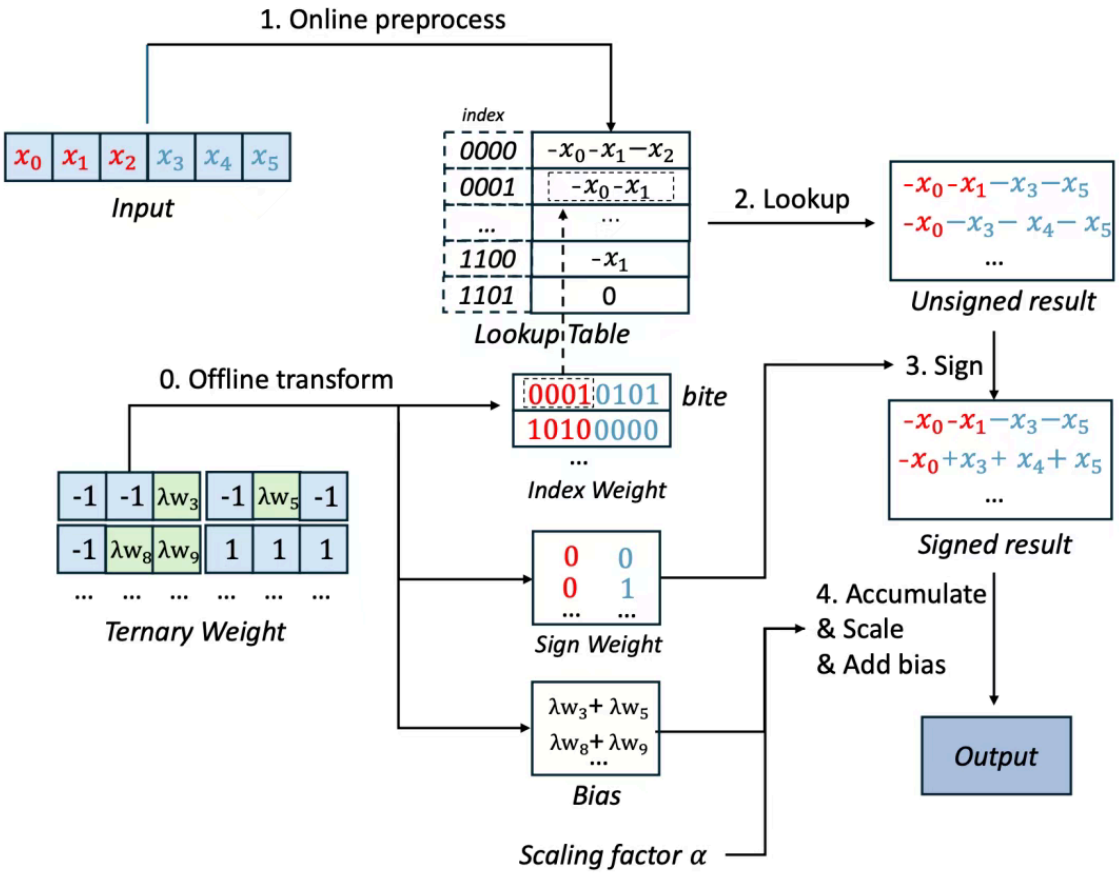
TEQUILA: TRAPPING-FREE TERNARY QUANTIZATION FOR LARGE LANGUAGE MODELS

Hong Huang[1]* Decheng Wu[2] Rui Cen[2] Guanghua Yu[2] Zonghang Li[3]
Kai Liu[2] Jianchen Zhu[2] Peng Chen[2] Xue Liu[4] Dapeng Wu[1]
[1]City University of Hong Kong [2]Tencent [3]MBZUAI [4]McGill University

腾讯技术工程
腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。
690篇原创内容
公众号

1、三值量化介绍

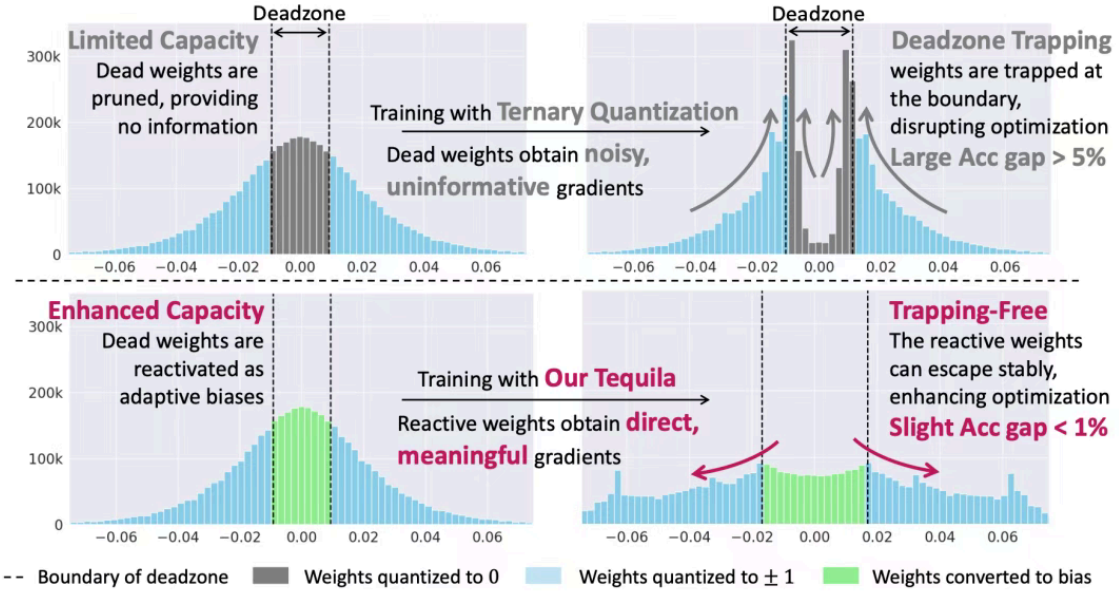
三值量化是部署大语言模型到端侧和CPU设备的一种高效方法。其核心是将权重约束为【-1, 0, +1】三个值，从而将矩阵乘法简化为加法操作。这种转换显著降低了计算复杂度。由于加法被硬件原生支持，因此三值量化在推动边缘计算和低功耗AI应用方面潜力巨大。



2、三值量化的缺陷与挑

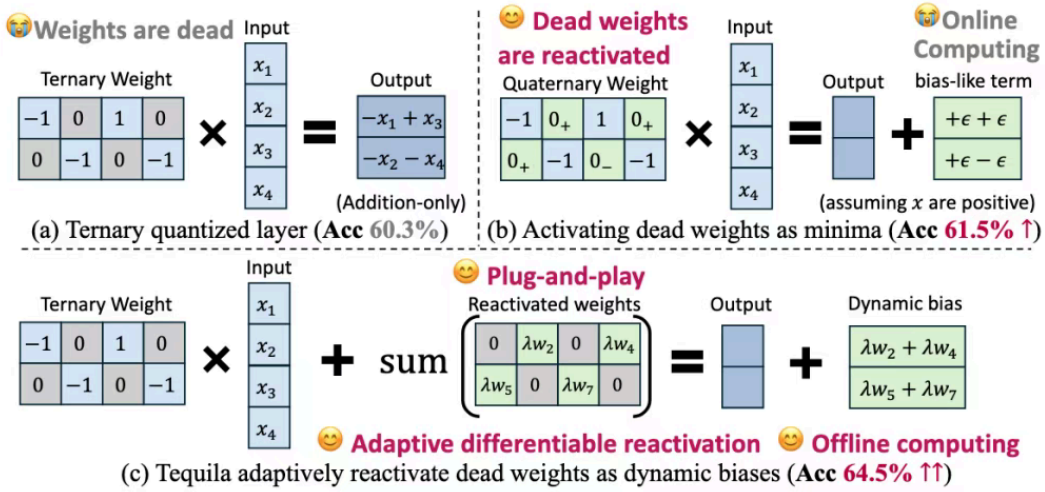
然而，这种激进的压缩方式会带来显著的信息损失，即便在大规模数据集上进行了量化感知训练（QAT），也常常会导致严重的精度下降。例如，BitNet 在 QAT 过程中消耗了 4T 个 token，但仍无法达到全精度模型的性能。因此，精度下降和高昂的训练开销这两个问题是开发有效三值 LLM 落地的主要障碍。

我们发现这些挑战的关键根源在于“**死区陷阱**”。“死区”即数值为0的区域，在三值量化中出现大量的0，并且训练时，在直通估计器（STE）由于缺乏一致的梯度优化信号，这些权重无法稳定地逃离死区，而是在死区边界累积，如下图（上部）所示。这导致了无效的振荡循环，使这些权重永久处于不活跃状态，严重阻碍了模型收敛。



为解决死区陷阱问题，我们提出了**Tequila**三值量化方法。我们的核心思想是通过将“死区”权重重新用作动态偏置bias来重新激活它们。这为输出提供了连续信号，显著增强了模型的容量。更重要的是，这些权重通过bias项直接获得有意义的梯度，从而能够稳定地摆脱死区，如上图（底部）所示。同时，这些bias可以离线计算，几乎不会增加推理开销。

3、Tequila三值量化创新



（1）极小值再激活算法，用来缓解死区陷阱。我们发现，三值量化中的“死区”现象源于零点权重在前向传播中无法提供有效信号，导致这些权重陷入无法更新，难以学习的恶性循环，严重阻碍模型收敛。为解决该问题，我们提出通过为这些无效权重注入少量信息值，重新激活其作用。该方法并非依赖梯度强行将其移出“死区”，而是赋予权重新的功能：既为增强模型容量，也为梯度提供清晰的传播路径，从而持续接收有效梯度，打破僵局。

因此我们提出了极小值再激活（Minima Reactivation）方法，保留了零权重的符号信息，将其重新激活为不同的值： -0 和 +0，分别代表负极小值和正极小值，如上图（b）所示。这创

建了一个有效的四元权重表示 {-1, -0, +0, +1}，同时保持了三值运算的计算优势，因为输入 x 与这些极小值的乘法简化为具有适当符号的常量绝对值，计算公式如下：

$$x \cdot 0_+ = \text{sign}(x)\varepsilon, \quad x \cdot 0_- = -\text{sign}(x)\varepsilon.$$

形式上，令 $\tilde{W} = (\tilde{w}_1, ..., \tilde{w}_n)$ 表示四元权重向量，并将死区内的索引集定义为 $D = \{i \mid -\Delta < w_i < \Delta\}$。前向传播过程可相应转换为：

$$Y = X\tilde{W}\alpha = \underbrace{\alpha \sum_{i \in \bar{D}} \text{sign}(w_i)x_i}_{\text{original output}} + \underbrace{\varepsilon \sum_{i \in D} \text{sign}(x_i)\text{sign}(w_i)}_{\text{online bias-like term}},$$

该公式表明，先前处于死区的权重现在通过偏置项bias对输出产生有意义的影响。因此，这些权重w从反向传播中获得信息梯度，表示为

$$\frac{\partial L}{\partial w_i} = \varepsilon \cdot \text{sign}(x_i) \cdot \frac{\partial L}{\partial Y}, \quad \forall i \in D.$$

与基于STE的传统三值量化相比，本方法使原本的“失效”权重能够输出非零的有效信号，并获得更明确、稳定的梯度，从而高效实现权重恢复，显著加快收敛。尽管极小值再激活算法验证了重新激活策略的可行性，但我们发现其存在两个局限：

a）重新激活权重的梯度更新仍依赖STE，会引入较大噪声，对精度提升有限；

b）所引入的类似偏置的项与输入相关，导致不可忽视的推理开销。基于这些发现，我们最终提出Tequila方法，在保留死区重用核心思想的同时，有效克服了上述的这些局限性。

（2）动态离线偏置。如上图（c）所示，Tequila 通过三项关键设计，在几乎不增加推理开销的前提下，有效解决了三值神经网络中的“死区”权重问题：

a) 可微量化取代 STE：针对“死区”权重ωi，引入动态偏置λωi 替换了不可微的恒定值ε 的映射，使量化函数变得平滑可微。该设计绕过了 STE，提供了直接且具有信息量的梯度，能够有效优化“死区”的权重。

b) “死区”权重融合至偏置： 鉴于在 Transformer 中输入的分布大致是对称的，我们将与输入无关的“死区”偏差融合至离线Bias，从而将推理开销降低到几乎为零，同时仍保留了权重再激活的优点。

c) 保留输入信息：重新激活的权重不仅作为离线偏置，还会参与三值矩阵乘法计算，既保留了关键的输入信息，又获取丰富的梯度信号，从而推动更有效的训练。

通过这三个关键设计，Tequila前向传递将高效的三值量化运算与自适应偏置相结合，如下公式所示：

$$Y = XQ(W) + C(W) = X\hat{W}\alpha + \sum_{i \in D} \lambda w_i,$$

其中偏置项C(W)作为死区权重的残差连接，该处理直接为这些”死“权重提供了更优的梯度，如下反向传播公式所示，为“死”权重提供直接、信息丰富的梯度信号，加速模型收敛。

$$\frac{\partial L}{\partial w_i} = x_i \frac{\partial L}{\partial Y} + \lambda \frac{\partial L}{\partial Y}, \quad \forall i \in D,$$

与现有三值量化方法相比，Tequila具有五大核心优势：

• 增强模型容量：通过重新激活失效权重，在不增加推理计算复杂度的前提下，有效扩展了模型参数空间。

• 无陷阱优化：Tequila通过提供直接且信息丰富的梯度，能够稳定逃离死区，实现无陷阱的权重优化。

• 训练稳定性：可微分的重新激活函数在保持量化约束的同时确保优化过程稳定，使训练收敛更一致可靠。

• 即插即用设计：Tequila作为简单易用的模块，可轻松集成到大多数现有三值量化方法中。

• 近乎零推理开销：与输入无关的偏置项可离线预计算并无缝融合到计算核中，实现近乎零的推理开销，完美保留纯三值量化的硬件效率。

4、实验效果

Tequila对比常用QAT、三值量化方法，效果指标提升明显，在10B的Token数据量上达到了sota的水平，多个Benchmark中提升3%左右，如下图所示：

Size	Method	ARC-e	ARC-c	HelS	PIQA	WinG	GPQA	Average
1B	BF16	0.654	0.313	0.477	0.742	0.603	0.222	0.502
	LSQ	0.376	0.177	0.258	0.574	0.506	0.231	0.354
	SEQ	0.421	0.180	0.273	0.604	0.510	0.232	0.370
	DLT	0.424	0.174	0.256	0.563	0.513	**0.277**	0.368
	TWN	0.407	0.220	0.284	0.601	0.492	0.212	0.363
	Absmean	**0.603**	**0.259**	**0.360**	**0.683**	**0.541**	0.227	**0.445**
	Tequila	**0.645**	**0.305**	**0.391**	**0.710**	**0.542**	**0.232**	**0.471**
3B	BF16	0.745	0.422	0.552	0.768	0.691	0.303	0.580
	LSQ	0.431	0.200	0.294	0.599	0.522	0.239	0.354
	SEQ	0.498	0.231	0.303	0.645	0.529	0.258	0.411
	DLT	0.361	0.161	0.260	0.572	0.496	0.272	0.354
	TWN	**0.692**	**0.351**	**0.462**	0.734	**0.586**	0.237	0.510
	Absmean	0.672	0.329	0.439	**0.735**	0.582	**0.301**	**0.510**
	Tequila	**0.702**	**0.346**	**0.464**	**0.739**	**0.627**	**0.303**	**0.530**

Table 1: Comparison of Tequila method with different ternary quantization methods

同时可以观察loss下降速度，可以发现我们的方法的下降速度明显优于其他方法，这也证明了重新激活死区权重对模型收敛有着巨大帮助。

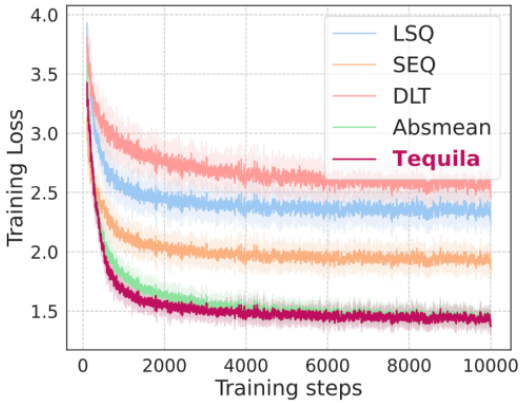


Figure 3: Evaluation of Tequila on convergence speed compared to SOTA ternary quantization.

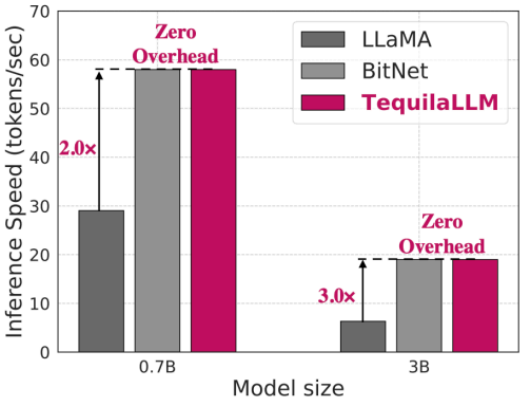


Figure 4: Inference speed of TequilaLLM versus BF16 LLaMA and ternary BitNet.

最后，性能测试中，三值量化推理性能在CPU上tokens/s提升2~3倍，对比BitNet三值量化的耗时发现，我们的方法对于推理时延的负担几乎为零。

5、总结

Tequila为高效模型压缩开辟了新的方向，为解决"死区陷阱"这一难题，Tequila提出自适应动态偏置，以近乎零推理开销下，成功激活这些权重来增强模型表达能力。在多个Benchmark中Tequila超越现有三值量化方法，在使用有限训练数据的情况下逼近全精度模型性能，同时保持三值量化的计算优势，最高可实现3倍推理加速。我们相信这项工作为将为LLM部署到资源受限设备，提供了切实可行且易用的解决方案。欢迎关注Tequila的工作：

github地址：https://github.com/Tencent/AngelSlim

论文地址：https://arxiv.org/abs/2509.23809



腾讯技术工程
腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。
690篇原创内容
公众号



阅读 7446 修改于2025年10月10日

留言

写留言

还没有留言，来写首评