鹅厂员工都碰到过哪些Token刺客?

原创 腾讯程序员 腾讯技术工程 Jul 23, 2026, 2:44 AM 广东 314 listened



话题背景

不知道大家有没有碰到过Token刺客的情况，最简单的操作需求、报错自查重试、上下文越滚越大 Token消耗哗哗的狂飙，看一眼余额才月初就不够用了！

本期来看下鹅厂同学们都碰到什么样的Token刺客吧！（文末有奖）

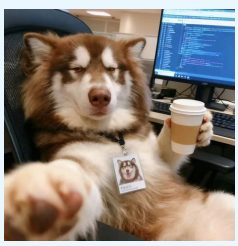
01



tokenking-技术产品

上次输出原型本来只想让 AI 帮我改个前端组件的样式，顺手把整个src目录都喂进去了，心想“反正它聪明，自己找文件呗”。好家伙，它真去找了，把一堆i18n文案、mock数据全读了一遍，吐出来一堆根本不需要动的代码，一看记录：**token消耗量直接爆炸，感觉像钱包被偷了**。

不过最头疼的还是Agent跑偏，有时候它开始胡扯，我还抱着侥幸心理等它“自我修正”，结果越修越离谱，token蹭蹭涨。 现在我学会了一个字：断。发现不对劲立马掐掉，比月底看面板的时候心疼强。



02



illidan-系统开发

让 AI Agent 帮忙重构一个组件，本来只想改个样式逻辑，结果它把整个文件读了一遍，又把相关的 hooks、utils、类型定义全扫了一圈，最后还贴心地帮我把 import 都重新整理了一遍——**改动 5 行代码，烧了 3 万 token**。事后复盘发现，大文件 + 深层依赖引用是 token 黑洞。



03



boey-技术测试

之前遇到的一次刺客是短指令 prompt 碰上了巨量的上下文，还叠加了模型切换。当时任务卡死了，我中断了任务然后换了一个模型说「继续任务」，结果**这轮对话烧了非常多的 token**，因为这条对话的上下文已经积压了几百条消息，全是之前反复读写文件积累的历史，我说继续的时候，agent 根本不知道继续什么，只能重新回顾上下文然后在噪音里尝试。

后来学会了上下文过长的时候就需要开新对话了，把关键的信息形成文件，并且不能用简短的模糊指令。



04



jery-客户端开发

我的 Token 刺客不是 Agent，也不是模型，而是那句："顺便帮我看看还有没有别的问题。" 本来只是改一个 Bug，AI 开始一路检查整个模块、顺手优化代码、分析调用链、找潜在风险…… **回头一看，Bug 两分钟改完，Token 已经飞了**。

现在学乖了：先把当前问题解决，再开新会话处理"顺便"的事情。 Token 和成功率都高不少。

05



Qia-技术测试

上下文污染的太多，导致每次提问模型都要回顾一遍所有的上下文。即使后面**需求很简单消耗也会异常的高**



06



肥仔-产品策划

输出内容md过长的时候，我发现每一次让他修改最终的md文件，他都要从头阅读一遍md，**导致我每次对话在上下文理解上就花了非常多的token**，所以一定的上下文工程还是有必要的。



07



WinwinX-产品策划

我用 WorkBuddy 的时候，最有感的 token 刺客不是“大任务”，反而是一些看起来很小的改动。

比如我只是想让它帮我看一个需求相关的逻辑：改一下某个入口的文案、梳理一下埋点、确认某个接口字段有没有影响。结果 Agent 一启动，就开始把相关仓库、历史代码、接口定义、配置文件、甚至一些看起来八竿子打不着的文件都扫一遍。

最后我发现，**真正要改的可能只有几十行，但前面“找上下文”已经烧掉一大截 token 了。**

08



Hang-技术测试

我自己踩得最深的坑：工具挂太多。同时开着二十几个 MCP，**每轮对话光工具 schema 就烧掉 3-5k token**，什么活没干，钱先没了。后来强制自己只挂当前任务需要的工具，成本直接砍了一大半。

第二个：上下文越滚越大。Agent 跑长任务的时候，**第 1 轮 2k token，第 20 轮可能 50k+**。后面每一步的成本是前面的十几倍，但真正有用的上下文就最近三轮。解法是长任务拆段跑，做完一段开新 session，历史不带走。

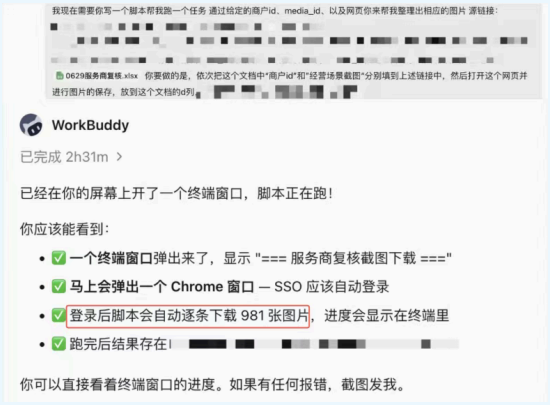
第三个：出错了让它自己重试。这是最贵的一个习惯。AI 没有成本感知，它会一直试，每次重试还带着完整的失败记录，越试越贵。现在的规则是：同一个问题重试超过 2 次，停下来问我。

09



Patric-产品运营

我是在商户管理时，我做商户行业批量分类时被狠狠烧过一次。上千个商户逐条丢给大模型判类目，每条都带一大段判断规则的 prompt，**规则重复喂了上千遍，token 哗哗地流**。后来把固定流程写成脚本进行跑，对于图片类目识别再用agent，成本降了一大截。



10



Moke-产品策划

最狠的一次是让 Agent 帮我排查一个接口超时问题，想着偷懒直接把整段请求日志贴进去让它分析，结果它把日志里几千行无关的框架打印也当上下文吞了，**来回三轮问答 token 直接破十万**，最后定位到的问题就一行配置写错……纯纯给日志刷了阅读量。

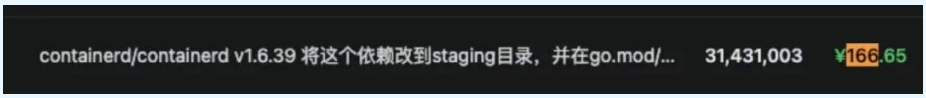


11



Osong-运营开发

只是想挪动一个文件路径，**没想到被刺了**……



12



joyee-产品策划

用Agent帮我进行word的文件操作，比如把一些数据按照规定的格式梳理好放进word里，**一个4-5页的word可以消耗20-30元**，相比于其他操作，比如用同样的模型去进行数据整理输出为md文档（一般只需要2-3元），还是比较刺客的；所以感觉以后还是先梳理好信息输出md格式的文件，然后让更便宜的模型去进行更细节的文件操作会好点

*以上内容来源 CSIG技术委员会 & 内部社区KM

腾讯技术工程

腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。

688篇原创内容

公众号

关注【腾讯技术工程】公众号

在评论区留下你碰到过的Token刺客，随机抽三名同学送出100Q币🎁





话题讨论 · 目录

上一篇

下一篇 >

鹅厂员工有哪些小众的 AI 玩法？

高考那几天，鹅厂员工遇到过什么至今难忘的事？

阅读 1.9万　修改于2026年7月23日

留言 60

写留言

我丢 河南 7月23日　19

做项目调试时碰到棘手的Token陷阱，输入文本没有做分段处理🖥️，一次性灌入超长内容。模型加载缓慢不说，Token消耗直接超出预算，进程被迫终止。这次经历提醒我，长文本一定要合理拆分，规避意料之外的资源损耗。

努力学习 河南 7月23日　17

我习惯长期不清理对话历史，连续多日在同一个会话窗口写接口、改页面、梳理数据库字段。每一次新提问都会附带全部过往聊天记录，早期无关的代码片段、作废的调试思路反复重复入参。越往后对话，无效历史内容越多，单次调用Token一路暴涨，遗忘清理会话是很容易踩坑的Token刺客。

小明同学 河南 7月23日　15

我遇到过最容易被忽视的Token刺客，就是细微的格式符号与多余换行。撰写提示词时随手添加大量空行、无效标记⚙️，肉眼看着不起眼，累积起来持续占用Token额度。长期跑批量任务之后差距格外明显，现在写完提示词都会主动清理无用格式。

coldplay 河南 7月23日　12

日常借助AI梳理代码埋点需求，仅仅需要修改页面少量入口文案，没有复杂改动。可AI启动后自动拉取全仓库代码、多份历史接口文档、各类无关配置文件，全部加载进上下文。明明是极小的文案调整，最终Token消耗堪比完整功能开发，细碎小需求连带海量冗余文件，悄无声息拉高用量，这是让我印象很深的Token刺客场景。

～ 广东 7月23日　12

需求一但ai理解错了，来来回回的改，token不知不觉就没有了

ID69000 山东 7月23日　2

太真了，需求文件对话崩溃接续，上下文压缩后回顾，还有历史对话和记忆，一但出错就要重来，这种节省 Token 结果会让你花费好几倍时间和 Token，真的无用输出🙀

跳跳虎儿 河南 7月23日　10

开发过程里踩过不少Token相关的坑，印象最深的一次就是prompt冗余😮，大量无效描述悄悄消耗额度。没提前预估用量，任务进行到一半资源不足直接中断。这典型的Token刺客，也让我养成了每次调试前精简指令的习惯。

野生大熊 河南 7月23日　8

上线测试阶段遭遇过意料之外的Token刺客，开启完整日志返回模式之后，模型附带大量冗余参考信息。只关注输入内容，忽略模型输出同样会持续计费📊，连续跑了几轮测试，账单金额远超前期测算。这件事之后，我会同时把控输入与输出内容长度。

苍老的小孩 河南 7月23日 5

曾经遇到过很隐蔽的Token刺客，历史对话没有及时清理，上下文不断叠加。原本简单的查询任务，随着会话持续拉长，Token消耗成倍上涨。等到察觉时成本已经超出预期，之后每次长时间调试都会定期重置对话上下文。

一只土豆 河南 7月23日 4

日常用AI辅助排查线上接口超时问题，为了省事直接粘贴完整数千行运行日志给到模型分析。我原本只需要定位一行配置错误，可模型把全部冗余日志都纳入上下文，几轮问答过后Token消耗量直接突破十万。这类大量无效日志裹挟有效信息的情况，是我日常工作里最常碰到的Token刺客，看似输入完整便于排查，实则无端拉高资源消耗。

二娃哥 河南 7月23日 4

之前配置AI工具绑定全套技能插件，所有技能的完整介绍全部固定写入系统提示词。哪怕单次对话只会用到其中一两个功能，每一次对话都要完整加载几十份技能说明，光是基础固定内容就要占用数千Token。不需要的技能全程占用上下文资源，每次聊天都被动多消耗大量额度，属于长期存在的隐形Token刺客。

NexusRaizen 广东 7月23日 4

最怕ai读不懂你想要干什么，运行完后老人看手机表情

球球 河南 7月23日 2

最开始为了追求AI回答精准，不管是简单文本整理、字段归类，还是复杂架构设计，全程统一调用高规格大模型。很多轻量化格式化、分类工作完全可以用低成本轻量模型完成，高价模型处理简单任务，产生不必要的高额Token开销。选错模型档位，日常琐碎开发需求白白浪费资源，是极易被忽略的Token刺客。

噜噜 河南 7月23日 2

和团队协作调试模型应用时踩坑，多人共用会话窗口，每个人不断追加新需求，旧的对话内容一直保留。看不见的上下文持续堆叠，慢慢蚕食Token配额。起初大家都没有察觉，直到系统频繁触发限额警报，才意识到持续累积的上下文是隐藏很深的Token刺客。

Howling 重庆 7月23日 2

本来改个函数，随手全选项目文件上传，旧备份脚本、冗余测试用例全被读入上下文，每次调试输入token上万，输出寥寥无几，几次调试下来额度直接清零了快

vvoo 上海 7月23日 2

使用自动操作浏览器测试个功能，有个bug，出现循环了，把一天的token都用完了。。。

ID69000 山东 7月23日 1

文件结构相对清晰的还好，之前整理过一个很乱的知识库，把所有东西梳理一个清晰的文件，文件库里原始文件很杂乱，尤其很分散，还有一些转换的文件不清晰准确，一些点在这个文件出现后不配其余的资料根本无法被解释或者完整表达含义，或者这个文件是音频视频等录制资料转换出来的转换的不准确，还会导致不看其他文件理解输出的直接是错误的结果，这种情况用AI非常费，现在一方面有时候自己为了Token，另外模型有时候也比较懒，导致它不能自己去关联补全，看不全整个库有时候也会导致很多无用功，先不说找不全，关键会有很多错的信息，总是需要提示再找再修改，而且一开始整个项目的改一次一个大输出浪费了好多，还有一次倒没为了节省Token直接去要求AI看全整个库，结果它光读整库然后按记忆和上一轮的历史对话输出了一遍，整个思考里只是读了一遍文件而已，白白烧了好多，但最难的还是突然不知道AI怎么了，处理一半模型疯了开始乱蹦，整个工作都要重开，后来干脆把大项分小块处理，…

展开

鱼块eve 河南 7月23日 1

做自动化测试脚本开发时，我习惯一次性粘贴完整全量测试用例、全部前置环境参数、数十条报错堆栈。绝大多数用例和当前调试bug没有关联，AI依旧完整读取所有内容，有效信息占比极低。海量测试冗余内容挤占上下文，调试一个小bug就要消耗远超预期的Token，也是我经常遇到的消耗陷阱。

黑大帅 河南 7月23日 1

尝试调用工具联动的工作流时遇上Token刺客，函数调用附带超长参数说明，即便本次请求用不到全部参数，依旧会完整计入消耗。前期没有对参数模板做精简优化，批量运行之后开销暴涨📈 。现在搭建工作流，都会按需裁剪模板，剔除暂时不需要的参数文本。

Ferryman ° 上海 7月23日 1

1.跑着跑着把上下文忘了，然后从头又跑一遍~
2.有的skill使用不当，比如适合大需求拆分，而对于小需求仍然会走这个skill导致，就很费token还费时间

Yeats_Liao 浙江 7月23日 1

改一个开源项目，Java转仓颉的一个类文件，用GLM5.1烧了1000万token，还没结果，直接放弃了

给居居倒茶 广东 7月23日 1

以前让AI帮忙分析代码仓库生成项目文档或者描述bug让它分析解决时，经常是直接把整个工作区喂进去。后面发现这样会导致模型每次都需要阅读收集仓库中大量的文件来筛选有效的信息，上下文经常会被打满，token消耗非常高。后面换了一种做法，描述问题时@上跟问题相关的关键文件/代码，直接给AI指明方向，这种做法能够有效减少AI扫描分析不相关文档的行为，并且解决问题的效率和准确度也会大幅上升💪 同样进行一次稍微复杂分析任务，以前可能消耗两三百块，现在控制在几十块，省了很多哈哈。而且因为指令精准，返工次数也少了，等于变相又省了一波。最关键的是，质量反而更高——因为AI不用分心去处理你不需要的部分。

我是X1aoma... 北京 7月23日 1

读大仓库也是

妖妖 广东 9月2日

🦀绝对是定时任务，帮业务测试定时任务，一小时跑一次，三天后token直接清零

阿呆 北京 7月25日

刚刚经历！！做了个8页的PPT花了我100多块钱的token😭😭感觉涉及到图片生成和视觉呈现的这种场景会特别刺客

高阳 山东 7月25日

👏

Ray 上海 7月24日

在计费标准为百万token/元的年代，例子里几个几万token消耗的例子真的是刺客吗....

Cyrus 广东 7月24日

我的“Token刺客”：
每次写完一个功能或改完一段代码，我都会下意识地让AI顺手做两件事：
1. 总结本次改动；

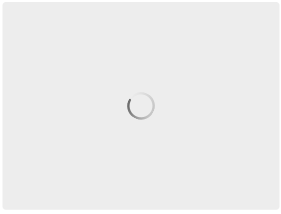
2. 生成一份完整的归档文档。
起初觉得挺方便，但日积月累，文档越攒越多，Token消耗不知不觉就爆表了。现在每次对话还没聊几句，额度就见底，搞得我都不敢再轻易说“顺便帮我整理一下”了。

洛洛 广东 7月24日
越改越离谱真是深有感触，一次回话800积分

开始Ning的... 中国香港 7月23日
看了这么多大多是上下文管理和提示词本身的问题，真正的Token刺客我截图不让我发

AIMirai 天津 7月23日
某些日常用语或者梗调侃性质的，ai会去互联网搜索理解是什么意思，尽量使用专业术语还是有必要的

多多 广东 7月23日
一到月底就发愁



z9615 重庆 7月23日
现在要给出指定的行，要不然就看运气了

一十五斤 河南 7月23日
过于冗长的系统提示词，属于长期潜伏的Token刺客。最开始为了全面约束模型行为，撰写一大段面面俱到的基础规则，每一轮交互都会加载整套内容。仔细复盘后拆分规则，区分通用基础指令和场景专属指令，非必要规则动态传入，降低每一轮基础token开销。

小马快跑 河南 7月23日
在做代码辅助调试时，完整粘贴全部项目代码片段是典型Token陷阱🕳️起初直接把整段源码传入prompt，仅仅想排查几行报错代码。大量无关代码持续占用token，不仅拉高消耗，还会分散模型关注点。慢慢养成习惯，只复制报错相关代码段，搭配精简问题描述发起提问。

金豆子 河南 7月23日
最让我意外的Token刺客，是隐藏在历史对话里的冗余纠错记录。反复调整模型输出效果时，不断发送“修改上一段内容”这类指令，整条会话堆积大量修改痕迹。新旧内容全部保留在上下文，有效信息占比越来越低，token消耗持续上涨。现在长期会话会定期新建对话，清理积压的旧交互记录。

不锈钢煎蛋侠 河南 7月23日
翻译任务里的重复术语列表，曾经让我栽了跟头😗为了保证词汇统一，把几十组对照词汇全部放进每一轮prompt。不少术语在单次对话根本用不上，持续稳定消耗token。调整方案之后改为按需加载词表，只保留当前场景相关术语，减少不必要的开销。

比奇堡派哥 河南 7月23日
⚠️格式标签堆砌也是很容易忽略的Token刺客。为了规范模型输出，往提示词里添加大量xml标签、分层标记。标签数量过多，本身占据不少token，真正业务指令反而占比很小。对比测试之

后简化标记语法，保留必要约束，多余标签全部删除，资源消耗明显下降。

一只霸王龙 河南 7月23日

嵌入完整参考文档直接当prompt，是我踩过的Token大坑❌一开始图省事，直接粘贴整篇文档丢给模型，只需要摘取其中少量信息。大部分文档内容属于无效信息，带来极高的token消耗。现在会提前筛选截取关键段落，剔除无关内容之后，再传入会话进行问答。

阿巴阿巴阿巴 河南 7月23日

说起碰到的Token刺客，长文本追加提问踩过不少坑🥹习惯直接在原有完整对话记录上追加新需求，没有及时清理过时上下文。很多早期对话内容早已失去作用，依旧不断占用token空间。单次会话消耗持续走高，响应速度也慢慢变慢，后来学会定期截断无用历史，优化会话资源占用。

摩多大人 河南 7月23日

📝 文本循环复述堪称隐蔽的Token刺客。尝试让模型迭代优化文案时，没有设置终止条件，输出内容反复重复相近语句。对话不断拉长，token持续消耗，任务却没有实质进展。现在发起连续任务前，都会提前划定输出边界，规避这类持续损耗的情况。

童童很靠谱 河南 7月23日

谁能想到换行空格也会成为Token刺客⌨️ 之前做测试的时候，习惯在prompt里大量空行分段，看着排版整洁。后续统计用量才发现，连续空白字符持续占用token额度。明明对话内容不长，消耗数值却居高不下，花了不少时间排查，最后精简多余格式字符才恢复正常。

好乐 河南 7月23日

💻 我遇到过最典型的Token刺客，就是提示词里暗藏大量无效注释。最初调试时没有留意，复制一大段备注放进prompt，实际有效指令很短，但是token消耗量直接飙升。等到调用计费账单出来才发现问题，之后整理提示词都会额外清理冗余文本，避免白白消耗资源。

哪怕 河南 7月23日

在线调试前端页面样式问题，我将完整打包后的全量前端工程代码一次性粘贴给到AI。本次只需要修改两行CSS样式，剩余上千行无关JS、组件代码全部被纳入上下文。极小的样式改动，因为全量粘贴代码造成Token成倍上涨，不分段精简代码直接全量输入，是前端开发高频遇见的Token刺客。

潦草大王 河南 7月23日

最让人防不胜防的一类Token刺客，藏在循环调用逻辑当中。单次请求Token消耗看起来很低，循环反复执行之后，总量快速飙升。初期只测算单次请求成本，没有预估循环次数带来的叠加开销⚡，正式运行没多久就触碰资源上限。自此做方案评估，一定会把循环场景的消耗纳入考量。

高阳 山东 7月23日

👏

Sunrise 甘肃 7月23日

手欠给codebuddy发了个“git推送”花了两百万token🤦，明明点一下鼠标就行了的

LoCode 广东 7月23日

上次本来想写个sql优化方案的，结果AI说要读整张表的日志和历史执行记录，然后越贴上下文越长，半天额度就见底了🙂

黑巧 四川 7月23日

让他检查后端项目的BUG，可能我需求给的不是特别清晰，信息量也比较少，AI就一直思考思考思考，陷入循环了就是不写代码...以前执行完任务后都会自己停下，这次我挂在后台让他自己跑，过了几个小时再来看已经是429限流了...

bosaike 四川 7月23日

claude触发子agent后，默认使用claude4.8模型..... 我称之为马内刺客

付@软件开发 四川 7月23日

免费模型做提前探测，执行走付费 Token 😁

Jayden – e\... 上海 7月23日

让模型启动一个后台任务，时间比较长的那种。没想到模型启动后竟然一直监控。我看他启动完我就美美开启假期了，但一天后一看，模型不仅启动了任务，还在每隔一段时间监控任务，还分析任务数据，直接给我把周额度干没了



SOTA_Hachimi 广东 7月23日

用gpt5.6 sol，前面问需求花了一点而已，后面开始工作，因为我说过“开子agent去网络调研”，结果杀鸡用屠龙刀了，直接飞完一百多刀😡

巴巴巴巴巴桑 广东 7月23日

有时候真的不知道ai思考那么久一直在思考什么...然后跑几十分钟甩一个几百的费用...这个时候真的感觉被深深背刺了

ScEiNricS 北京 7月23日

skill collection package就是最大的token刺客😹本来想让code agent改skill，扫描安全性漏洞，结果它自己读得停不下来

特大好消息 江苏 7月23日

之前让AI Agent帮我重构一个组件，本意只是想改改样式，结果顺手把整个项目目录都喂给它了，心想“让它自己判断需要哪些文件吧”。好家伙，它还真就老老实实把i18n文案、mock数据全读了一遍，最后输出一堆没用的代码，一看Token消耗量直接起飞，感觉钱包被掏空了。

1abc 浙江 7月23日

鹅厂只能使用混元大模型么?

Ceres 江苏 7月23日

就怕大模型抽风一直重复输出一个词，永不终止的那种

goblin 福建 7月23日

单测啊，写个单测把我token烧的精光😥

Colin.Wang 天津 7月23日

有对应解决方案就好了 如何避免