英伟达GPU全系列硬核科普手册：一文读懂NVIDIA芯片的定位、规格与应用场景

原创 腾讯程序员 腾讯技术工程 Mar 20, 2026, 2:36 AM 广东 1396 listened



作者：nickycao

> H20、L20、A800、RTX 50 系…… 英伟达 GPU 家族庞大又难记？游戏、设计、AI 训练、推理到底该选哪款？别再被型号绕晕！这篇全网最全图解指南，从入门到旗舰、从消费级到数据中心，一次性讲清 NVIDIA 全系列 GPU 的区别与用法，看完秒变选型高手。

这篇文章是一份**英伟达 GPU 全系列的硬核科普手册**：从游戏显卡到 AI 超级芯片，覆盖 消费级 GeForce（RTX 5090 ～ RTX 3090）、工作站 RTX Pro（RTX 6000 Ada / RTX A6000）、推理卡 L/T 系列（L40S / L4 / T4）、训练卡 B/H/A 系列（B200 / H200 / H100 / A100）以及中国特供版（H20 / L20 / RTX 4090D）五大产品线。

核心逻辑只有三条：**显存**决定模型装不装得下，**算力**决定算得快不快，**互连带宽**决定多卡扩不扩得动。

如果你只想快速选型——游戏创作看 GeForce，专业设计看 RTX Pro，推理部署看 L/T，训练研发看 H/B，国内合规看中国特供版。

🧭 0.阅读导图与学习路径

这篇不是一口气必须读完的论文，而是一份按需查阅的 GPU 百科；先抓住产品线主线，再按你的角色和场景深入感兴趣的板块。





🏗️ 1.架构演进史

NVIDIA 每隔约 2 年推出新一代 GPU 架构，每一代都带来计算能力的质变。



🔤 2.GPU 命名规则解读

看似复杂的型号其实藏着清晰逻辑。学会「拆字」，一眼识别定位。



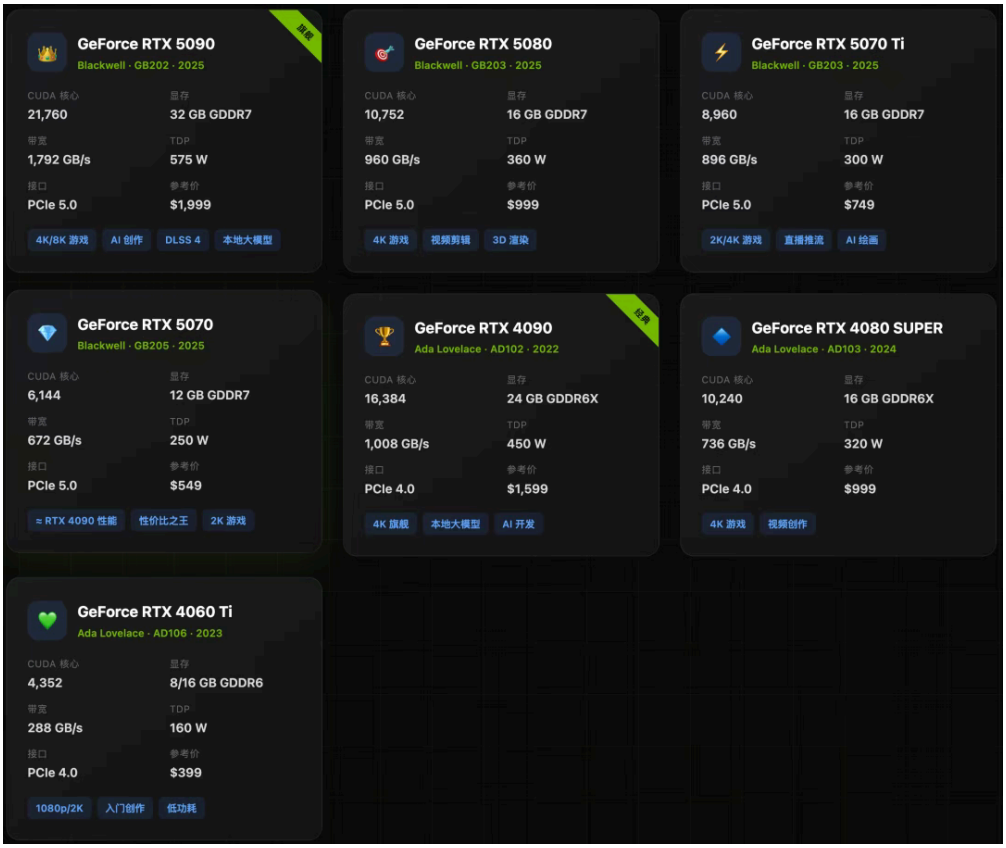
💡 3.核心概念扫盲

搞懂这些关键术语，后面的参数不再陌生。



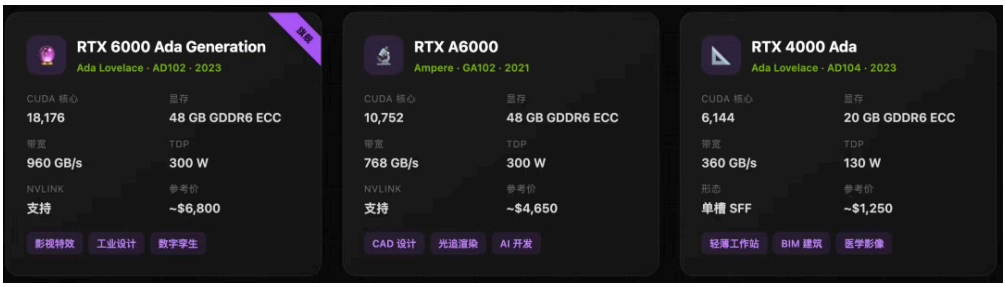
🎮 4.消费级 GPU（GeForce 系列）

面向游戏玩家与创作者。性价比高、驱动生态丰富，支持光追和 DLSS。



🖥️ 5.专业工作站 GPU

面向 CAD/CAE、影视特效、科学可视化。大显存 ECC、ISV 认证、长周期驱动。



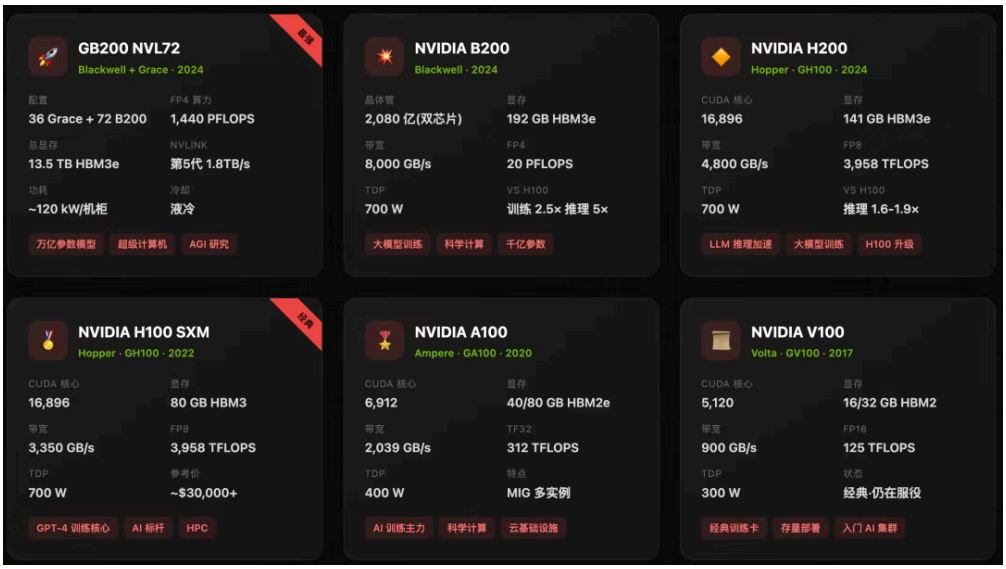
⚡ 6.推理加速卡（数据中心）

专为 AI 推理优化，追求高吞吐、低延迟和低功耗。承担 ChatGPT 等服务的实际运算。



🔥 7.训练旗舰（数据中心）

AI 大模型训练核心。GPT-4、Llama 等大模型背后靠成千上万张这类卡协同工作。



🇨🇳 8.中国特供版 GPU

📋 受美国出口管制限制，NVIDIA 为中国市场定制的合规版本。核心规格有所调整，但仍是国内 AI 产业的主力芯片。

出口管制背景：

自 2022 年起，美国陆续限制高端 AI 芯片对华出口。NVIDIA 通过降低互连带宽（NVLink）、削减 CUDA 核心数或限制算力精度等方式，推出符合管制要求的「中国特供版」。这些芯片在中国 AI 大模型训练和推理中仍发挥关键作用。**命名规律**：

数据中心卡在原型号数字修改为 「800」（如 A100→A800、H100→H800），或推出全新编号（H20、L20）；

消费级在型号后加 「D」（如 RTX 4090D）。





腾讯技术工程

腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。

688篇原创内容

公众号

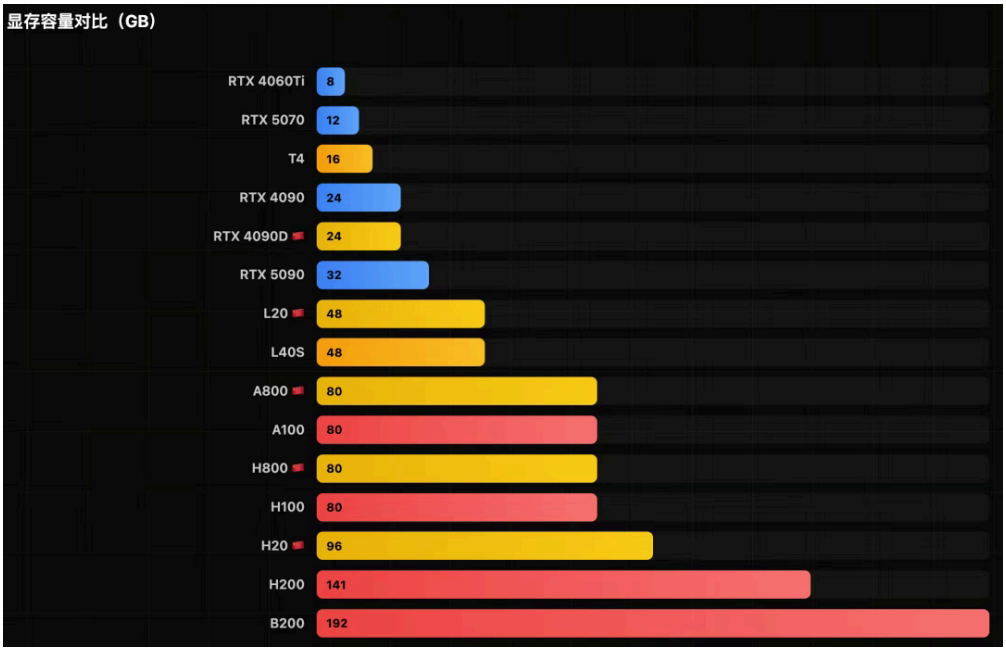
📊 9.横向对比总表

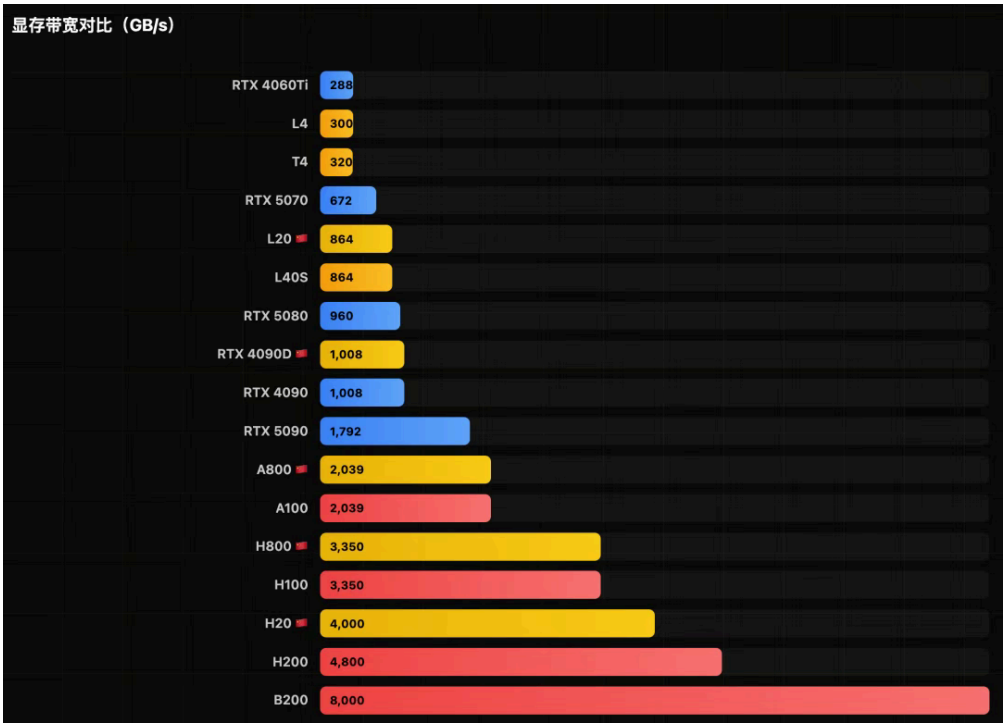
一张表快速对比关键参数差异。

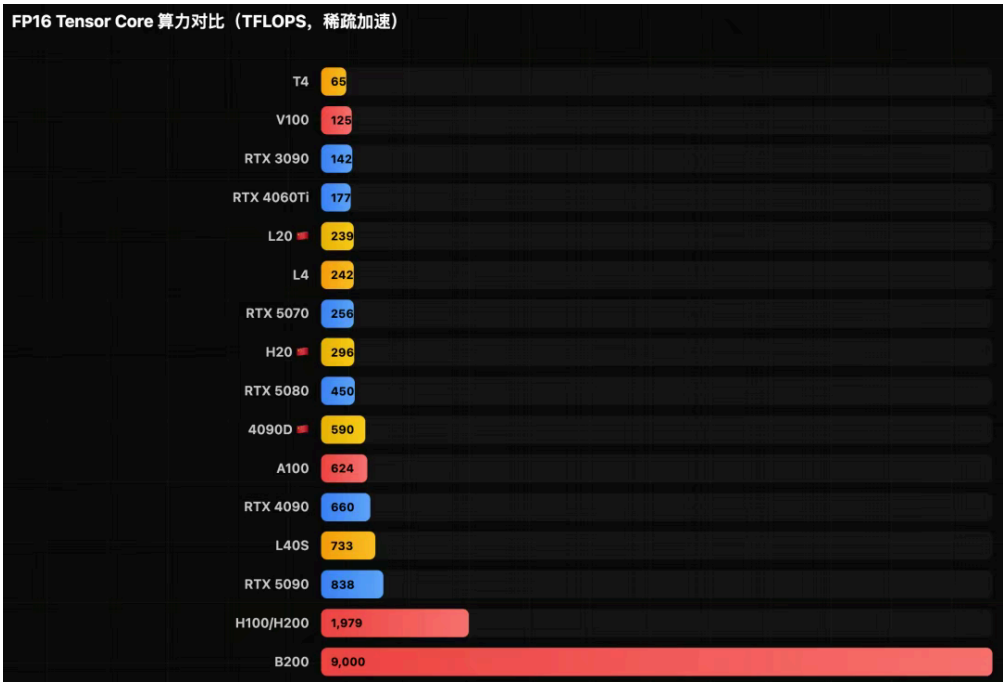
型号	类别	架构	CUDA	显存	带宽	TDP	定位
RTX 5090	消费	Blackwell	21,760	32GB GDDR7	1,792 GB/s	575W	旗舰游戏+AI
RTX 5080	消费	Blackwell	10,752	16GB GDDR7	960 GB/s	360W	高端游戏
RTX 5070	消费	Blackwell	6,144	12GB GDDR7	672 GB/s	250W	甜品≈4090
RTX 4090	消费	Ada Lovelace	16,384	24GB GDDR6X	1,008 GB/s	450W	上代旗舰
RTX 6000 Ada	工作站	Ada Lovelace	18,176	48GB GDDR6	960 GB/s	300W	专业渲染
RTX A6000	工作站	Ampere	10,752	48GB GDDR6	768 GB/s	300W	专业设计
L40S	推理	Ada Lovelace	18,176	48GB GDDR6	864 GB/s	350W	全能推理
L4	推理	Ada Lovelace	7,424	24GB GDDR6	300 GB/s	72W	低功耗推理
T4	推理	Turing	2,560	16GB GDDR6	320 GB/s	70W	经典推理
B200	训练	Blackwell	—	192GB HBM3e	8,000 GB/s	700W	顶级训练
H100	训练	Hopper	16,896	80GB HBM3	3,350 GB/s	700W	AI 标杆
H200	训练	Hopper	16,896	141GB HBM3e	4,800 GB/s	700W	H100 增强
A100	训练	Ampere	6,912	80GB HBM2e	2,039 GB/s	400W	经典主力
H20	中国版	Hopper	~9,984	96GB HBM3	4,000 GB/s	400W	中国市场主力
H800	中国版	Hopper	16,896	80GB HBM3	3,350 GB/s	700W	H100 合规版
A800	中国版	Ampere	6,912	80GB HBM2e	2,039 GB/s	300W	A100 合规版
L20	中国版	Ada Lovelace	11,776	48GB GDDR6	864 GB/s	275W	推理合规版
RTX 4090D	中国版	Ada Lovelace	14,592	24GB GDDR6X	1,008 GB/s	425W	4090 合规版

📈 10.性能可视化

图形直观感受关键指标差异。







⚡ 11.GPU 算力指标对比与排行

算力是衡量 GPU 实力的核心指标。这里将所有主流 GPU 的关键算力数据汇总排列，涵盖从消费级到数据中心的完整图谱。



排名按 FP16 Tensor Core 算力（稀疏加速峰值）降序排列。H800/A800 算力与原版相同（仅互连降速），故单独列出。B200 FP16 数据为 Blackwell 双芯架构峰值。

#	型号	类别	架构	FP32 TFLOPS	FP16 Tensor TFLOPS（稀疏）	FP8/INT8 TFLOPS/TOPS	显存 容量	带宽 GB/s	TDP W	能效比 FP16/W
1	**B200** 训练	Blackwell	2024	—	9,000	18,000 (FP4)	192 GB HBM3e	8,000	700	12.86
2	**H200** 训练	Hopper	2024	67	1,979	3,958 (FP8)	141 GB HBM3e	4,800	700	2.83
3	**H100 SXM** 训练	Hopper	2022	67	1,979	3,958 (FP8)	80 GB HBM3	3,350	700	2.83
4	**L40S** 推理	Ada Lovelace	2023	91.6	733	733 (FP8)	48 GB GDDR6	864	350	2.09
5	**RTX 5090** 消费	Blackwell	2025	105	838	1,676 (FP4)	32 GB GDDR7	1,792	575	1.46
6	**RTX 6000 Ada** 工作站	Ada Lovelace	2023	91.1	728	728 (FP8)	48 GB GDDR6	960	300	2.43
7	**RTX 4090** 消费	Ada Lovelace	2022	82.6	660	660 (FP8)	24 GB GDDR6X	1,008	450	1.47
8	**A100 (80GB)** 训练	Ampere	2020	19.5	624	624 (INT8)	80 GB HBM2e	2,039	400	1.56
9	**RTX 5080** 消费	Blackwell	2025	56	450	900 (FP4)	16 GB GDDR7	960	360	1.25
10	**L4** 推理	Ada Lovelace	2023	30.3	242	485 (INT8)	24 GB GDDR6	300	72	3.36
11	**RTX 4090D** 中国版	Ada Lovelace	2023	73.5	590	590 (FP8)	24 GB GDDR6X	1,008	425	1.39
12	**RTX 5070 Ti** 消费	Blackwell	2025	47	376	752 (FP4)	16 GB GDDR7	896	300	1.25
13	**RTX A6000** 工作站	Ampere	2021	38.7	310	310 (INT8)	48 GB GDDR6	768	300	1.03
14	**H20** 中国版	Hopper	2024	44	296	296 (FP8)	96 GB HBM3	4,000	400	0.74
15	**RTX 5070** 消费	Blackwell	2025	32	256	512 (FP4)	12 GB GDDR7	672	250	1.02
16	**RTX 4080S** 消费	Ada Lovelace	2024	52	418	418 (FP8)	16 GB GDDR6X	736	320	1.31
17	**L20** 中国版	Ada Lovelace	2024	59.8	239	239 (FP8)	48 GB GDDR6	864	275	0.87
18	**H800** 中国版	Hopper	2022	67	1,979	3,958 (FP8)	80 GB HBM3	3,350	700	2.83
19	**A800** 中国版	Ampere	2022	19.5	624	624 (INT8)	80 GB HBM2e	2,039	300	2.08
20	**V100 (32GB)** 训练	Volta	2017	15.7	125	—	32 GB HBM2	900	300	0.42
21	**RTX 3090** 消费	Ampere	2020	35.6	142	284 (INT8)	24 GB GDDR6X	936	350	0.41
22	**RTX 4060 Ti** 消费	Ada Lovelace	2023	22.1	177	177 (FP8)	8 GB GDDR6	288	160	1.11
23	**T4** 推理	Turing	2019	8.1	65	130 (INT8)	16 GB GDDR6	320	70	0.93
24	**A10** 推理	Ampere	2021	31.2	125	250 (INT8)	24 GB GDDR6	600	150	0.83





💰 性价比 vs 能效比对照

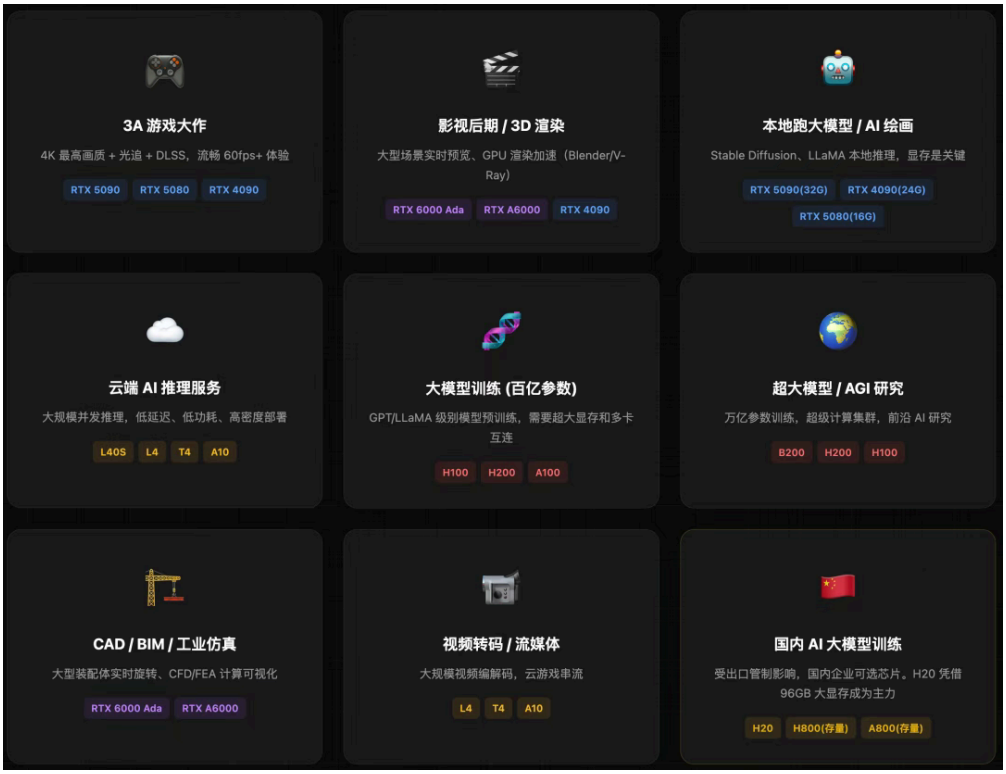
#	型号	FP16 Tensor TFLOPS	参考价 USD	每千美元 FP16 算力	TDP W	每瓦 FP16 算力	显存/千美元 GB/$K	适合场景
1	RTX 4090	660	$1,599	413	450	1.47	15.0	性价比之王
2	RTX 4090D 🇨🇳	590	¥12,999 ~$1,800	328	425	1.39	13.3	国内性价比
3	RTX 5090	838	$1,999	419	575	1.46	16.0	消费级旗舰
4	RTX 5080	450	$999	450	360	1.25	16.0	高端甜品
5	RTX 5070	256	$549	466	250	1.02	21.9	入门 AI 最划算
6	L40S	733	~$7,000	105	350	2.09	6.9	数据中心推理
7	L4	242	~$2,500	97	72	3.36	9.6	低功耗边缘推理
8	H100 SXM	1,979	~$30,000	66	700	2.83	2.7	训练 / 大规模推理
9	H20 🇨🇳	296	~$12,000	25	400	0.74	8.0	中国 LLM 推理主力
10	A100 (80G)	624	~$12,000	52	400	1.56	6.7	经典训练主力

参考价格为 2025 年初典型市场价（新卡），非官方 MSRP 的可能存在溢价。「每千美元 FP16 算力」= FP16 TFLOPS / (价格/1000)，越高越好。



🎯 12.应用场景推荐

根据你的实际需求，找到最适合的 GPU。

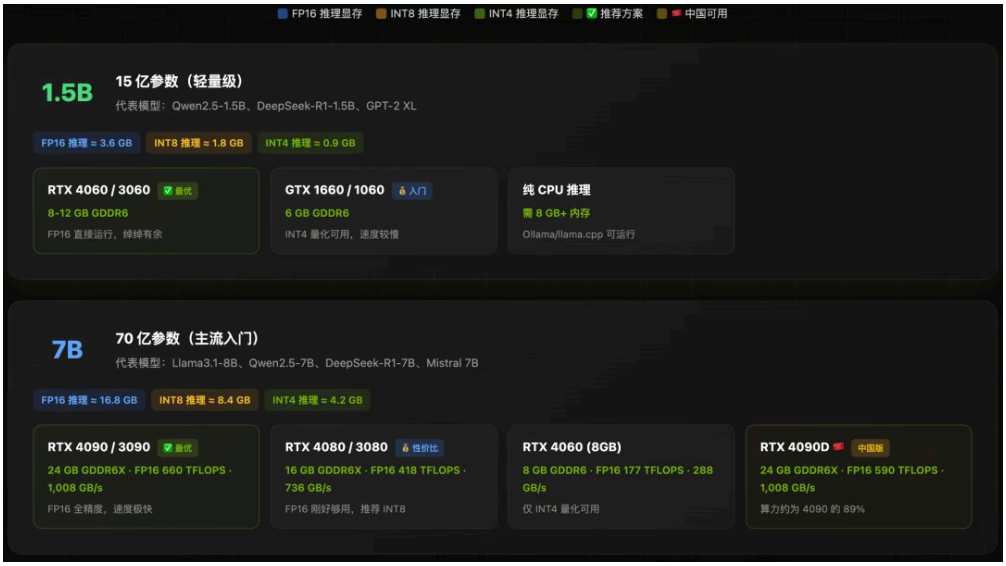


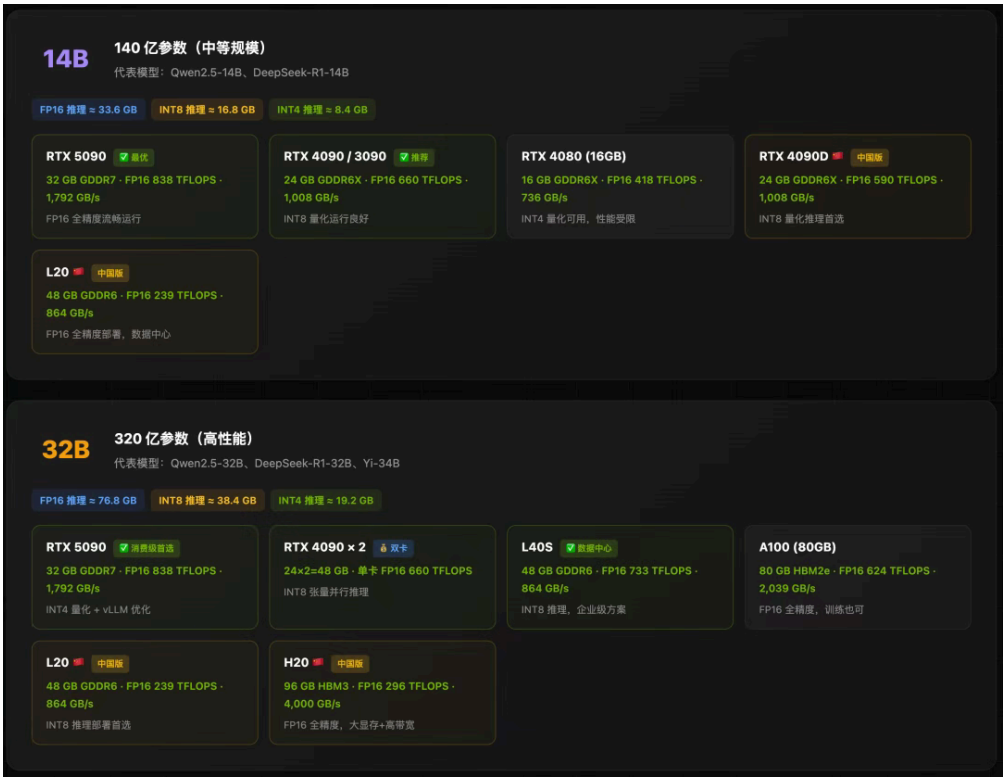


13.模型参数 × GPU 选择对照

不同参数规模的大模型（LLM），在推理和训练场景下对 GPU 显存的需求差异巨大。掌握估算方法，精准匹配硬件。




FP16 推理显存
INT8 推理显存
INT4 推理显存
推荐方案
中国可用
1.5B
15 亿参数（轻量级）
代表模型：Qwen2.5-1.5B、DeepSeek-R1-1.5B、GPT-2 XL
FP16 推理 ≈ 3.6 GB
INT8 推理 ≈ 1.8 GB
INT4 推理 ≈ 0.9 GB
RTX 4060 / 3060
最优
8-12 GB GDDR6
FP16 直接运行，绰绰有余
GTX 1660 / 1060
入门
6 GB GDDR6
INT4 量化可用，速度较慢
纯 CPU 推理
需 8 GB+ 内存
Ollama/llama.cpp 可运行
7B
70 亿参数（主流入门）
代表模型：Llama3.1-8B、Qwen2.5-7B、DeepSeek-R1-7B、Mistral 7B
FP16 推理 ≈ 16.8 GB
INT8 推理 ≈ 8.4 GB
INT4 推理 ≈ 4.2 GB
RTX 4090 / 3090
最优
24 GB GDDR6X · FP16 660 TFLOPS · 1,008 GB/s
FP16 全精度，速度极快
RTX 4080 / 3080
性价比
16 GB GDDR6X · FP16 418 TFLOPS · 736 GB/s
FP16 刚好够用，推荐 INT8
RTX 4060 (8GB)
8 GB GDDR6 · FP16 177 TFLOPS · 288 GB/s
仅 INT4 量化可用
RTX 4090D
中国版
24 GB GDDR6X · FP16 590 TFLOPS · 1,008 GB/s
算力约为 4090 的 89%


14B
140 亿参数（中等规模）
代表模型：Qwen2.5-14B、DeepSeek-R1-14B
FP16 推理 ≈ 33.6 GB
INT8 推理 ≈ 16.8 GB
INT4 推理 ≈ 8.4 GB
RTX 5090
最优
32 GB GDDR7 · FP16 838 TFLOPS · 1,792 GB/s
FP16 全精度流畅运行
RTX 4090 / 3090
推荐
24 GB GDDR6X · FP16 660 TFLOPS · 1,008 GB/s
INT8 量化运行良好
RTX 4080 (16GB)
16 GB GDDR6X · FP16 418 TFLOPS · 736 GB/s
INT4 量化可用，性能受限
RTX 4090D
中国版
24 GB GDDR6X · FP16 590 TFLOPS · 1,008 GB/s
INT8 量化推理首选
L20
中国版
48 GB GDDR6 · FP16 239 TFLOPS · 864 GB/s
FP16 全精度部署，数据中心
32B
320 亿参数（高性能）
代表模型：Qwen2.5-32B、DeepSeek-R1-32B、Yi-34B
FP16 推理 ≈ 76.8 GB
INT8 推理 ≈ 38.4 GB
INT4 推理 ≈ 19.2 GB
RTX 5090
消费级首选
32 GB GDDR7 · FP16 838 TFLOPS · 1,792 GB/s
INT4 量化 + vLLM 优化
RTX 4090 × 2
双卡
24×2=48 GB · 单卡 FP16 660 TFLOPS
INT8 张量并行推理
L40S
数据中心
48 GB GDDR6 · FP16 733 TFLOPS · 864 GB/s
INT8 推理，企业级方案
A100 (80GB)
80 GB HBM2e · FP16 624 TFLOPS · 2,039 GB/s
FP16 全精度，训练也可
L20
中国版
48 GB GDDR6 · FP16 239 TFLOPS · 864 GB/s
INT8 推理部署首选
H20
中国版
96 GB HBM3 · FP16 296 TFLOPS · 4,000 GB/s
FP16 全精度，大显存+高带宽







🧭 14.选购决策指南

不知道选哪张卡？跟着这棵决策树走一遍。



📝 本文数据整理自 NVIDIA 官方资料及公开报道，参考价格为发布时建议零售价（MSRP），实际价格因市场供需而异。

🇨🇳 中国特供版信息基于公开报道整理，部分规格可能因出口管制政策调整而变化。

📝 仅供科普参考，不构成购买建议。



腾讯技术工程
腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。
688篇原创内容

公众号

阅读 6911

留言

写留言

还没有留言，来写首评