三个关键词，2026谷歌 I/O大会全说透了

腾讯技术工程 May 20, 2026, 12:25 AM 广东 81 listened



导语

> 北京时间今天凌晨 1 点，谷歌 I/O 2026 在 Shoreline 圆形剧场落幕。整场 keynote 大约 1 小时 51 分钟，涉及十几款产品、三代模型、一个新 IDE、一个新 Agent、一套新搜索范式
>
> 但如果只能记一句话，那就是皮查伊（Sundar Pichai）在演讲第 16 分钟说的那一句。

"There are three areas where I want to go deeper today to show you the progress in each: **Models, coding, and agents.**"



这不是日程表，这是谷歌交给 AI 下半场的答题卡。

而这三块拼图最令人振奋的地方在于：

模型：Gemini 3.5 Flash 一个 "Flash 级" 的小模型，把谷歌自己三个月前的旗舰 Gemini 3.1 Pro 在几乎所有基准上**正面打穿**；

编程：Antigravity 用 93 个子 Agent、12 小时、不到 1000 美元，**从零造了一个能跑 Doom**

的操作系统；

Agent：Search 直接进入"**Search agents**"时代——它不再只回答你，**它开始替你做。**

这一夜，AI 第一次大规模地从"对话框"走进了"日常事"。

一、模型层：3.5 Flash 把自家上一代 Pro 干翻了，Omni 让 AI 第一次会"改"视频

1. 数据先行：每分钟 190 亿 tokens，13 个产品月活破 10 亿

讲模型之前，皮查伊先甩了一组数据，定调"现在到底有多大"：

- 谷歌每月处理 tokens：**从 9.7 万亿涨到 3.2 千万亿**；
- 每分钟处理：**190 亿 tokens**；
- 全球开发者：**850 万**；
- 月活破 10 亿的谷歌产品：**13 个**，其中 5 个超 30 亿；
- AI Overviews 月活：**25 亿**；
- AI Mode 上线一年，月活突破 **10 亿**；
- Capex 投入：**从 2022 年的 310 亿美元，飙到 2026 年的 1800–1900 亿美元**——四年 6 倍。

这是 Gemini 3.5 出场前的全部底气。



2. Gemini 3.5 Flash：今日全量上线，把自家上一代旗舰按在地上

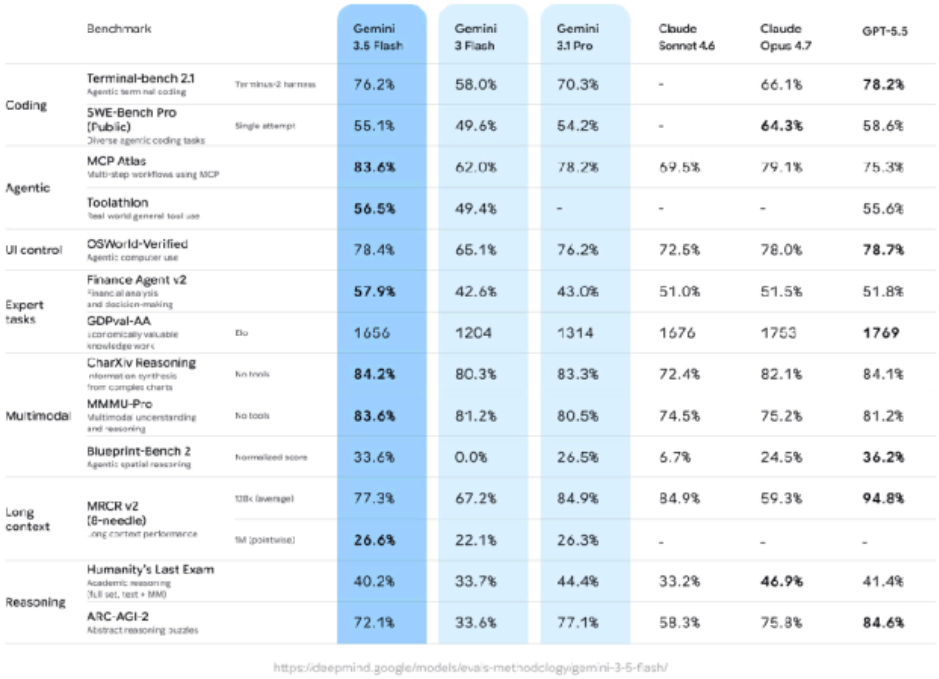
接下来是模型层最大一块石头——**Gemini 3.5 Flash 今日全量上线。**

- 今天起在所有谷歌产品和 API 中**全量开放**；
- **同时成为 Gemini App 与 Google Search AI Mode 的默认模型**——没错，你今天打开 AI Mode 搜的每一条，背后都已经是 3.5 Flash；

- **Gemini 3.5 Pro** 下个月跟上。

但真正让现场倒吸一口凉气的是数字：

- **速度**：输出 **289 tokens/秒**，比 GPT-5.5、Claude Opus 4.7 **快 4 倍以上**；
- **价格**：比同级前沿模型**便宜超过一半**；
- **性能**：**在几乎所有基准上，与自家三个月前的旗舰 Gemini 3.1 Pro 正面对标并实现反超。**



	Benchmark		Gemini 3.5 Flash	Gemini 3 Flash	Gemini 3.1 Pro	Claude Sonnet 4.6	Claude Opus 4.7	GPT-5.5
Coding	Terminal-bench 2.1 Agentic terminal coding	Terminus-2 harness	76.2%	58.0%	70.3%	-	66.1%	**78.2%**
	SWE-Bench Pro (Public) Diverse agentic coding tasks	Single attempt	55.1%	49.6%	54.2%	-	**64.3%**	58.6%
Agentic	MCP Atlas Multi-step workflows using MCP		**83.6%**	62.0%	78.2%	69.5%	79.1%	75.3%
	Toolathlon Real world general tool use		**56.5%**	49.4%	-	-	-	55.6%
UI control	OSWorld-Verified Agentic computer use		78.4%	65.1%	76.2%	72.5%	78.0%	**78.7%**
Expert tasks	Finance Agent v2 Financial analysis and decision-making		**57.9%**	42.6%	43.0%	51.0%	51.5%	51.8%
	GDPval-AA Economically valuable knowledge work	Elo	1656	1204	1314	1676	1753	**1769**
Multimodal	CharXiv Reasoning Information synthesis from complex charts	No tools	**84.2%**	80.3%	83.3%	72.4%	82.1%	84.1%
	MMMU-Pro Multimodal understanding and reasoning	No tools	**83.6%**	81.2%	80.5%	74.5%	75.2%	81.2%
	Blueprint-Bench 2 Agentic spatial reasoning	Normalized score	33.6%	0.0%	26.5%	6.7%	24.5%	**36.2%**
Long context	MRCR v2 (8-needle) Long context performance	128k (average)	77.3%	67.2%	84.9%	84.9%	59.3%	**94.8%**
		1M (pointwise)	**26.6%**	22.1%	26.3%	-	-	-
Reasoning	Humanity's Last Exam Academic reasoning (full set, text + MM)		40.2%	33.7%	44.4%	33.2%	**46.9%**	41.4%
	ARC-AGI-2 Abstract reasoning puzzles		72.1%	33.6%	77.1%	58.3%	75.8%	**84.6%**

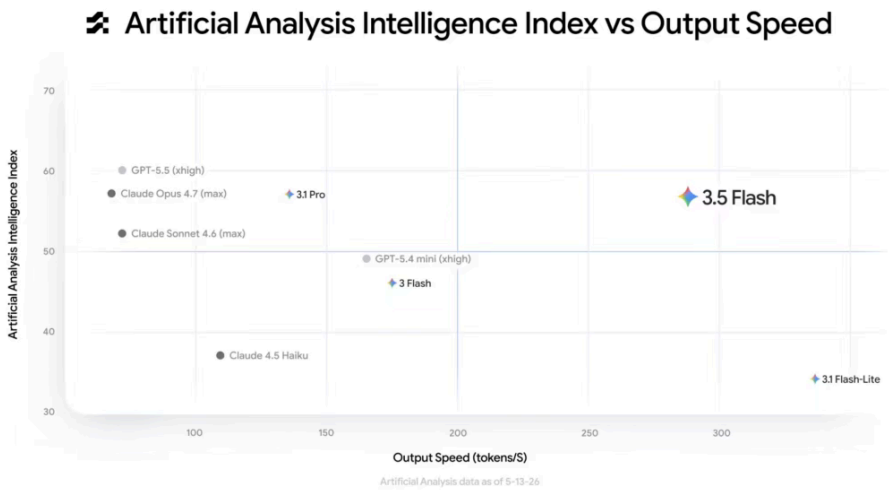
https://deepmind.google/models/evals-methodology/gemini-3-5-flash/

最后这一条值得停下来再读一遍——这是一个 **Flash 级**模型，在主要 benchmark 上**全面对标自家上一代 Pro**。换算到外部世界，约等于：一辆刚出厂的"经济款"，把自家三个月前的"性能旗舰"按在地上摩擦。

四组关键基准成绩：

基准	项目	3.5 Flash 成绩
Terminal-Bench 2.1	编码能力	**76.2%**
GDPval-AA	真实世界 Agent 任务	**1656 Elo**
MCP Atlas	大规模工具使用	**83.6%**
CharXiv Reasoning	多模态推理	**84.2%**

更暴力的是它对企业账单的杀伤力——皮查伊原话：**大客户若把 80% 的工作切到 3.5 Flash，一年能省下超过 10 亿美元的 API 成本。**



这是谷歌今晚扔在桌上的第一张牌：**"我用一个 Flash 级模型，把整个前沿模型市场的均衡价格区间，向下又拉了一档。"**

3. Gemini Omni：AI 第一次会"改"一段已经拍好的视频

如果说 3.5 Flash 是模型层的"性价比王炸"，那 Omni 就是模型层的"想象力天花板"。

Demis Hassabis 上台揭幕：**Omni 是一个原生的视频生成与编辑模型家族**，今晚发布的首款成员叫 **Gemini Omni Flash**，更强的 Omni Pro 不久后跟上。

它最炸的地方，**不是从零生成视频**——这事 Veo 早能做。

"Just like Nano Banana redefined image editing, **Omni gives you a much more natural way to edit video with conversational language**."

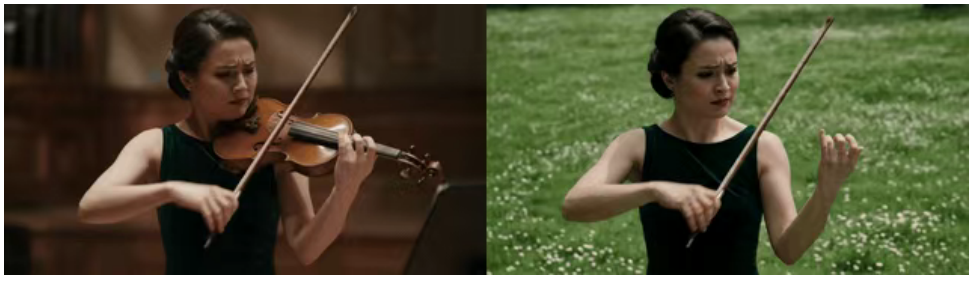
（正如 Nano Banana 重新定义了图片编辑，**Omni 让你能用对话式语言、自然地编辑视频**。）

—— Demis Hassabis

真正的跨越，是它能改一段已经存在的视频，而不破坏原有人物的表演。

你拍了一段 selfie，一句 prompt + 一张参考图，它能：把背景换掉、加上特效、塞进一个新角色——而你脸上的表情、肢体语言、说话节奏，**纹丝不动**。

这一步是从"生成"迈向"编辑"——而**这一步，正是创作者真正在意的那一步**。



发布会还顺手秀了一手原生**音视频同步生成**：画面、配乐、音效在同一次推理里出来，不再需要三个模型接力配菜。

首发渠道：Omni Flash 今日正式上线，同时接入 **Gemini App、Google Flow 和 YouTube Shorts**——其中 **YouTube Shorts 用户可直接免费使用**。to-C 的扩散速度，谷歌这次没省力气。

顺带一提，谷歌 AI 内容防伪水印 SynthID 自上线以来，**已为 1000 亿张图像和视频、6 万年时长的音频打上水印**——他们清楚 Omni 这种工具会带来什么。研究显示，人类只能正确识别约 25% 的高质量深伪视频，水印这件事不再是"可选项"。

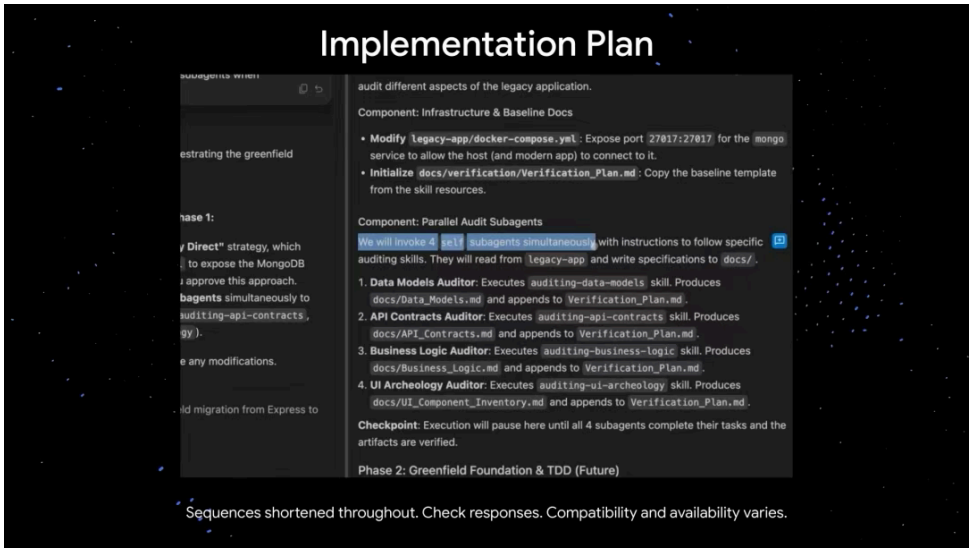
二、编程层：Antigravity 2.0——一个能跑 Doom 的操作系统

如果说模型层是地基，那今晚最让开发者血压升高的一段，全部发生在编程板块。

主讲人是 **Varun Mohan**——前 Codeium / Windsurf 创始人 CEO，加入谷歌后操盘 Antigravity。他给 2.0 写下的定位只有一句：

> **"Unabashedly agent first."（毫不掩饰地，Agent 优先。）**

1. 一组先扔出来的数据：Antigravity 内部已经"飞起来"了



光是 Antigravity 一个产品，谷歌内部处理 token 的速度——

从今年 3 月的 5000 亿/天，飙到现在的 3 万亿/天。

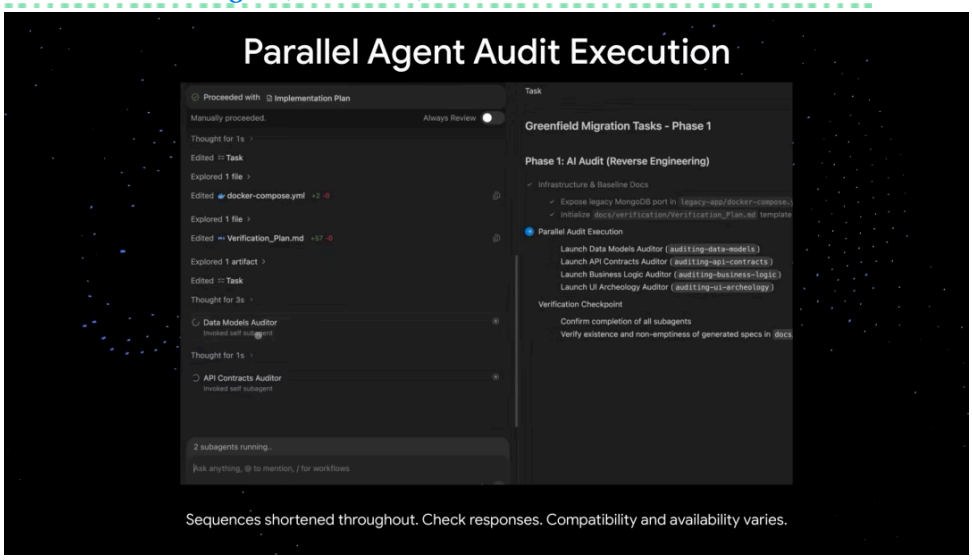
两个月，6 倍。 这是 Antigravity 在内部跑出来的真实加速度。

而开发者今天拿到的 Antigravity 里的 Flash，**是经过专项优化的 12× 加速版**——也就是 3.5 Flash 在同等任务上吞吐能再翻 12 倍。

2. Antigravity 2.0 给开发者的三件大事

- **全新独立桌面应用**：抛开传统 IDE 的"编辑器+插件"思路，把 *Agent 对话面板 / Agent 产物面板 / 多 Agent 编排面板* 做成一等公民；
- **CLI + SDK + 原生语音**：接入 Gemini audio 模型，可以直接用嘴和 Antigravity 谈需求；
- **Android、Firebase、AI Studio 全栈原生集成**；
- 底层引擎：**Gemini 3.5 Flash × Antigravity Agent Harness**，自带 sub-agents、hooks、async 三大原语。

3. 王炸时刻：93 个子 Agent，12 小时，造了一个能跑 Doom 的操作系统



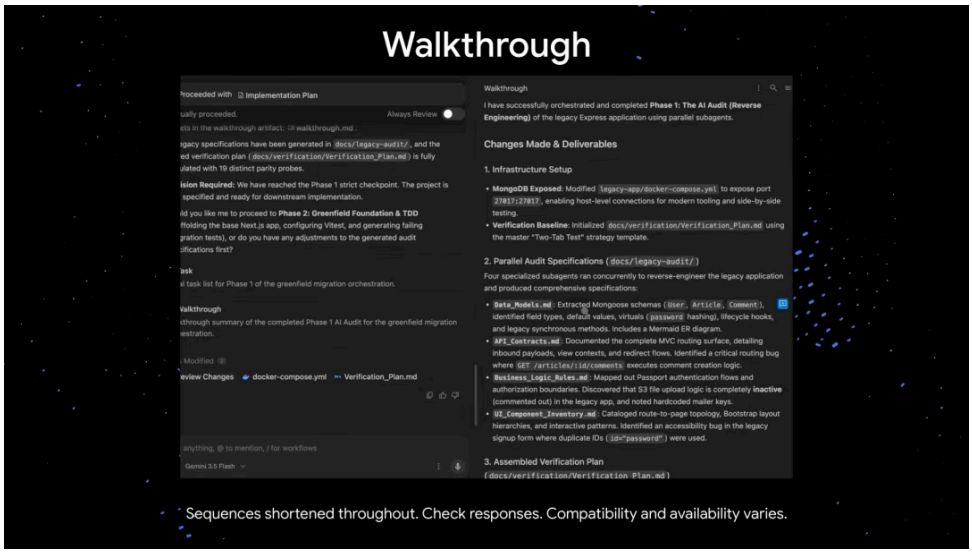
Varun 在台上点开了一个不可思议的实验记录——

指标	数字
子 Agent 并行数	**93 个**
总耗时	**12 小时**
模型请求次数	**超 15,000 次**
处理 tokens	**26 亿**
API 总成本	**不到 1000 美元**
产物	**一个能跑 Doom 的操作系统** （含调度器 / 内存管理 / 文件系统）

用谷歌自己的话说——

> "**调度程序、内存管理、文件系统，每一行代码都是 Agent 写的、Agent 测的、Agent 审计的。**"

现场演示更震惊：Varun 在自家 OS 里随手敲了个 `sl`（Linux 老 `ls` 输错梗），跳出一只小火车；接着试着跑 Doom——缺驱动；他随口让 Antigravity 自己去修——修好了，全场鼓掌。



一件以前需要一整支系统团队做半年的事。

Varun 给这件事下的定调，是今晚开发者圈最值得被钉在墙上的一句话：

> "**Multiday engineering efforts are collapsing into hours, if not minutes.**"（**以前要拉几天的工程任务，正在被压缩成几小时，甚至几分钟。**）

Antigravity 2.0 今天起全球开放。

三、Agent 层：Spark + Search Agents，AI 走出对话框的两条路径

到模块三，皮查伊把这一年的 "agentic" 叙事钉死：

> "We are firmly in our **agentic Gemini era**."
>
> （我们已经稳稳进入 **agentic Gemini 时代**。）

但 Agent 不是一个产品，而是**两条铺设路径**——

- 一条是 Gemini App 里的主控大脑 **Spark**；
- 一条是直接长在全球最大入口里的 **Search Agents**。

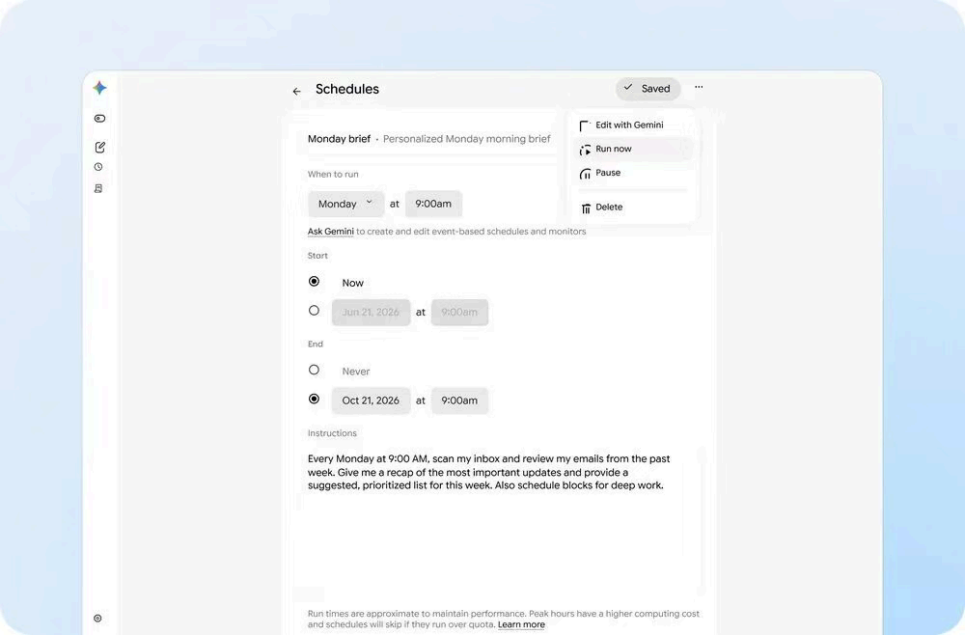
1. Gemini Spark：你的 24×7 数字管家

Spark 是 Gemini App 里新冒出来的彗星图标。它的定位非常直白：

> "It's your personal AI agent that helps you navigate your digital life, taking action on your behalf and under your direction. **It runs on dedicated virtual machines on Google Cloud,**

> **and it is 24/7."**

翻译成人话：**它是一台 7×24 小时不打烊、托管在谷歌云上的"你"。**



关键设计：

- UI 是 **Chat / Agent 双 Tab**——Chat 还是问答，Agent 才是派活；
- 跨端：网页 / 桌面 / Android & iPhone 实时同步；接下来还会铺到 **邮件 + IM**；
- 能跑**定时任务**（"每周一 8 点把上周会议纪要整理给我"）；
- 通过 MCP 协议，**未来几周打通第三方工具**；
- 数据视野：连接的 Google 应用 + 聊天记录 + 已登录网站 + Personal Intelligence 个人画像 + 实时位置；
- **下半年**，Spark 将**直接落地到 Chrome 里**，成为 "agentic browser"——这就是去年传闻已久的 "Chrome Auto Browse" 叙事的真正归宿；
- 同期还会推出 **Android Halo**——手机上专门为 Agent 准备的"基地"。

节奏与价格：

- 本周：仅对 trusted testers 灰度；
- **下周**：向**美国 Google AI Ultra 订阅用户**开 Beta；
- **AI Ultra 订阅同步调整**：
  - **新增 $100/月 入门档**——这是开通 Spark Beta 的最低门槛；
  - **最高档 Ultra 计划从** 250 降到**200/月**；
- 此外，Gemini App 同步改版（代号 Neural Expressive），**计费模式改为按算力计费**。

> ⚠️ **Spark 自带的诚实自白：**Spark 是实验性产品。虽然它被设计成在敏感操作前征求许可，但它可能在未询问的情况下分享你的信息或代你完成购买。请勿依赖它做医疗、法

> 律、财务等专业决策。
>
> —— 这段话是谷歌自己写在产品安全说明里的。它不是免责声明，是当下所有 agentic 产品集体面对的真实风险。

2. Search 的 25 年最大改版：进入 "Search Agents" 时代

接下来上台的是 **Liz Reid**（谷歌搜索负责人）。她甩出今晚 Agent 板块第二组震撼数据：

- AI Mode **上线刚一年**，月活突破 **10 亿**；
- AI Mode 查询数**自上线以来每季度翻倍**；
- 已升级到 **Gemini 3.5**——现在打开 AI Mode，你用的就是它。

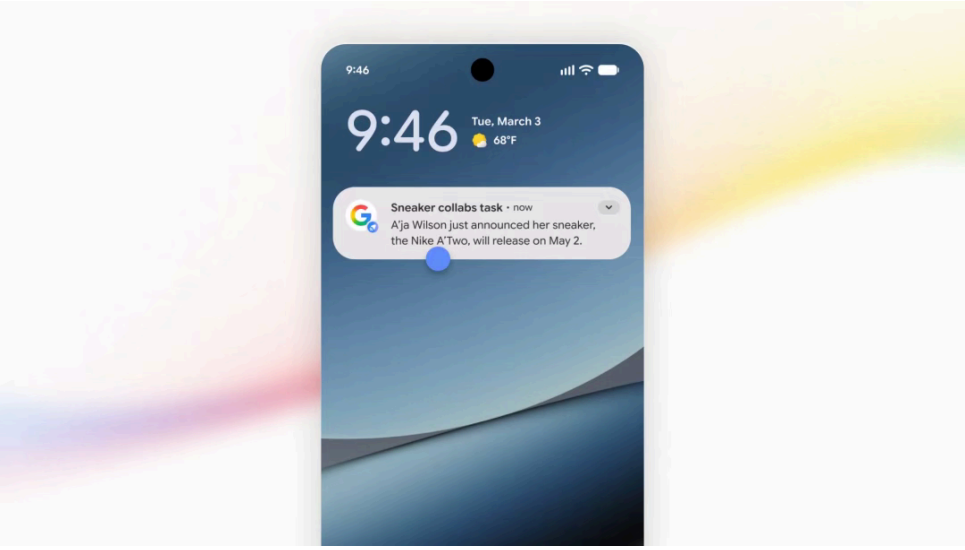
然后她说出全文最值得划线的那句：

> **"We're entering the era of Search agents."**
>
> **（我们正在进入"搜索智能体"的时代。）**

3.三件具体的事

(1) 全新的 AI 搜索框 —— 25 年来最大的一次搜索框升级。原生支持**文本 / 图像 / 文件 / 视频混合输入**，AI Overviews 与 AI Mode 之间无缝切换。

(2) Information Agents（信息智能体）—— 24×7 在后台替你"盯着"



它主动监控你交代过的事：

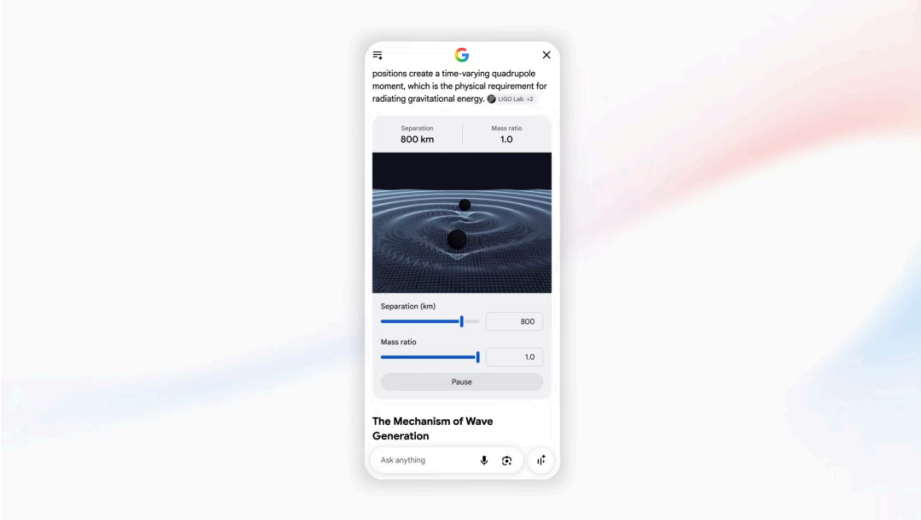
- demo 1：**监控生物科技板块"市盈率<15、正现金流、低负债"的股票**，命中即推送；
- demo 2：**租房**——你随口讲一段需求，它持续在背后筛新房源；
- demo 3：**心仪球鞋一发售即时预警。**

预计的上线时间：**今年夏天**。

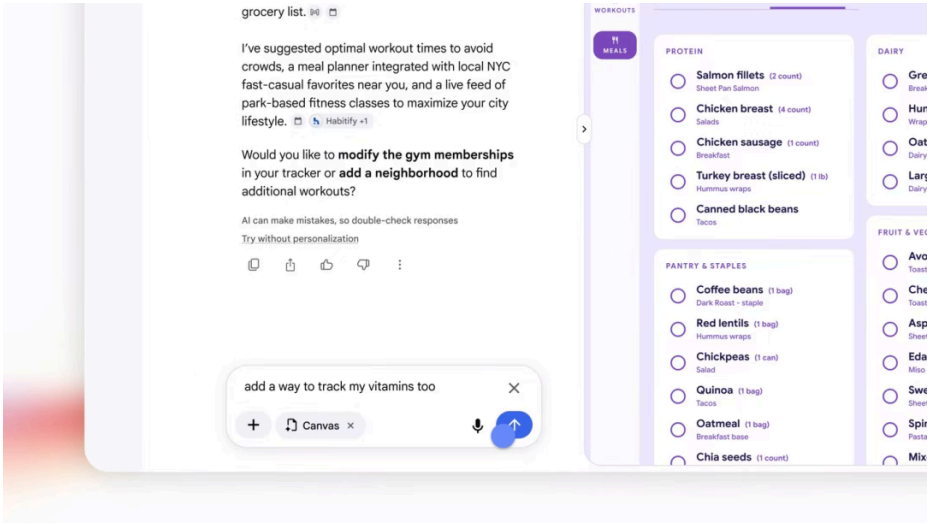
(3) Generative UI in Search —— Antigravity 直接被嵌进 Search 后端

这是今晚 Search 部分最反直觉的一段。

- demo 1：问一个关于黑洞引力波的物理问题，**Search 现场写出了一个交互式可视化 mini-app**；



- demo 2：Search 主动提议——"要不要给你做个**周末家庭计划器**？"它结合 Gmail / Photos / Calendar 里的家庭画像，实时排出周末两天的行程，能转发给老婆、能一键同步到全家共享日历。



预计上线时间：**今年夏天免费向所有人开放。**

> **这意味着什么？** 意味着 Search 不再只是给你一个"答案页"——它给你一个**为你这个问题专门生成的临时 App**。

4.顺带的一颗长期变量：UCP（Universal Commerce Protocol）

Search 章节末尾，Vidhya Srinivasan 抛出了一个野心更大的东西——**UCP 通用商业协议**：

> "**UCP does for agentic commerce what HTTP did for the web**: It gives agents and systems a common language."
>
> （**UCP 之于 agentic 商业，正如 HTTP 之于 Web**——它让所有 Agent 和系统说同一种语言。）

谷歌 Shopping Graph 已收录 600 亿条商品，这是 UCP 一上来就能撑住的底盘。这一步如果跑成，"AI 替你购物"就不再是各家厂商各自的小作坊，而是整个互联网商业层的协议级重构。

四、把三块拼图咬合起来看：谷歌究竟在赌什么？

把今晚的三块板块叠在一起，会浮出一句异常清晰的判断：

> **AI 第一次大规模地，从"对话框"走进了"日常事"。**

- **模型** → Omni 让 AI 第一次能改一段已经拍好的视频；
- **编程** → Antigravity 用 1000 美元造了一个能跑 Doom 的操作系统；
- **Agent** → Spark 24×7 替你跑后台，Search 边搜索边替你下单。

OpenAI 的 Agent 平台、Anthropic 的 Conway、微软的 Agent 365 都在路上。但谷歌今晚交出的这份答卷，差异化只有一句话——

> **"我把 Agent 直接装进了你每天必开的搜索框和 Gemini App。"**

这场 Agent 决赛的胜负手，可能不在谁的模型 benchmark 高一两个点。

它在——谁能把 AI 真的铺到 10 亿人的日常里。

谷歌握着三个一般人一抬手就会用到的入口：Gemini App（Spark）+ Google Search（Search Agents）+ Antigravity（开发者）——这是一道别家短期内复制不出来的分发护城河。

至于另一面：当一个 24×7 的 Agent 拥有你的邮箱、相册、日历、位置和支付权限时，安全边界谁来守？谁来负责？——这是谷歌今晚没能给出完整答案的题，也是接下来一年所有大厂都绕不开的题。

五、写在最后

回头看皮查伊那句开场白——"**Models, coding, and agents.**"——它其实不是日程表，是谷歌交给 AI 时代下半场的答案：

- 模型继续往前推（更便宜、更多模态、能编辑而不只是生成）；
- 编程被 Agent 重写（一个人 + 一群子智能体 = 一个工程团队）；
- Agent 借着搜索框和 App 入口，第一次真正走进了 10 亿人的日常。

> **AI 不再只回答你，它开始替你做。**

你最期待哪一件事先发生在自己身上？——

- □ Spark 替你管收件箱和日程
- □ Search Agent 替你抢球鞋 / 监控租房 / 盯股票
- □ Antigravity 替你写下一个项目的代码

评论区聊聊。

一分钟视频速览





腾讯技术工程
腾讯技术官方号。腾讯技术创新、前沿领域发布解读平台。
688篇原创内容

公众号



作者提示: 内容由AI生成
阅读 9337　修改于2026年5月20日

留言

写留言

还没有留言，来写首评