阿里巴巴 12 篇论文入选全球网络顶会 SIGCOMM 2026（内附下载）

原创 阿里学术 阿里技术 2026年8月19日 03:25 浙江 5人

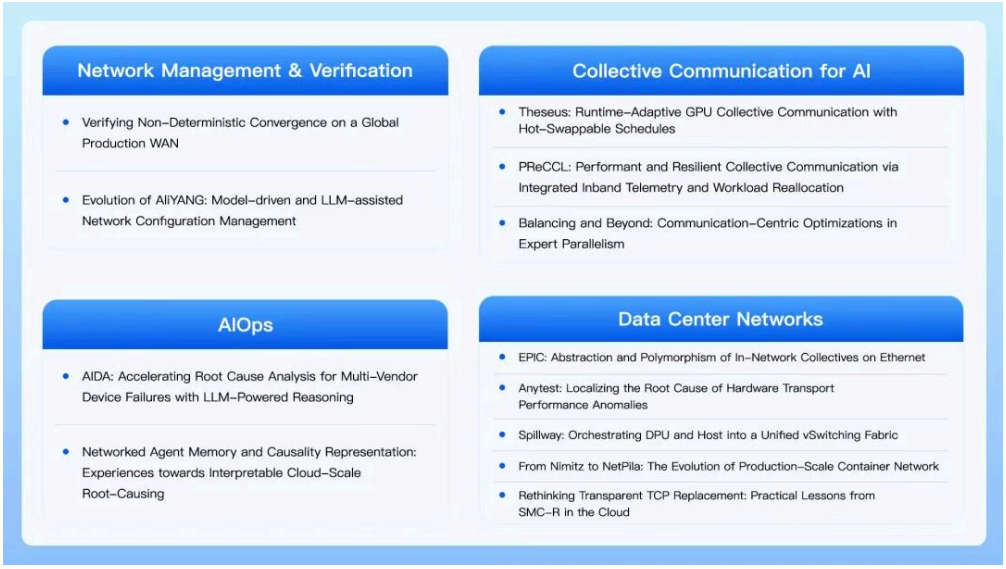


这是2026年的第 53 篇文章

（ 本文阅读时间：约 15 分钟 ）

日前，计算机网络与通信领域顶级国际学术会议 SIGCOMM 2026在美国丹佛召开，阿里巴巴集团共有 **12** 篇论文被主会收录，在全球企业中处于领先身位。作为唯一与顶尖高校/科研院所同处第一梯队的中国产业界机构，论文研究成果涵盖AI 智算网络与集合通信、云网关数据面、网络验证、智能运维等技术方向，以持续突破再次获得国际学术界的认可。

SIGCOMM 是计算机网络领域公认的最高级别国际学术会议（CCF A 类），常年录用率仅 15%—22%，含金量极高。



阿里巴巴资深技术专家翟恩南联合担任第三届 ACM SIGCOMM 形式化方法辅助网络运维研讨会（The 3rd ACM SIGCOMM Workshop on Formal Methods Aided Network Operation，FMANO）大会主席，阿里巴巴高级技术专家袁驿飞主持本届研讨会。研讨会汇聚学界网络研究人员与互联网服务提供商，围绕形式化方法在网络运维中的应用展开充分讨论，以提升网络的可用性、可靠性与性能。



以下为各论文解读⬇️

Network Management & Verification

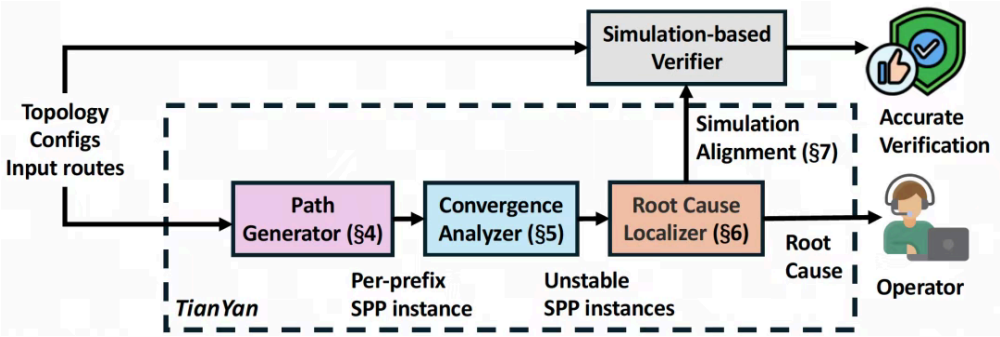
1.Verifying Non-Deterministic Convergence on a Global Production WAN

大规模生产级广域网依赖仿真验证工具保障配置正确性，阿里云自研的 Hoyan 及业界同类工具均假设 BGP 控制平面收敛到唯一确定的数据平面。然而，非确定性收敛——同一配置因收敛时序不同而产生多个稳定数据平面——使验证器报告"正确"而实际网络已偏离预期，由此引发的流量黑洞等事故事后才被发现。在数千台路由器、数十万条链路的WAN上验证该问题面临指数级可扩展性挑战，现有方法均无法适用。

论文提出了业界首个在全球生产级 WAN 上验证非确定性收敛的系统——TianYan。其核心洞察是：生产网络中同组路由器因共享相似策略，其路由行为具有可预测的相似性。TianYan据此证明两条剪枝定理，将路径搜索空间从路由器级压缩至组级，实现指数级缩减且不影响分析正确性。系统采用四阶段流水线：首先通过改进的路由仿真为每个前缀构建精简的收敛分析模型；然后以多项式时间算法对全量 200 万前缀快速筛选，识别约 4 万疑似前缀，再按根因分组将耗时的约束求解从数万次缩减至约百次；接着自动定位导致非确定性收敛的根因——具体到哪些路由器及冲突策略；最后通过消除争议环或对齐仿真至实际网络状态，恢复验证准确性。

TianYan 已部署超一年，发现约2%前缀（~4 万）存在非确定性收敛，识别约 100 类根因，将约 3 万前缀的验证结果从错误对齐至正确，首次揭示非确定性收敛在生产WAN中的广泛性与实际影

响。相关结果已帮助运维团队识别多个此前未被察觉的设计与实现缺陷，并上报推进治理。



> 论文下载地址：
> https://dl.acm.org/doi/pdf/10.1145/3789240.3829180

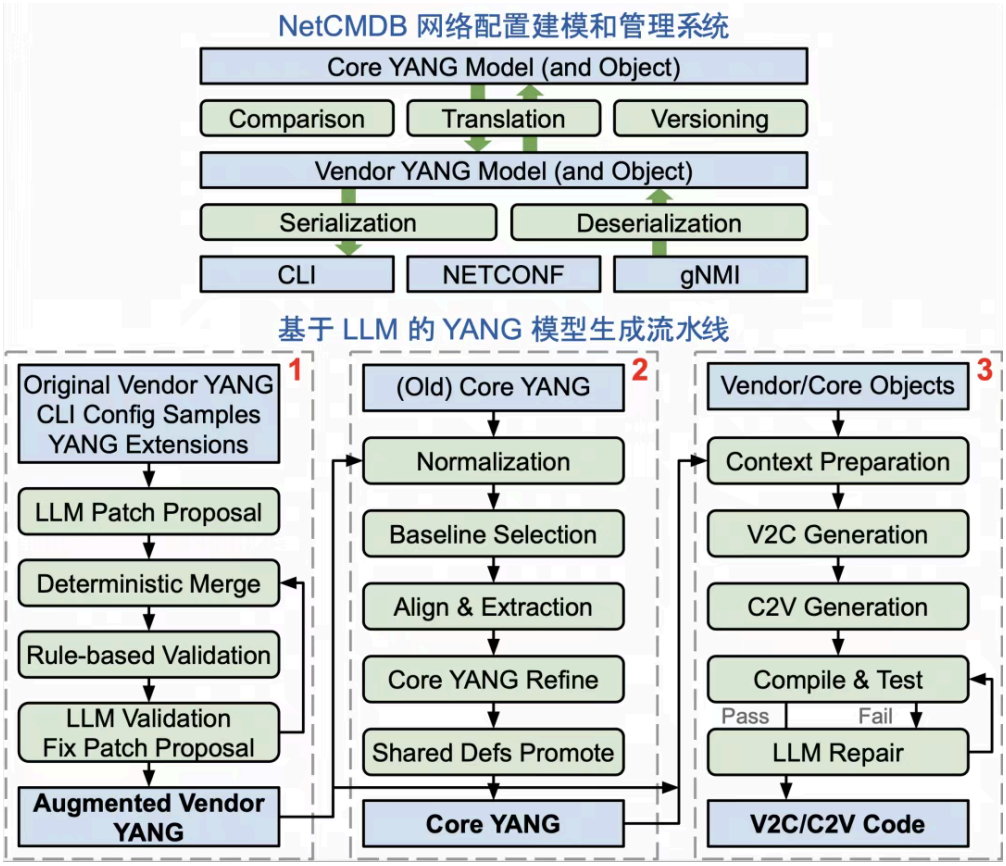
2.Evolution of AliYANG: Model-driven and LLM-assisted Network Configuration Management

在大规模云网络中，多厂商设备、CLI/NETCONF/gNMI 等多种管理接口以及持续变化的网络架构，使配置管理长期依赖大量厂商专用模板和脚本。阿里云生产环境中，仅配置生成、变更与审计就积累了数万套模板和数百万行代码，重复逻辑多、验证困难，也难以随网络快速演进。

AliYANG 的核心思想，是把配置语义从易碎的文本模板中抽离出来，沉淀为统一、可执行的模型。它扩展标准 YANG，使模型既能描述结构化接口，也能表达 CLI 命令的语法、层级、删除方式及语义比较规则。厂商增强模型保留设备真实能力，厂商无关的 Core YANG 则统一跨厂商配置语义，实现“语义与实现解耦”。

NetCMDB 将模型编译为强类型配置对象，为翻译、序列化、比较和版本管理提供生产级运行时能力，使网络架构设计、全量配置生成、增量配置变更和持续配置审计都基于同一套模型完成。系统进一步引入 LLM，辅助厂商模型增强、核心模型设计和双向翻译代码生成，并通过确定性合并、编译和测试闭环保障质量。

该系统已连续生产运行三年，管理十万级设备和超过十亿行配置；全网配置查询由 20 余小时缩短到秒级，新厂商接入工程投入降低4至6倍。AliYANG 表明，模型可以成为配置管理长期演进的控制点，而 LLM 更适合在离线、可验证的工程闭环中加速模型演进。



论文下载地址：

https://dl.acm.org/doi/pdf/10.1145/3789240.3829193

AIOps

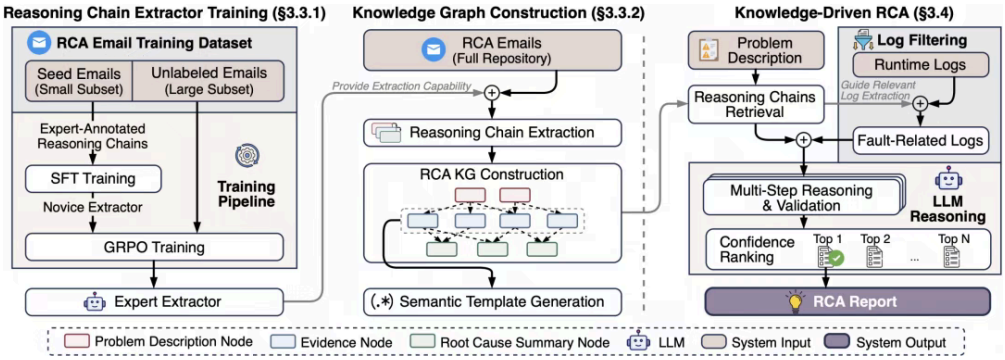
1.AIDA: Accelerating Root Cause Analysis for Multi-Vendor Device Failures with LLM-Powered Reasoning

在云网络故障处置中，监控系统通常能快速定位“哪台设备出了问题”，但回答“为什么出问题”仍依赖运营人员与设备厂商反复收集日志、邮件沟通。厂商专有知识分散在大量非结构化历史邮件中，故障类型长尾且持续演进，使传统机器学习、日志模板和通用 RAG/LLM 难以兼顾精度、可解释性与泛化能力。

AIDA 的关键思路，是把历史故障处理中隐含的专家诊断逻辑结构化，再用当前设备日志逐步核验，而不是让 LLM 直接猜测根因。离线阶段，AIDA 通过监督微调和 GRPO 强化学习训练专用提取器，将邮件蒸馏为“问题描述—诊断证据—根因结论”的可解释推理链；随后利用结构感知的图融合方法合并等价节点、消除冗余并保留不同因果路径，构建可持续更新的 RCA 知识图谱，同时生成语义日志模板。

在线诊断时，AIDA 根据故障描述检索候选推理链，从海量日志中筛选相关证据，再对证据节点和完整推理链进行分步验证与置信度排序，最终输出包含关键日志、历史案例和推理过程的根因报告。若证据不足或链条存在矛盾，系统会拒绝下结论并转交人工，避免基于局部证据误诊。

AIDA 已在阿里云生产网络部署超过一年，处理 846 起设备故障，诊断精确率达到95.4%；中位根因分析时间由 72.6 小时缩短至 1.6 分钟，复杂长尾案例的 P90 由 329.9 小时降至 19.4 小时。实践表明，可靠的 LLM 诊断不仅依赖模型能力，更依赖结构化知识与可验证推理闭环。



> 论文下载地址：
> https://dl.acm.org/doi/pdf/10.1145/3789240.3829126

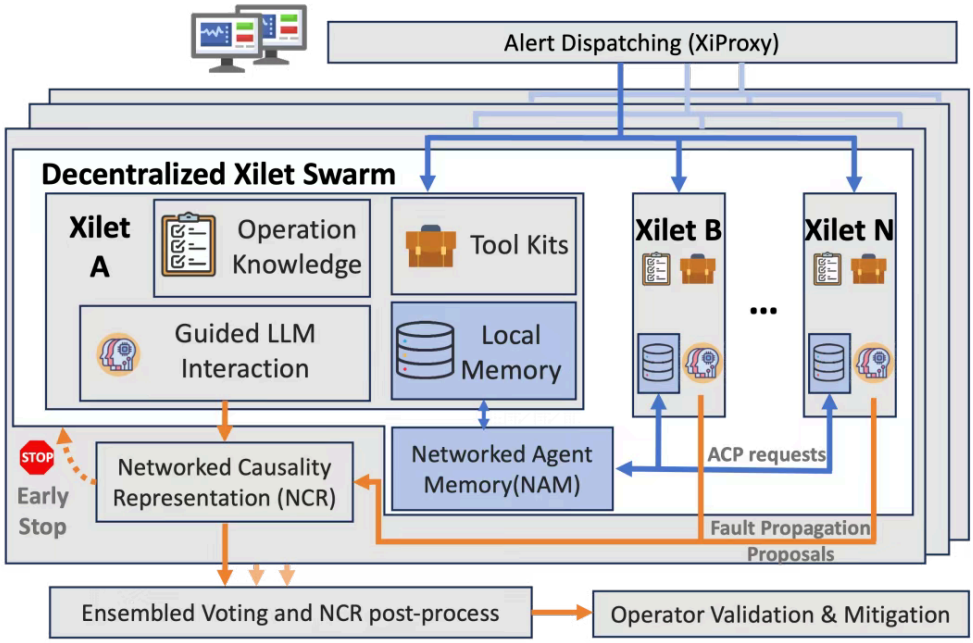
2.Networked Agent Memory and Causality Representation: Experiences towards Interpretable Cloud-Scale Root-Causing

在大规模物理网络中，设备或链路故障的影响常沿物理拓扑、路由路径和协议依赖逐级扩散，几分钟内即可触发数千条异构告警。规则系统难以覆盖未知故障；单智能体受上下文限制，面对告警风暴常需截断信息，容易遗漏关键因果信号，且难以将诊断结论与原始告警对应，无法支撑运维人员核验传播过程和开展生产处置。

论文提出面向生产网络根因定位的多智能体系统 XiHe。XiProxy 归一化并分发告警，再按设备故障域或告警特征，将任务分派给去中心化的 Xilet 智能体群。各 Xilet 在运维知识库约束下调用工具开展证据推理，以适应未知故障并减少无依据的推断。

为兼顾规模与全局视角，XiHe 设计网络化智能体记忆，使各 Xilet 通过拓扑感知通信共享根因假设、因果依赖和验证结果；同时利用网络化因果表示，将分布式推理汇聚为统一因果图，关联异常类型、故障域和原始告警，呈现根因到业务症状的传播路径。Xilet 并行推理，配合集成投票和因果图稳定后的早停机制，进一步提升结果稳定性与时效性。

XiHe 已在阿里云生产网络部署超过 12 个月，协助处理 3000 余起事件，整体根因定位准确率达到 94.6%；与最佳现有方法相比，诊断错误减少 54.9%。即使告警量扩大百倍，准确率仍保持 90.0%。结果表明，可验证因果链不仅能提升诊断效果，也能增强运维人员对 AI 诊断的信任。



论文下载地址：
https://dl.acm.org/doi/pdf/10.1145/3789240.3829145

Collective Communication for AI

1.Theseus: Runtime-Adaptive GPU Collective Communication with Hot-Swappable Schedules

当前 GPU 集合通信库（CCL）采用为稳定环境预设的调度，其支持的调度集合与选择逻辑在 communicator 初始化时即固定，无法反映运行时不断变化的条件，如 workload 特征与硬件健康状态。因此长时间运行的 GPU 作业在执行数小时乃至数天后性能明显下降，导致作业完成时间变长、集群资源浪费。NCCL/RCCL 等库只能在静态调度空间内做有限调整，初始化后无法接纳新调度或改变通信结构。

Theseus 是一个提供“调度级”运行时自适应能力的新型 CCL 后端，允许用户自定义调度与选择策略，并作为 drop-in 替代方案便于集成。它的两大核心特性是动态选择与热切换。

动态选择方面，Theseus 设计了 selection context，让用户能用跨集群的运行时条件（超出 CCL 内部指标）灵活指定策略，并通过定制的 agreement 协议保证各 GPU 选择一致，把每次请求的协商开销摊薄到近乎为零。热切换方面，它用资源管理树分层组织调度资源，实现调度间高效的资源共享；当旧调度不再合适、需要替换时，做增量的 delta 迁移而非从零重建，从而以低开销、无中断地在所有 GPU 间一致地切换调度。

在多种 GPU workload 与直观策略下的评测表明，相比 NCCL，Theseus 在稳定环境下通信时间最多加速 1.61×，动态环境下最多加速 2.46×，端到端作业完成时间最多提升 1.84×，且开销相当或更低。

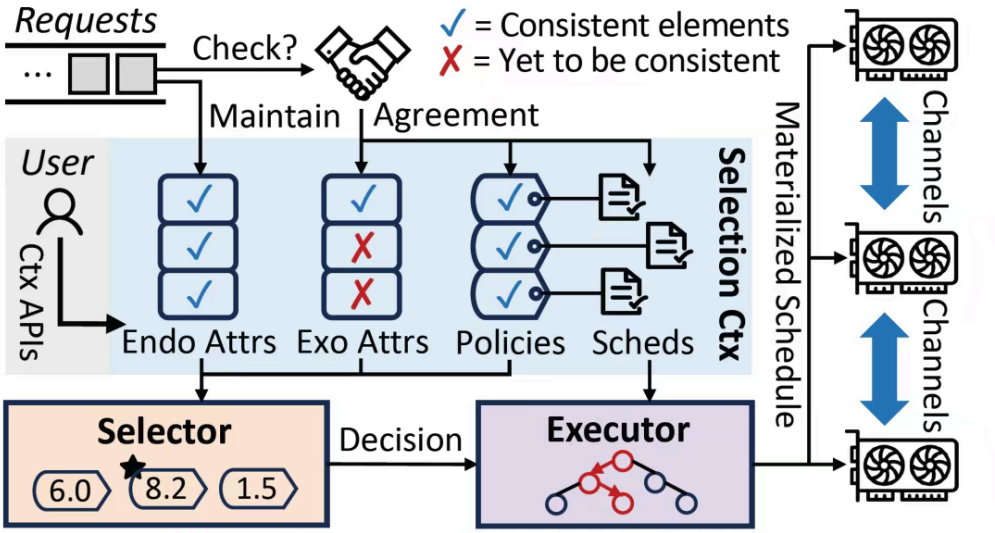


Figure 6: Architecture of Theseus.

论文下载地址：

https://dl.acm.org/doi/pdf/10.1145/3789240.3829134

2.PReCCL: Performant and Resilient Collective Communication via Integrated Inband Telemetry and Workload Reallocation

现代集合通信库（CCL）把一次集合通信任务（CCT）拆解为多个子任务，各自映射到一个虚拟拓扑（VT，如 ring 或 tree）以最大化并行度与链路利用率。随着 AI 训练扩展到更大集群，拥塞与故障不可避免，任何一个掉队的 VT 都会拖慢整个 CCT。现有方案要么依赖底层传输层机制、缺乏跨子任务视角，要么采用静态 CCL 调度、无法适应动态异构网络。

PReCCL 是一个可直接替换 NCCL（drop-in）的方案，将软件在带内（inband）遥测与跨 VT 工作负载再分配相结合。不同于依赖专用硬件的遥测（如 P4-INT），PReCCL 在 CCL 内部实现在带监控，精确测量每个 VT 的 stall 计数，并把遥测元数据搭载在已有的集合通信流量上，几乎不引入额外传输。

借助这种细粒度可见性，PReCCL 用动态跨 VT 再分配机制，把拥塞或故障导致的掉队 VT 上的负载迁移到健康 VT。再分配只在 CCT 边界发生：每个 CCT 标记 epoch，各 rank 从同一 epoch 元数据确定性地计算下一次分配，在途 CCT 不被修改，也不新建或销毁 NCCL 连接，仅调整已有通道上的字节范围，从而避免跨 rank 一致性竞争、无需额外同步；部分故障同样以此机制屏蔽并重分配，训练不中断。

PReCCL 在 32 卡 GPU 测试床、大规模仿真和 1024 卡生产集群上评测。在测试床上，CCT 完成时间最多提升 2.1×，端到端训练提升 1.21×，且在调优的消息大小阈值之上开销很低。结果表明，CCL 自身正是兼顾性能与韧性的最佳观测与调控点。

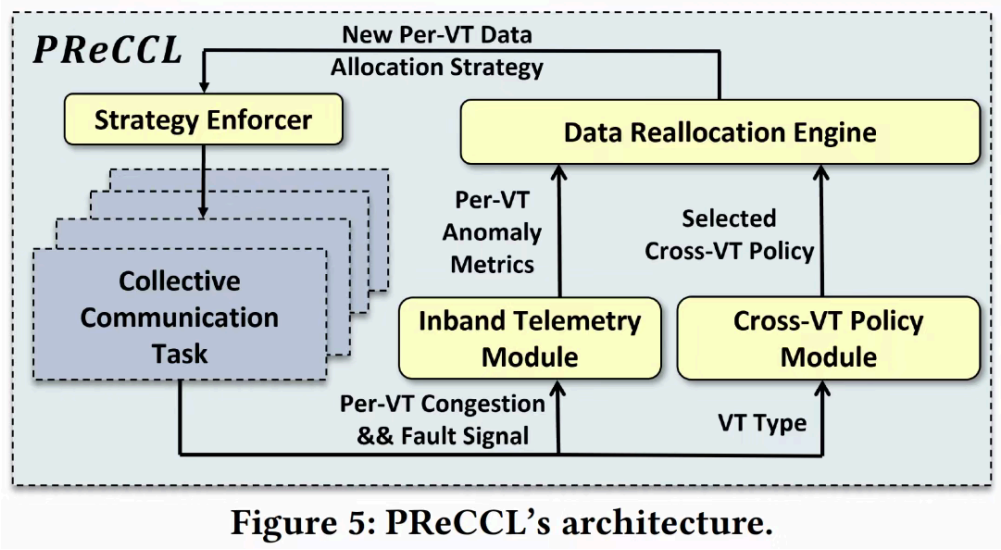


Figure 5: PReCCL's architecture.

> 论文下载地址：
> https://dl.acm.org/doi/pdf/10.1145/3789240.3829133

3.Balancing and Beyond: Communication-Centric Optimizations in Expert Parallelism

混合专家（MoE）架构通过每个 token 只激活少量专家，把大语言模型扩展到万亿参数规模。生产中的 MoE 推理通常采用专家并行（EP），把整块专家放置到不同 GPU 上以保持 GEMM/kernel 效率。然而线上 EP 部署常受两个瓶颈困扰：一是专家负载不均，产生计算与通信上的掉队者；二是通信低效，即便负载均衡后 GPU 间传输仍主导延迟。EPLB 等现有方案靠周期性按历史统计重排专家，但无法实时调整，且只均衡计算、忽视网络流量，使不均衡仍是尾延迟的主要来源。

EPIC 是一个经验驱动的 EP 推理系统，针对真实部署逐步解决上述问题。它先通过性能感知的专家迁移与运行时专家激活缓解负载不均，再用拓扑自适应的传输 kernel 与细粒度的计算—通信重叠改善通信效率。

在均衡侧，EPIC 融合拓扑感知的专家放置与低成本迁移，同时均衡计算与通信；在通信侧，它提供拓扑感知传输 kernel 与去冗余机制以消除重复传输，并做每专家的细粒度计算来隐藏通信而不损失 GEMM 效率。EPIC 会根据不同场景自动选择最合适的优化策略组合，以取得最佳性能。

EPIC 已在线上推理服务中以 O(10K) GPU 规模部署，服务开源模型（如 Qwen3-Coder、DeepSeek-R1）与内部自研模型。在保持服务稳定的同时，将通信时间与每 token 延迟（TPOT）最多分别降低 40% 和 21%，TPS 最多提升 27%。

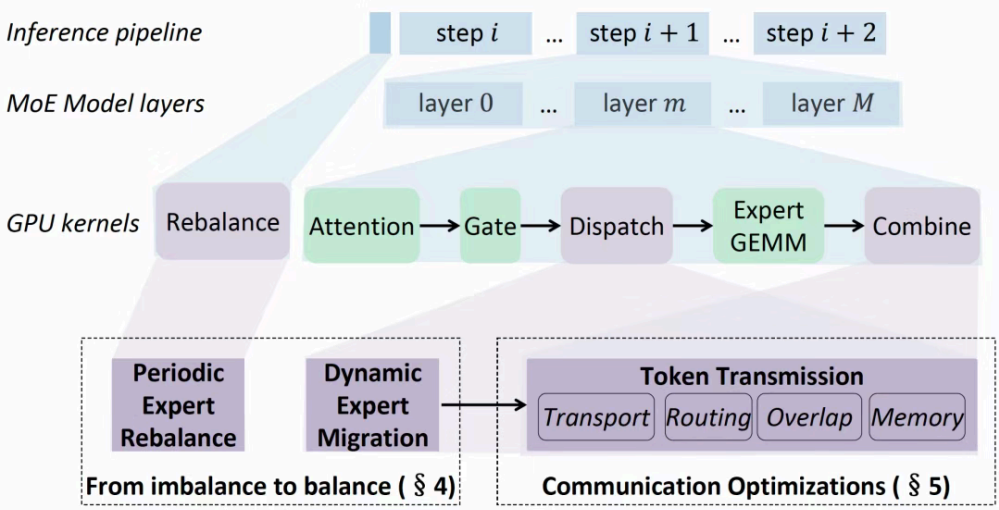


Figure 5: EPIC's system architecture overview

论文下载地址：

https://dl.acm.org/doi/pdf/10.1145/3789240.3829201

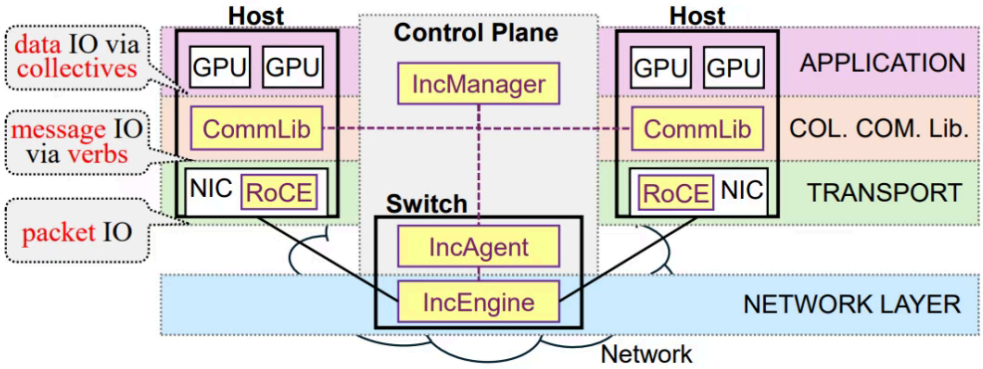
Data Center Networks

1.EPIC: Abstraction and Polymorphism of In-Network Collectives on Ethernet

在网计算将集合通信卸载到网络交换机进行，可以压缩流量，进而加速传输过程。在网计算系统的构成通常包括交换机、网卡、协议栈、通信库、网络管理器；但是在开放以太网生态中，上述组件分属不同的供应商或者开发者，彼此之间存在依赖。以太网生态的的供应商和开发者在自己的功能范围内无法实现整体的系统；在单独一个生态位实现自己功能而缺乏其他厂商配合的情况下，其研发投入无法体现为系统级别的加速能力，造成低效的投入回报比。

高通量以太网联盟作为标准组织，设计了EPIC协议（Ethernet Polymorphic In-network Collective）；依靠“统一抽象、多态实现”的核心思路，给出了协议规范和参考实现。协议规范中，功能组件的划分按照以太网供应商的功能范围划分，且保持已有接口规范；在协议参考实现中，EPIC给出符合协议规范的三种形态的交换机设计，都可以与网卡正确互操作，允许不同硬件能力的交换机厂商广泛参与。EPIC的设计另外克服了三项挑战：采用形式化协议验证的方法分析和确认了三种形态协议的正确性；采用模块化设计的方法设计三种协议，允许三种形态的协议从简到繁的演化，降低研发成本；在统一抽象基础上设计了基于SDN结构的资源管理方案，适用于多种人工智能训推场景。

EPIC协议规范交付给高通量以太网联盟的成员进行实现和验证，联盟通过协议验证平台测试了协议正确性，通过可编程交换机平台验证了加速效果和RDMA协议兼容性，通过模拟平台测试了协议在大规模集群下的资源利用率，通过FPGA/RTL级实现和测试验证了芯片可行性。



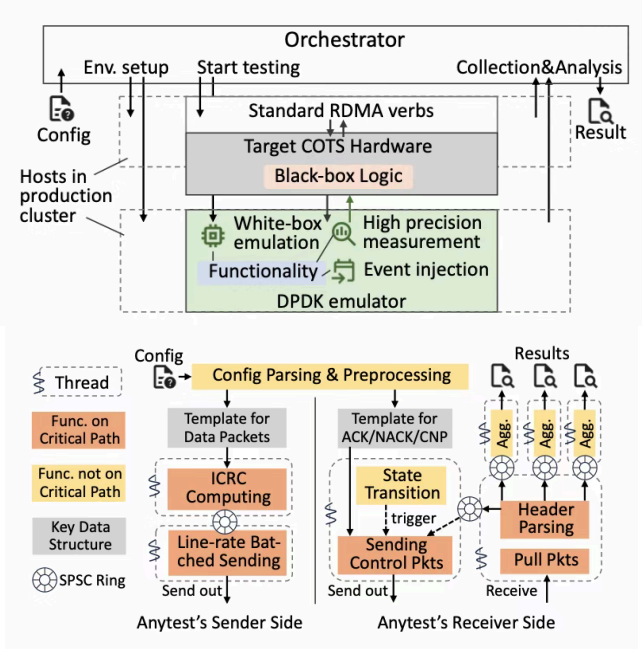
论文下载地址：
https://dl.acm.org/doi/pdf/10.1145/3789240.3829196

2.Anytest: Localizing the Root Cause of Hardware Transport Performance Anomalies

基于 RoCEv2 的 RDMA 已成为高性能计算、存储与大模型训练/推理的骨干互连。但随着规模扩大，即便没有链路或硬件故障，也频繁出现吞吐塌陷、持续不公平、延迟膨胀等传输层性能异常（NPA）。定位其根因是最棘手的运维难题：监控计数器停留在 10 毫秒到秒级，而硬件状态机在亚微秒级反应，微突发被平均掉；RoCEv2 是发送端、接收端与交换机紧耦合的分布式系统，同一症状可能源自多处；异常又与具体拓扑、固件强绑定，难以离线复现。传统计数器推断缺乏因果性，商用硬件测试仪需重新布线且离线，模糊测试类工具能发现却无法定位。

Anytest 的关键思路是做一个在位（in-situ）的黑盒测试工具，对 RoCEv2 进行角色分解：反应点 RP（发送端拥塞控制）、通知点 NP（接收端 CNP/ACK/NACK）、拥塞点 CP（交换机）。每次测试让被测设备（DUT）只扮演一个角色，用协议正确的 DPDK 端点模拟其余两个角色，从而把 DUT 从跨组件交互中隔离出来，把黑盒行为变成可检验的假设。为此它实现了三项能力：协议正确的白盒报文生成、事件注入（控制包与特定报文序列）、以及基于硬件时间戳的微秒级高精度测量；并用 O(1) 的 ICRC 快速路径、基于填充的包间隔控制等技术在单核实现 200Gbps 线速，可扩展至 400/800Gbps。整体遵循“症状→测试轨道→角色隔离回归测试→触发条件”的工作流。

Anytest 已在阿里云 RoCE 集群按需部署约一年，覆盖 4 款网卡与 6 款交换机，累计定位 58 起 NPA，其中 39 起（67.2%）由回归测试套件零人工直接定位，平均定位成本仅 3.1 人时，而此前单个复杂案例的绕行排查可达约 20 人天。它成功揭示了拥塞塌陷（固件 CNP 回复模式、隐藏令牌桶、丢包抑制 CNP）、PER_QP 定时器聚合导致的 incast 不公平、DCQCN 对间隔敏感、固件相关的拥塞控制差异等真实根因。核心启示是：可靠定位必须依赖角色隔离、微秒级分辨率与包级注入，配置并不等于语义、拥塞反馈本身也可能失效，都需以在线执行证据来验证。



论文下载地址：

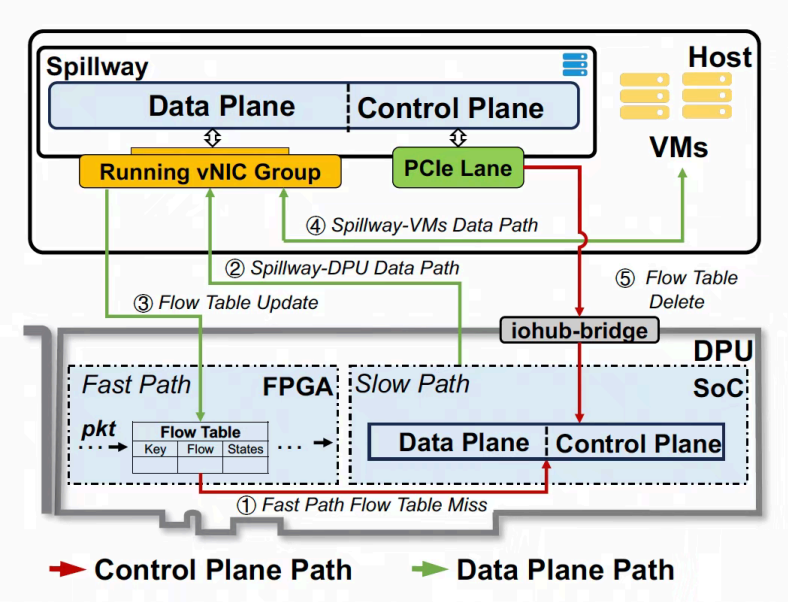
https://dl.acm.org/doi/pdf/10.1145/3789240.3829125

3.Spillway: Orchestrating DPU and Host into a Unified vSwitching Fabric

现代云数据中心普遍依赖 DPU 卸载 vSwitch 转发功能，以降低主机侧资源开销、强化租户隔离。然而 DPU 的内存、CPU 等资源有限，硬件升级周期较长，严重制约了 vSwitch 所能支撑的 session 表容量、conntrack 流数和 CPS 性能。与此同时，AI 训推、NFV 等业务呈现出短连接突发、连接风暴等高度动态的流量特征，使得 DPU 资源更容易饱和，而主机侧算力却大量闲置、无法被利用。

为此，阿里云云网络团队提出了 Spillway —— 打破单节点内 DPU 与主机计算域之间的刚性边界，构建业界首个 DPU–Host 混合数据平面，实现 vSwitch 虚拟转发的平滑弹性扩展。当 DPU 资源使用饱和时，统一资源调度器在主机空闲 vCPU 上启动 Elastic VM 以运行 vSwitch 处理溢出流量，对租户和控制平面完全透明。流量调度采用 sketch 测量机制，结合 Top–K 策略只回注最具成本效益的流。在租户隔离方面，配合 pCPU 绑定、NUMA 优化、CAT/MBA 控制、用户态虚拟 ATC 等先进虚拟化技术规避了资源竞争，实现租户性能的强隔离。

Spillway 已在阿里云大规模部署超12个月，覆盖 3000 余台服务器，单节点CPS性能提升最高90%，应对流量突发弹性扩容仅需 200 ms，比跨节点故障转移快了一个数量级，而对同节点其他租户的吞吐干扰不超过 1%。大规模生产部署验证了方案的实用性与经济价值，为 AI 时代云网络应对动态流量奠定了新底座。



论文下载地址：

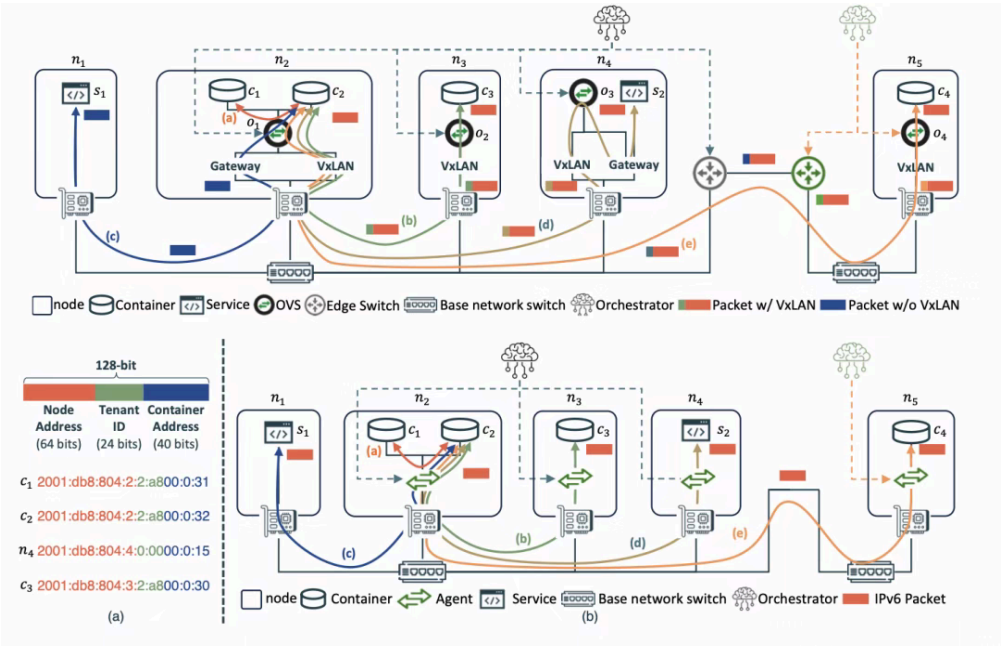
https://dl.acm.org/doi/pdf/10.1145/3789240.3829154

4.From Nimitz to NetPila: The Evolution of Production-Scale Container Network

在大规模云容器服务中，容器网络需要同时满足弹性、性能与稳定性三重要求。阿里自 2019 年起构建的第一代容器网络 Nimitz 采用 VxLAN 实现"overlay—underlay"映射，在数千租户、数十种业务上稳定运行了五年。但随着 AI 训练与推理兴起，单租户容器规模突破 O(100K)，Nimitz 遭遇"C100K 问题"：VxLAN 映射表随容器数线性膨胀，单个 OVS 表项逼近 50 万条；一次 10% 扩容就要处理 15 万次同步请求；封装/解封装还带来约 5% 的吞吐与延迟开销，并引发 RoCE 性能抖动、节点冷启动与清理缓慢等一系列退化。根因在于 VxLAN 人为割裂了 overlay 与 underlay 两个地址空间，必须在全网维护并广播全局映射，这在超大规模下难以为继。

NetPila 的关键思路是彻底抛弃 VxLAN，用 IPv6 编码取而代之。它把 64 位节点地址、24 位租户 ID 与 40 位容器地址编码进单个 128 位 IPv6 地址，使容器地址成为物理网络地址的自然延伸。由此容器网络不再需要 overlay—underlay 映射表，也不再封装/解封装，报文处理表复杂度从 O（容器数）降至 O（本地容器数），全部表项可静态卸载到网卡硬件；集群更新也从全局广播退化为节点本地的点对点通信。针对 IPv6 暴露节点地址的隐私风险，NetPila 用对称密钥 AES-128 对 IP 做密文替换，并默认丢弃所有报文、逐条校验源与目的以实现租户隔离。

NetPila 已在生产环境部署超过两年，代表性部署含 9,205 节点、589,120 容器，评测覆盖多达 2.5 万节点的作业。在 2.5 万节点上完成 10% 扩容，耗时从 Nimitz 的 12.5 分钟降至 1.25 分钟，即便扩展到 10 万节点也仅需 5 分钟；RoCE 延迟最多降低 4.281%、带宽最多提升 6.055%；vLLM 推理的首 token 时延、每 token 时延与 token 间时延分别改善约 0.8%、0.669% 与 1.081%，且相较原生 IPv6 的开销可忽略。实践表明，现代大规模容器网络很少真正用到 VxLAN 的 IP 迁移、自定义子网等"灵活性"，简单反而带来更好的弹性、稳定与性能。

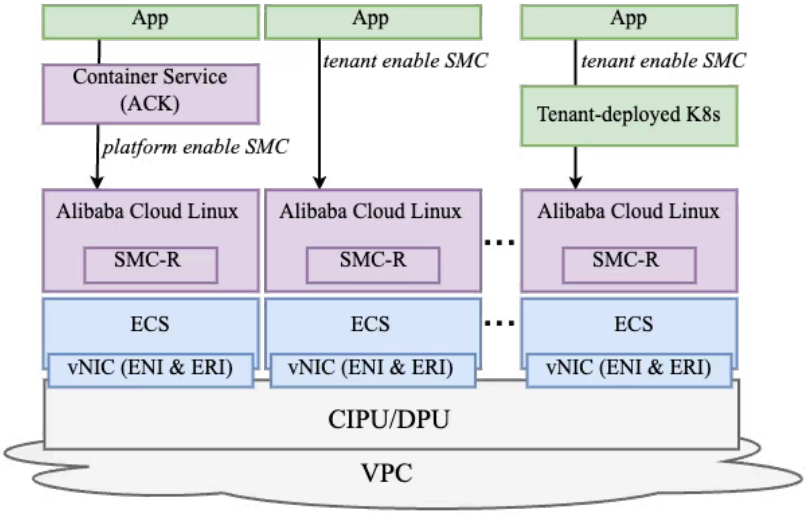


> 论文下载地址：
> https://dl.acm.org/doi/pdf/10.1145/3789240.3829203

5.Rethinking Transparent TCP Replacement: Practical Lessons from SMC-R in the Cloud

随着云上网络带宽迈向 100Gbps+，Linux 内核 TCP/IP 协议栈的处理开销日益凸显，而应用大多基于 socket 接口开发，难以改造为 RDMA 原生接口。透明 TCP 替换技术让应用无需修改即可享受 RDMA 加速，相关研究多年活跃于学术界，却始终缺乏生产级规模落地。依托阿里云自研的核心网络技术 eRDMA，团队历时四年，将内核态 SMC-R 方案在真实业务场景中推广和打磨。

论文系统梳理了透明替换“难以即插即用”的深层原因：启用机制不灵活、应用对 Linux TCP 的隐性依赖、运维生态缺口、中间件干扰等，并给出工程化解法：基于 eBPF 的内核级启用机制与连接级管控策略，无需侵入租户镜像即可按需启停，相关补丁已贡献至 Linux 上游社区。论文还厘清了端到端性能收益的真实来源：协议栈自身提速仅数微秒，生产环境中普遍存在的非最优系统配置与应用行为才是差距的主因，而透明替换恰好绕开了这些短板。在贴近生产默认配置的实测中，SMC-R 将 Redis 请求延迟最高降低 70%，MySQL 吞吐量最高提升 52%。



论文下载地址：

https://dl.acm.org/doi/pdf/10.1145/3789240.3829194



欢迎留言一起参与讨论~

阅读 4735　修改于2026年8月19日

留言

写留言

还没有留言，来写首评