面向监控场景的无订阅异常发现：问题、思路与边界

原创 孙晴 阿里技术 2026年7月30日 04:55 浙江 5人



这是2026年的第 44 篇文章

（ 本文阅读时间：约 20 分钟 ）

本文讨论一种面向监控指标的自适应异常发现方法：系统从多天历史数据中学习正常形态，在保留固定阈值、前序环比、昨日同比等线上订阅规则兜底的同时，无需等待用户逐条订阅，即可生成带证据的异常候选。
文中案例均已采用通用名称，日期及业务标识已隐去，量级与回放结果以相对化或区间化方式展示。图表用于说明数据形态与判断逻辑，不代表具体业务规模。

01
研究问题与边界：
未订阅指标如何进入异常发现视野

现有监控告警通常从三个角度观察指标变化：固定阈值判断当前值是否越过明确边界；前序环比比较相邻时间槽，用来发现突然跳变；昨日同比比较当天与前一日的同一时刻，吸收一部分日内周期。实际使用中，三者既可以单独配置，也可以组合使用，**由固定阈值守住底线、前序环比捕捉突变、昨日同比提供时间参照**。这些方法简单、透明、容易解释，是现有告警体系的重要基础。

三种口径也各有适用边界。固定阈值不会随凌晨、白天和晚高峰的量级变化而调整；前序环比容易放大低基数和短时抖动，对每一步变化不大但持续恶化的过程又不够敏感；昨日同比虽然比较了相同时间槽，却只参考相邻一天，遇到周末、活动期、业务增长，或者参照日自身存在异常时，结果就可能失真。为了让规则适应具体指标，用户通常还需要选择比较口径、填写阈值和连续命中次数，再根据运行结果反复调参。规则可以稳定执行这些条件，却不会仅凭多天历史自动理解日内高低峰和不同日期类型的正常差异。

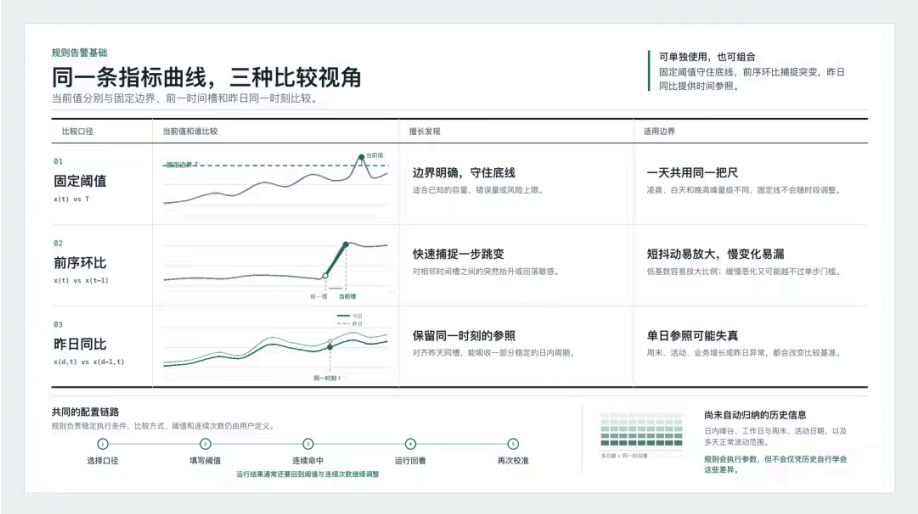


图 1：现有告警的三种常用比较口径与适用边界。固定阈值观察绝对边界，前序环比比较相邻时间槽，昨日同比比较跨日同槽；三者可以组合使用，但仍依赖人工选择口径、设定阈值并持续校准。

真正的覆盖缺口，往往出现在新接入或尚未订阅的指标上：规则配置完成之前，指标不会主动进入告警视野；即使已经配置，同一个数值在凌晨可能明显反常，放到晚高峰却只是正常流量。过去一段时间，我们做过未订阅指标巡检、日报提醒和虚拟监控兜底，也对大量历史告警样本进行了批量分析。这些实践扩大了监控覆盖面，也让我们看到，**低基数波动、自然流量变化和规则误配，仍会产生不少低价值消息。**

基于这些观察，本次研究没有把目标设为替换线上订阅规则，而是尝试补充一条自动发现路径：在保留固定阈值、前序环比和昨日同比等线上订阅规则兜底的前提下，系统直接从指标的多天历史中学习正常形态，在用户尚未订阅、尚未选定比较方式和阈值时，先生成可供核验的异常候选。围绕这个目标，我们验证了「**固定粒度指标数据 → 历史回放 → 指标画像 → 时间前推离线选模 → 异常候选**」这条完整链路。



图 2：从原始观测到异常候选的五段研究链路。

02
步骤一：准备数据——把指标放进统一的时间坐标

研究从监控平台已经采集到的指标数据开始。对同一个监控指标，我们按 10 分钟粒度聚合每天的观测值，再把连续多天的数据排成矩阵：每一行代表一天，每一列对应同一个时间位

置。这样的整理并不复杂，却决定了后面的历史比较是否成立。真正关键的不是马上套模型，而是先把数据口径弄清楚：

- 真实的零值和没有采集到数据不能混为一谈。
- 数据延迟补写造成的尖峰，不能直接当成业务异常。
- 总量、影响用户数和错误占比回答的是不同问题，不能塞进同一条规则里比较。
- 活动期、周末和日常日期需要保留上下文，不能默认完全同分布。

选择 10 分钟粒度，是在灵敏度和稳定性之间做折中：它比小时粒度更容易捕捉突发变化，又比分钟级数据更能过滤短暂抖动；固定时间槽也让不同日期落到了同一套可比较的时间坐标上。

03
步骤二：识别形态——从多日历史中看懂正常状态

得到多天数据后，我们先用两种最直观的方式回看历史。热力图把每天放在一行，将一天中的时间槽横向展开：颜色相近，说明同一时刻的水位接近；某一天出现明显高亮带，往往意味着持续偏离。多日同屏曲线则把每天的走势叠在同一条时间轴上，日内规律、固定时段峰值和偶发噪声会更容易分开。两种视图放在一起后，我们观察到几类差异很大的数据形态；它们看起来都是「数值发生了变化」，判断方式却并不相同。

为什么聚合指标会形成可重复的条件概率形态

监控指标往往是大量用户行为经过业务链路和上报机制聚合后的结果，并不是完全随机的点列。即使没有活动，大多数人共同的作息也会带来稳定的昼夜节律：凌晨休息时整体流量较低，白天随用户日常活动增多而抬升，晚间又可能出现流量高峰。如果再叠加固定开场、定时发券、补货或截止时间等活动规则，用户会在相近时段集中响应，进一步形成可重复的峰谷与阶段性走势。

这不意味着每个用户每天都会做出相同选择，而是指**当星期类型、活动阶段、用户结构、流量入口、业务规则和采集口径等条件近似时，大量个体的随机差异在聚合后部分抵消，使指标的预期水位、峰谷位置和正常波动区间呈现稳定性。**因此，这里所谓的「可重复」不是每天复制同一条曲线，而是在相似条件下重复落入一个可学习的概率分布。后续基线学习的也正是这种「时段预期值 + 允许波动区间」，而不是一条不允许变化的固定模板。

下文的形态分类来自对大量监控指标的批量回看和共性特征归纳。为了让每种形态更容易理解，文中从具有相似特征的多个指标中各选取一个代表性样本，并使用通用名称说明。案例用于帮助识别共性形态，不代表相应形态只存在于某一类业务。

稳定日内型：高峰并不天然异常

在稳定日内型指标中，多天曲线通常共享相近的日内轮廓。下图选取的**某交易指标**是其中一个代表性案例：每天的绝对水位会变化，但凌晨、白天和晚间的节奏大体一致，因此适合比较历史同一时间槽。

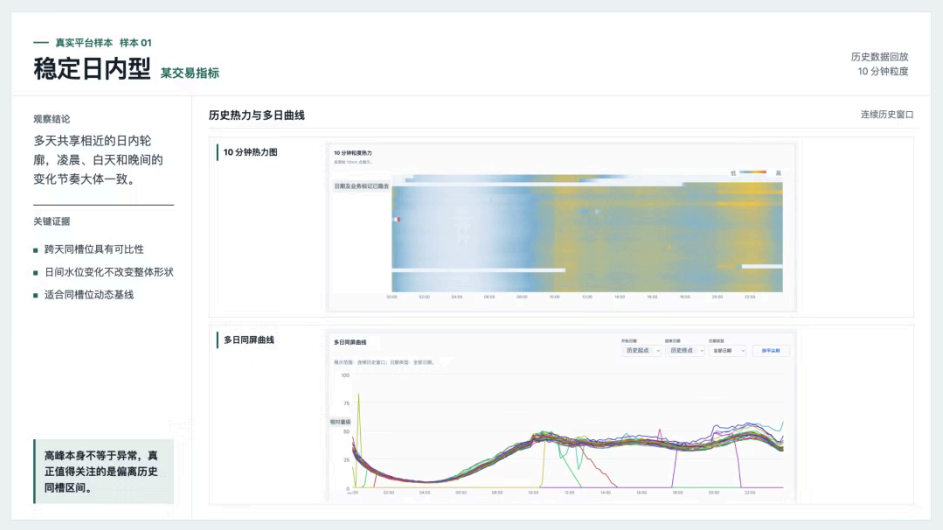


图 3：稳定日内型的代表性案例。高峰期的数值虽然更大，但只要仍在历史同槽区间内，就不应该因为超过一条固定值而告警。日期及业务标识已隐去，横轴保留日内时刻，纵轴以相对量级展示。

周期尖峰型：正常尖峰需要被学进基线

在周期尖峰型指标中，峰值常在固定窗口重复出现，更像活动节律或业务机制。下图的**某请求指标**是这类特征的代表性案例；模型需要先学会这些可重复的峰值，再判断当天是否超过历史尖峰上界。



图 4：周期尖峰型的代表性案例。多个日期在相近时间出现峰值，尖峰的位置比尖峰本身更有解释力。日期及业务标识已隐去，横轴保留日内时刻，纵轴以相对量级展示。

随机尖刺型：单点越界不急着发消息

在随机尖刺型指标中，尖刺通常分散在不同时间，孤立点多，很难拟合成一条稳定日内曲线。下图选取的**某低量指标**是这类特征的代表性案例；这里更适合观察尖刺复发、持续时间和累计影响，而不是预测每一个尖刺。

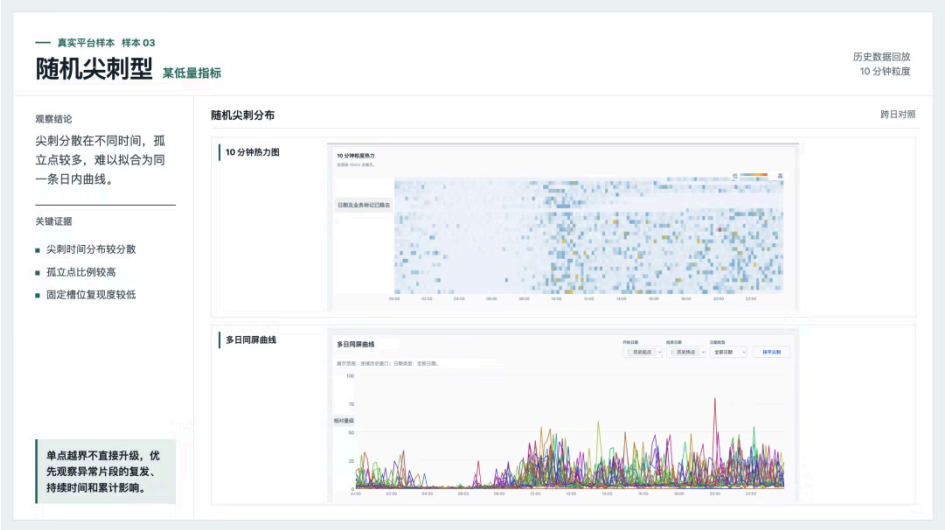


图 5：随机尖刺型的代表性案例。全天散落着短尖刺，固定阈值容易频繁触发，按异常过程聚合更适合描述它。日期及业务标识已隐去，横轴保留日内时刻，纵轴以相对量级展示。

持续偏离：连续异常比孤立点更值得关注

当某一天的观测值连续多个时间槽与历史曲线簇拉开距离时，就出现了持续偏离。下图的**某履约指标**是较为典型的案例；这种连续偏离比单点尖刺具有更高的候选优先级。



图 6：持续偏离的代表性案例。热力图形成连续高亮带，多日曲线中也能看到当天走势明显脱离历史区间。日期及业务标识已隐去，横轴保留日内时刻，纵轴以相对量级展示。

跨指标数据质量信号：先判断是不是大家一起变了

另一类共性现象会同时出现在多个业务逻辑互不关联、原始量级也相差很大的指标上。下图选取三个指标作为代表性案例：它们先按各自历史尺度独立归一化，因此比较的是变化节奏，而不是绝对值大小。尽管三条曲线来自不同业务链路，观测窗口开始后仍共同出现「回落—抬升—再次回落」的相近拐点，构成疑似多指标同窗变化信号。此时不宜马上把它们拆成多个业务异常，而应优先核验采集链路和平台状态。

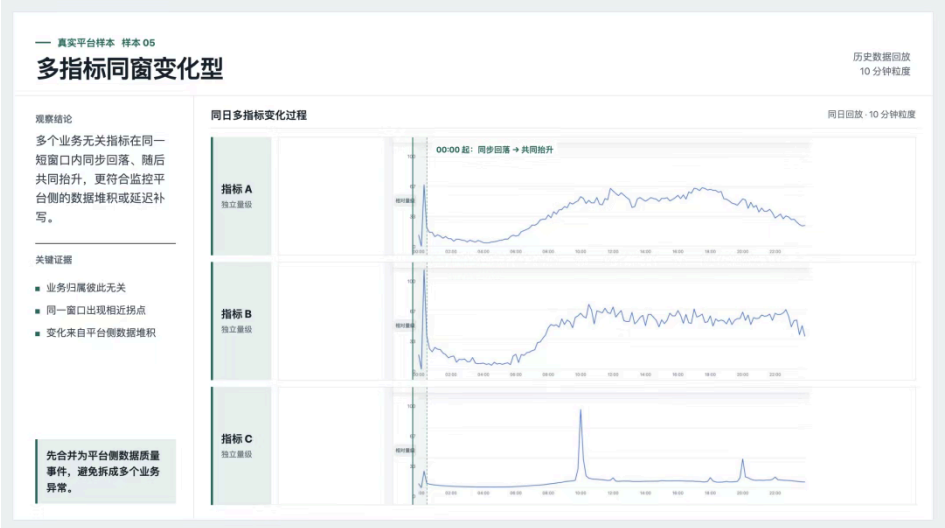


图 7：疑似多指标同窗变化的代表性案例。三条曲线的原始量级和业务逻辑均不同，按各自历史尺度归一化后，仍能看到相近的变化顺序和时间重合；标注仅覆盖同步回落、共同抬升和紧随其后的再次回落。跨指标一致性是单条曲线无法提供的重要证据。日期及业务标识已隐去，横轴保留日内时刻，纵轴以相对量级展示。

这些从批量观察中挑选出的代表性样本共同说明，**不同的数据形态需要不同的判断尺度。**监控如果主要依赖「超过固定值」「前序环比上涨几倍」或「昨日同比上涨几倍」这类单点比较，即使组合多条规则，也很难覆盖所有情况：稳定日内型可能在高峰期误报，随机尖刺型容易频繁触发，周期尖峰型可能把正常活动当成故障，低量指标还会被百分比变化过度放大。

04
步骤三：构建画像——把看图经验转成特征与策略路由

人工看图适合帮助研究人员建立直觉，却无法覆盖监控平台里的大量指标。要让这套方法自动运行，就需要把「看起来像什么」转换成可以重复计算的特征，用它们回答几类具体问题：数据有没有缺失、日常水位有多大、多天曲线是否共享同一轮廓、同一时间槽是否稳定、尖刺是随机还是周期出现，以及局部指标占总体的比例有没有发生结构性变化。



图 8：指标画像的主要计算依据。每项画像结论都有可核验的数据依据：可以定位到对应的历史数据片段，并查看相应的计算结果，例如缺失情况、日内稳定性、尖刺规律和结构变化；关键上下文不足时，结论保留为“不可判定”。

画像会按证据优先级逐项检查稳定日内、周期尖峰、随机尖刺、稀疏低量、比例异常、平台或数据质量敏感以及样本不足等方向；命中后，系统同时给出形态分类、判断依据、证据状

态和是否具备建模条件。如果缺少总量分母、关联指标或平台事件序列等关键上下文，相应结论会保留为"不可判定"，不会把证据缺失解释成未命中。



图 9：指标画像在研究样本上的输出示意。画像结果除形态分类外，还保留判断依据、证据状态和建模条件，并据此确定默认处理方式、异常过程回放和时间前推离线选模入口。图中数值采用区间或定性标签。

画像一旦形成，后续处理范围也随之收窄。图 9 中的研究样本被归为随机尖刺型后，单个尖刺不会因为一次越界直接升级，而会先进入尖刺预算和异常过程回放，继续比较复发次数、持续时间、累计超额面积和影响面。稳定日内型则重点比较历史同槽位，周期尖峰型保留固定窗口，稀疏低量型先处理最小基数和置信度。这样，后面的时间前推选模面对的是画像限定后的候选策略，而不是把所有模型无差别地套在每个指标上。

05
步骤四：回放选模——用时间前推选择适合当前指标的基线

有了画像之后，模型仍然不能拿全部历史拟合，再用同一批数据证明自己有效，因为那相当于提前看到了答案。这里采用时间前推回放：每次验证只使用此前已经发生的历史；完成一个验证窗口后，再把该窗口加入下一轮训练。窗口持续向前移动，直到覆盖全部可验证日期。

这套回放方式主要保证两件事：

1. 每个验证窗口都只使用当时真实可见的历史，不会看到未来数据。
2. 可以观察样本从不足到稳定的过程，而不是只看最后一个窗口的效果。

在离线回放中，我们会比较多种基线，包括动态谐波、稳健分解、同槽邻域中位数、同槽中位数、同槽截尾均值、同槽指数平滑和前一日同槽等方法。



图 10：同一指标在时间前推回放中的模型比较。不同方法在相同历史窗口和验证窗口中接受比较；图中仅保留相对误差和排序，不展示真实业务量级及精确评估数值。

常见误差指标可以评价预期曲线与实际曲线的距离，但选模不能只看哪条线拟合得最贴近。监控场景还关心边界是否稳定、正常尖峰能否被包容、持续异常能否进入候选、随机单点是否被过度放大，因此离线回放会同时保留两类结果：

- 模型中心预测的相对误差和排序；
- 动态边界、证据可信度以及异常候选的回放表现。

画像负责缩小研究方向，时间前推回放提供统一的历史考场。两者结合以后，选模不再依赖"这个算法听起来更先进"，而是看它是否更适合当前指标的数据形态。

06
步骤五：生成候选——用动态边界收敛异常过程

基线确定以后，系统的主要判断不再只依赖一条人工设定的比较规则，而是为一天中的不同时间槽学习各自的正常区间。以稳定日内型为例，白天某个时间槽的观测值会与历史相同时间附近的数据比较，而不会和凌晨或晚高峰混在一起。每个时间槽都会形成一个预期水位、一个需要继续观察的柔性边界、一个需要重点检查的高分位边界，以及对当前历史样本是否充分的可信度判断。

当天整体流量偏高或偏低时，基线也需要随之校正。模型会根据当天已经发生的时间槽估算水位变化，避免出现「整天流量都涨了，却只有某个点被误判」的情况。即便超过边界，观测值也不会立刻成为候选，还要继续检查几方面证据：

- 实际量和绝对增量是否足以排除低量抖动；
- 历史样本和日期上下文是否具有足够可信度；
- 是否显著超过高分位边界，或在短窗口内反复超过柔性边界；
- 孤立尖刺是否具有足够强度，否则先留在观察区。



图 11：实际曲线与动态基线、柔性边界和高分位边界的回放结果。候选点来自动态边界与持续性证据，不依赖用户预先配置当前值、前序环比或昨日同比的阈值。日期及业务标识已隐去，横轴保留日内时刻，纵轴以相对量级展示。

随机尖刺型使用另一套思路。它不追求准确预测每个尖刺，而是把时间上相邻的尖刺合并成一个异常过程，再看短时间复发、累计超额面积、持续时间和整体水位变化。一个孤立尖刺可以被容忍，同一过程反复出现或持续恶化时才升级为候选。

07
完整回放案例：将多次线上订阅规则命中收敛为一个持续候选

在一段连续多日的时间前推回放中，我们选取某低量指标的一天作为验证样本，模型只使用验证窗口之前可见的历史数据。当天，固定阈值和前序环比等线上订阅规则产生了多次命中；随机尖刺策略没有逐点升级，而是先将时间上相邻的尖刺合并为异常过程，再比较复发强度、累计影响和持续性。

回放结果显示，多数孤立命中没有形成达到历史分布上界的持续过程，因此被留在观察区；另有一组相邻命中落入同一个连续区间，合并后保留为一个异常候选。从模型视角看，相邻点属于同一件事，不应被拆成多条独立消息。



图 12：随机尖刺型告警回放。固定阈值、前序环比等线上订阅规则在当天产生多次命中，其中多数孤立点在离线回放中被留在观察区；一组相邻命中被合并为同一个连续过程，最终只保留一个具有持续性证据的候选。日期及业务标识已隐去，横轴保留日内时刻，纵轴以相对量级展示。

这个候选过程包含多个有效尖刺，持续时间超过历史同类过程的高分位水平。模型保留它，依据不是其中某一个点特别高，而是整段波动持续得明显比历史更久。回放中也有单点峰值更高，但因为只形成较短过程，没有越过持续性等综合门槛，仍留在观察区。

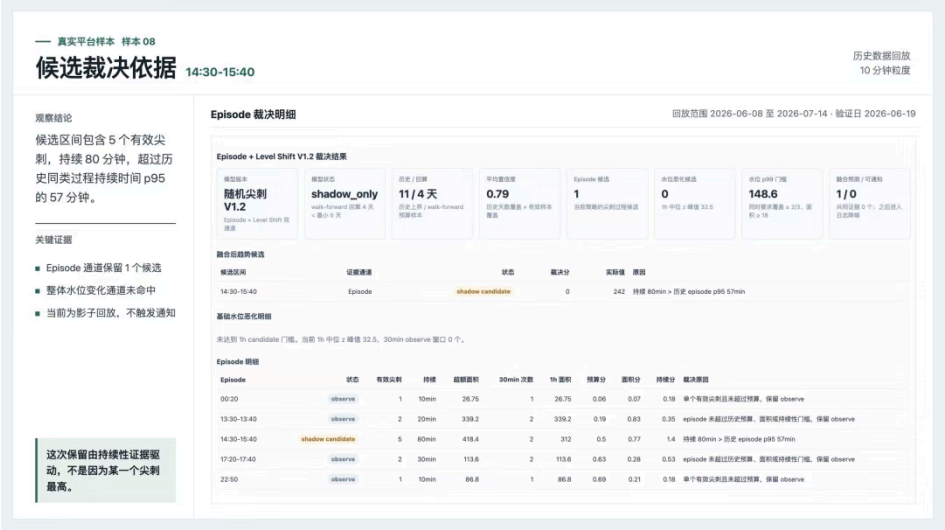


图 13：候选过程的裁决依据。连续区间在有效尖刺数量、累计影响和持续时间等方面超过历史同类过程的高分位水平，因此被保留为离线异常候选。图中采用定性证据和相对量级，不展示内部状态、精确评分或通知门槛。

最终输出的不是一个简单的「异常 / 正常」，而是一条带证据的异常候选，包含当前观测、历史预期、动态边界、证据可信度、持续情况和候选原因。

08
结果边界：异常候选为什么不等于通知

历史回放表明，候选生成阶段无需读取人工订阅规则，模型可以只根据指标历史生成异常候选。候选生成后，我们再把它与固定阈值、前序环比、昨日同比等线上订阅规则的历史命中做离线对照：部分样本里，线上订阅规则没有命中，动态基线却发现了持续偏离；另一些样本里，这类规则会被正常高峰或随机尖刺反复触发，画像策略则能把这些点留在观察区。

不过，「曲线不像平时」和「现在值得打扰业务」并不是同一个问题。平台延迟补写、活动期变化、少数用户集中请求、业务规则调整，都可能让曲线越过基线，仅凭数值模型还不足以决定是否通知。因此，这篇文章把研究终点严格放在**异常候选**：系统主动发现可疑变化，并给出可回放、可解释的证据，但不把每一个候选直接等同于一条告警消息。

「无需先订阅即可发现候选」的价值，在于为线上订阅规则补充一条自动发现路径，而不是替代它。过去，用户需要先为每条指标选择一种或几种比较口径，再分别配置阈值和连续次数；在这条研究链路里，只要指标已经有稳定上报数据，系统就可以先回放历史、识别画像、比较模型并生成候选。用户不必从一张空白规则表开始，也不必预先知道凌晨、晚高峰和活动期分别应该采用哪种口径、填写多少；候选是否升级为通知，则仍然要结合业务上下文和通知策略。

09
结论：
无订阅发现补充的是候选发现，而不是直接发消息

固定阈值回答「有没有超过一个数字」，前序环比回答「有没有突然变化」，昨日同比回答「是不是和前一日同一时间不一样」；自适应基线进一步追问的是，当前观测是否明显偏离了这条指标在多天历史和当前上下文中的正常状态。从固定粒度数据到历史回放，从画像分型到时间前推选模，再到动态基线生成异常候选，这条链路不是把线上订阅规则换一种写法，而是在"先靠经验配置规则"之外，增加一套可以计算、回放和解释的候选发现路径。

这套方法不假设一个模型适合所有指标，也不会把一次越界直接包装成智能告警。稳定日内曲线、固定窗 口尖峰、随机尖刺、低量数据和多指标同窗变化，各自使用与其形态相匹配的观察方式。**对告警自动化而言，关键不是提高发消息的速度，而是先用足够长的历史回答「这条指标平时是什么样」，再判断当前偏离是否值得进入通知链路。**



欢迎留言一起参与讨论~

留言 4

写留言



琳 广东 7月30日 2

可学习



Reed 浙江 7月30日 1

学习



50床 浙江 7月30日 1

学到了



蓝天 陕西 7月30日 1

优秀

首评